Sesión 2. Clasificación. Regresión logística

- Discriminantes lineales.
- Regresión logística.
- Métricas para evaluar modelos de clasificación.

Universidad de los Andes
Departamento de Ingeniería de Sistemas y Computación
Maestría en Ingeniería de Sistemas y Computación

Aparte

- ¿Qué es un algoritmo de aprendizaje? Ejemplo: regresión lineal.

Solo atributos numéricos

	x_1	x_2		x_d	y
Instancia 1					
Instancia 2					
Instancia N					

Aprendizaje supervisado
Tarea de regresión

Algoritmo de aprendizaje

Procedimiento de optimización

Función de costo

Procedimiento analítico:

Entrada = Conjunto de datos $D = \{(\boldsymbol{x}_i, y_i)\}_{i=1..N}$

Comienzo

Construir la matriz $\boldsymbol{X}$ *y el vector* $\boldsymbol{y}$ *a partir del conjunto de datos*

Calcular la pseudo-inversa $\boldsymbol{X}^+$ *de la matriz* $\boldsymbol{X}$ *=*

$$\boldsymbol{X}^+ = (\boldsymbol{X}^T\boldsymbol{X})^{-1}\boldsymbol{X}^T$$

Determinar los parámetros como:

$$\boldsymbol{w} = \boldsymbol{X}^+\boldsymbol{y}$$

Fin-procedimiento analítico

Salida = solución $\{\boldsymbol{w}\}$

Modelo estimado

Seleccionado de

Conjunto de hipótesis
H

$$\hat{y} = w_0 + w_1 \times x_1 + w_2 \times x_2 + \cdots + w_d \times x_d$$

$$parámetros\ del\ modelo = \{w_0, w_1, \ldots, w_d\}$$
$$d = No.\,de\ variables$$

$$J(W) = \frac{1}{N}\sum_{i=1}^{N}\left(\left((w_0 + w_1 \times x_{i1} + w_2 \times x_{i2} \ldots\ldots w_d \times x_{id}\right)\right) - y_i\right)^2$$

❑ ¿Cómo resolver el problema de optimización?

Ejemplo: método de descenso por el gradiente

Intuición…

Problema: los puntos rojos en este paisaje representan la ubicación de varios excursionistas y todos quieren descender lo más rápidamente posible a la zona más baja a su alcance (indicada en azul) ¿Cuál dirección debe tomar cada uno?

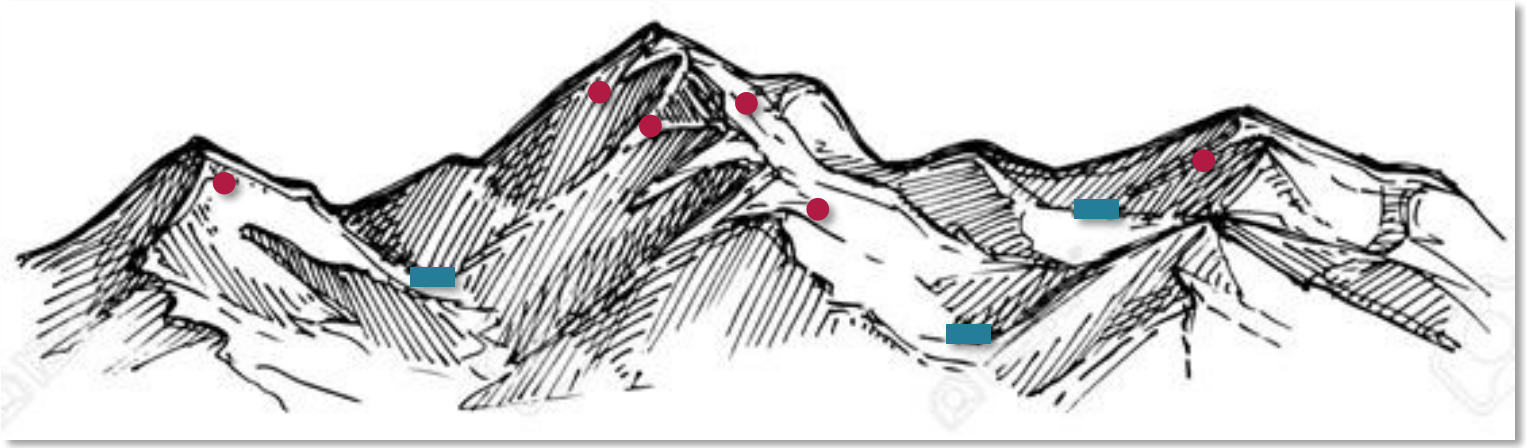

- Supóngase que se puede representar este paisaje (superficie) por una función de tres variables (x_1, x_2, x_3).
- Un punto en este paisaje (ubicación) lo dará el valor de la función $f(x_1, x_2, x_3)$.

☞ Se puede utilizar entonces el concepto de gradiente de una función.

☞ ¿Qué es el gradiente? El gradiente es un operador que, al aplicarse a una función, da como resultado un vector que apunta en la dirección de más rápido crecimiento de esa función.

☞ Por ejemplo, al evaluar el gradiente en los puntos que determinan la ubicación de nuestros excursionistas, se obtendrían las siguientes direcciones (flechas verdes):

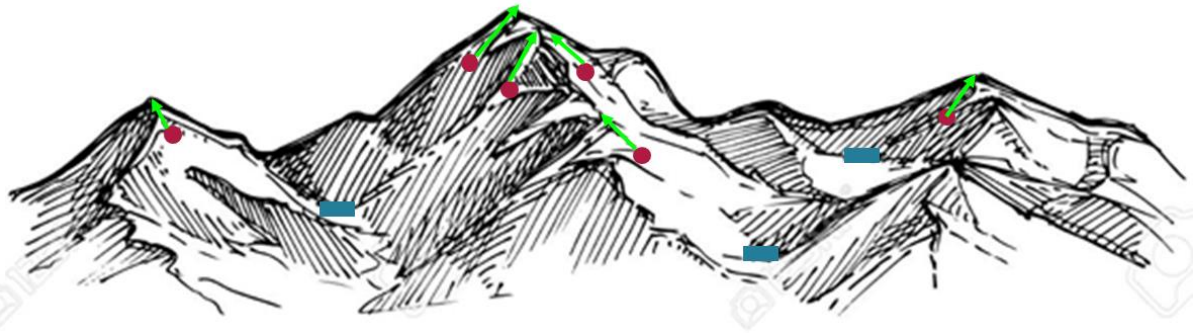

Pero no se quiere llegar al punto máximo, se quiere descender al punto más bajo.

¿Qué hacer? Tomar la dirección contraria.

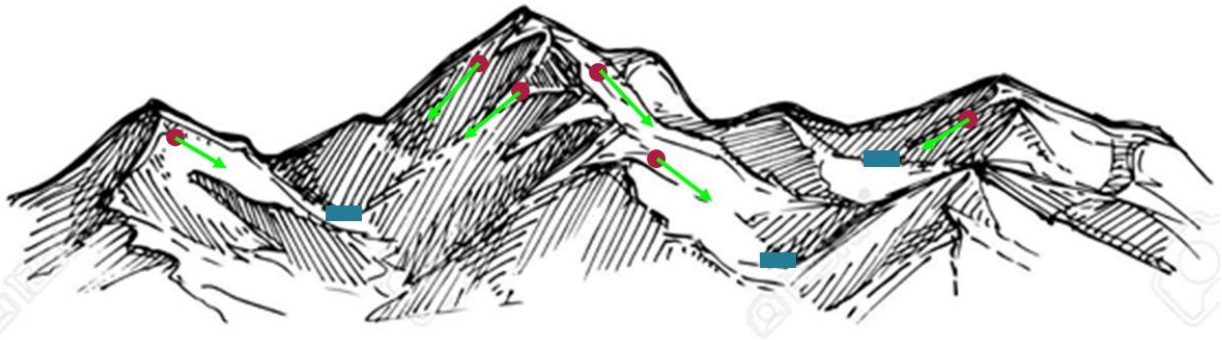

A partir de este concepto se construye entonces un método de optimización para determinar el mínimo de una función = **Método de descenso por el gradiente.**

- ¿Cómo determinar el gradiente? Supóngase que nuestra función paisaje está determinada por la siguiente expresión:

$$f(x_1, x_2, x_3) = 2{x_1}^2 + x_2^2 + 3x_3$$

- El gradiente de la función f será:

$$\nabla f(x_1, x_2, x_3) = \left(\frac{\partial f(x_1,x_2,x_3)}{\partial x_1}, \frac{\partial f(x_1,x_2,x_3)}{\partial x_2}, \frac{\partial f(x_1,x_2,x_3)}{\partial x_3}\right)$$

$$\nabla f(x_1, x_2, x_3) = (4x_1, 2x_2, 3)$$

- Por ejemplo, al evaluar el gradiente en el punto $\boldsymbol{x} = (0.5, 0.5, 1)$, se obtiene el siguiente vector :

$$\nabla f(x_1, x_2, x_3)\Big|_{\boldsymbol{x}=(0.5,0.5,1)} = (2, 1, 3)$$

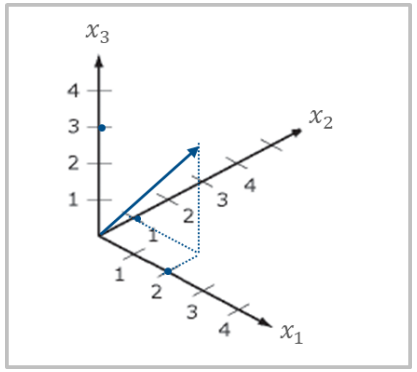

Optimización por descenso por el gradiente

Procedimiento iterativo:

$$k = 0$$

$$\boldsymbol{x}(k) = valor\ inicial$$

Repetir hasta convergencia

$$\boldsymbol{x}(k+1) = \boldsymbol{x}(k) - \alpha g_k \quad donde\ g_k = \nabla f(\boldsymbol{x})\Big|_{\boldsymbol{x}(k)}$$

$$k = k + 1$$

Se parte de valores iniciales de las variables de la función (cualquier punto en nuestro paisaje).

α = constante de aprendizaje.
Determina el "tamaño" del paso en cada iteración.

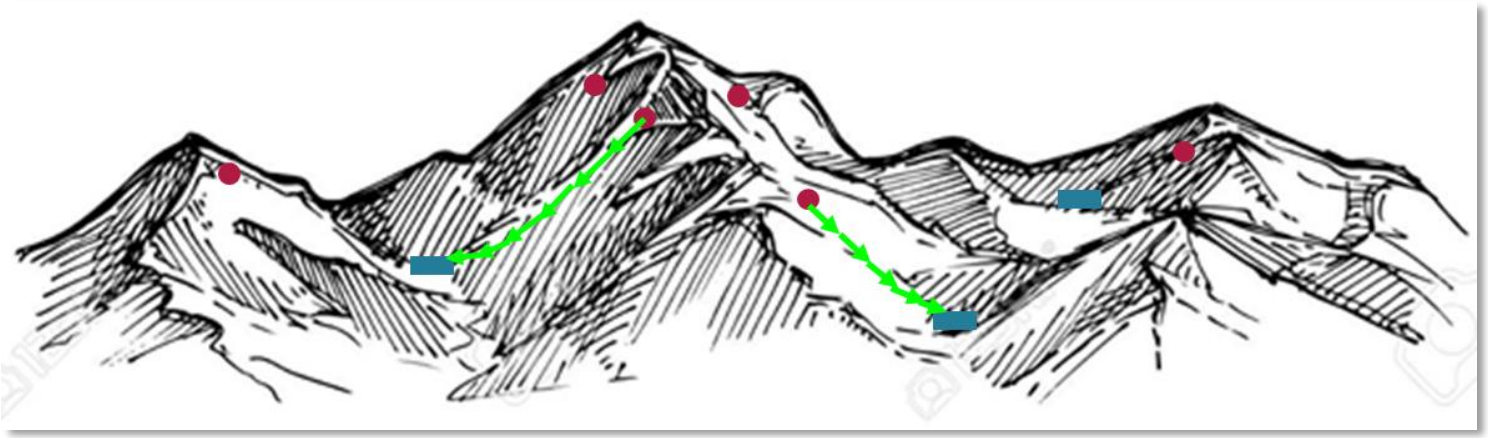

- El conjunto de pasos de actualización de los valores de $\boldsymbol{x}$, define una trayectoria, desde el punto inicial hasta el mínimo de la función.
- Al evaluar el gradiente en puntos diferentes (ubicaciones de nuestros montañistas) obtendremos vectores diferentes, que nos indican el "camino" (dirección) por el cual debemos avanzar para alcanzar nuestro objetivo.

Por ejemplo, en regresión lineal (una variable):

$$\boldsymbol{Función\ de\ costo} = \boldsymbol{J(\Omega)} = \frac{1}{N}\sum_{i=1}^{N}(\widehat{y_i} - y_i)^2 = \frac{1}{N}\sum_{i=1}^{N}\left((w_0 + w_1.x_i) - y_i\right)^2$$

- La función que define nuestro "paisaje" es la función de costo (es la función a optimizar).
- Variables = parámetros del modelo.
- <u>Objetivo</u>: determinar los valores de los parámetros que minimizan la función de costo.
- Gradiente de la función de costo:

$$\nabla J(w_0, w_1) = \left(\frac{\partial J(w_0,w_1)}{\partial w_0}, \frac{\partial J(w_0,w_1)}{\partial w_1}\right)$$

$$\frac{\partial J(w_0,w_1)}{\partial w_0} = \frac{2}{N}\sum_{i=1}^{N}((w_1 \cdot x_i + w_0) - y_i)(1)$$

$$\frac{\partial J(w_0,w_1)}{\partial w_1} = \frac{2}{N}\sum_{i=1}^{N}((w_1 \cdot x_i + w_0) - y_i)(x_i)$$

¿Cómo se actualizan los parámetros?

$$w_0(k+1) = w_0(k) - \alpha\frac{\partial J(w_0,w_1)}{\partial w_0}$$

$$w_1(k+1) = w_1(k) - \alpha\frac{\partial J(w_0,w_1)}{\partial w_1}$$

$$w_0(k+1) = w_0(k) - \alpha\left[\frac{2}{N}\sum_{i=1}^{N}((w_1 \times x_i + w_0) - y_i)\right]$$

$$w_1(k+1) = w_1(k) - \alpha\left[\frac{2}{N}\sum_{i=1}^{N}((w_1 \times x_i + w_0) - y_i)x_i\right]$$

¿Y cómo influye la constante de aprendizaje?

Tomar en cuenta que esta función de costo es convexa, solo tiene un mínimo global.

Por ejemplo, si $w_0 = 0$, se tendría:

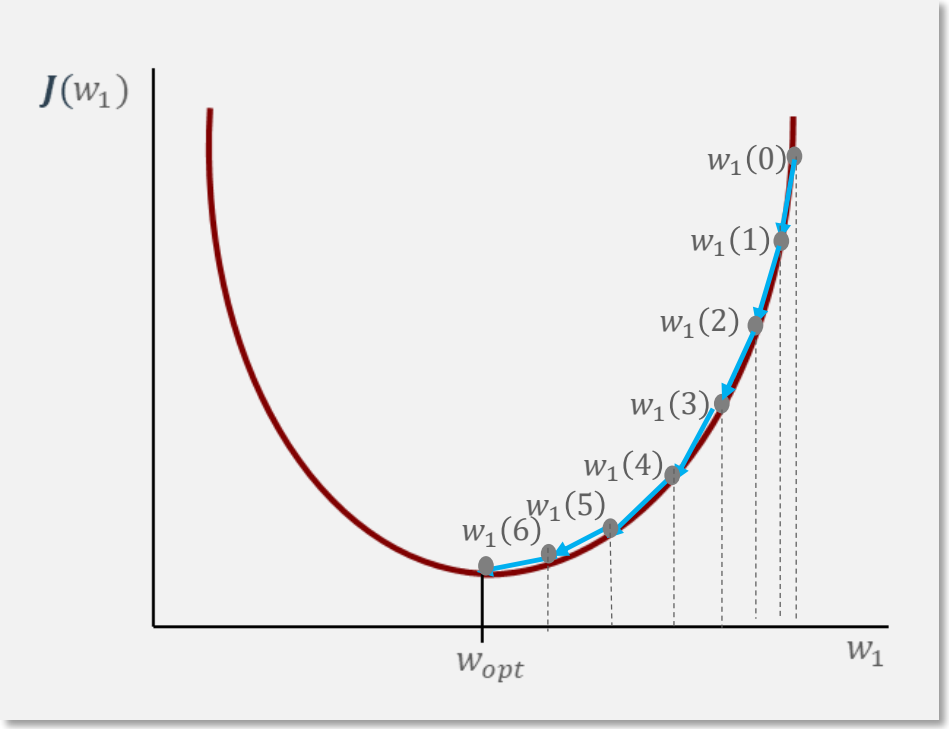

La constante de aprendizaje determina el "tamaño" del paso de actualización. →

La constante de aprendizaje es un parámetro del algoritmo que hay que ajustar ¿Cuál usar?

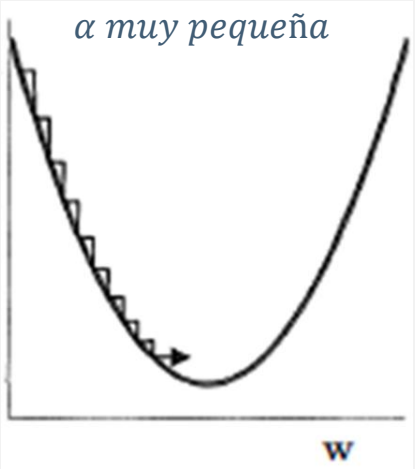

Convergencia pero tarda mucho

No converge

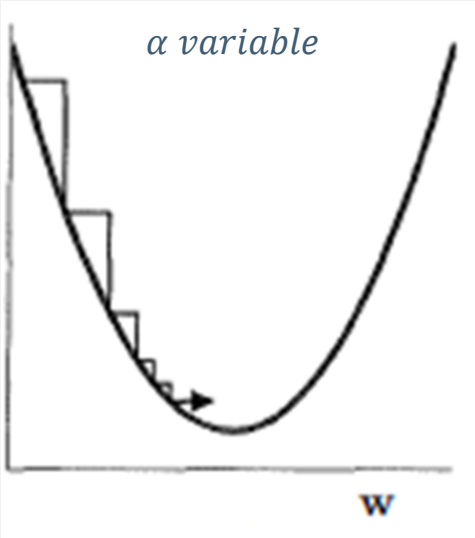

El valor depende de la iteración (adaptativa). Al principio pasos grandes, que se van ajustando.

Yaser S. Abu-Mostafa, Malik Magdon-Ismail, Hsuan-Tien Lin. (2012). *Learning from Data*. A Short Course. AMLBook.com

❑ ¿Cómo evaluar modelos de regresión?

¿Qué hace un algoritmo de aprendizaje para resolver la tarea de regresión?

x_1	x_2	.....	x_d	y
⋮				

$\hat{y}$

Las métricas de evaluación tienen en cuenta el valor y el estimado para todos los datos

Algoritmo de regresión

$$g: X \rightarrow Y / g(\boldsymbol{x}) = \hat{y}$$

$$\boldsymbol{x} = (x_1, x_2, x_3, \dots, x_d)$$

Objetivo: que el estimado $\hat{y}$ se aproxime al valor real tanto como sea posible.

$$\hat{y} \cong y$$

- **Algunas métricas para evaluar modelos de regresión:**

Métrica	Interpretación
$r^2 = coeficiente\ de\ determinación = \frac{\sum_{i=1}^{N}(\hat{y}_i - \bar{y})^2}{\sum_{i=1}^{N}(y_i - \bar{y})^2}$	Proporciona una medida de la proporción de la variación en la variable objetivo que es explicada por el modelo. Si, por ejemplo, r2 = 0.863 podríamos afirmar: “86,3% de la variabilidad en la variable respuesta es tomada en cuenta por la combinación lineal entre esta y las variables predictoras”. Dependiendo del contexto, podría no obtenerse valores altos de R2. Por ejemplo, en estudios sociales normalmente se obtienen valores inferiores al 50%, por la dificultad de incluir en el modelo todas las variables que pueden incidir en las predicciones. Sin embargo, aun con valores bajos, si hay variables predictoras estadísticamente significativas, siempre serán de utilidad hacer el análisis.
$Error\ cuadrático\ medio = MSE = = \frac{1}{N}\sum_{i=1}^{N}(\hat{y}_i - y_i)^2$	Para la interpretación, se suele utilizar la raíz cuadrada de este valor (RMSE) conocida como error típico o error estándar. Una ventaja es que el resultado se expresa en las unidades de medida de la variable objetivo. Es muy importante conocer la distribución de esta variable para poder determinar la calidad del modelo con base en el error. Por ejemplo, si el RMSE es de 5 ¿Podemos decir que el error es pequeño? ¿Es grande? Si la escala de la variable objetivo está entre [1, 10000] podríamos concluir que es pequeño, pero si la escala es de [1, 10] ¿También lo será? Seguramente no en este contexto. Al elevar al cuadrado el error de predicción se produce una sobreestimación cuando la diferencia entre el valor estimado y el valor real es grande.
$Error\ absoluto\ medio = MAE = \frac{1}{N}\sum_{i=1}^{N}\lvert\hat{y}_i - y_i\rvert$	Al igual que MSE, mide el error de predicción. Pero resulta más adecuada cuando en el conjunto de datos hay valores extremos.

Año	precio	kilometraje	motor	poder_maximo	asientos	combustible_CNG	combustible_Diesel	combustible_LPG	combustible_Petrol	propietario_First Owner	propietario_Fourth & Above Owner	propietario_Second Owner	propietario_Test Drive Car	propietario_Third Owner
2014	450000	145500	1248.0	74.0	5.0	0	1	0	0	1	0	0	0	0
2014	370000	120000	1498.0	103.52	5.0	0	1	0	0	0	0	1	0	0
2006	158000	140000	1497.0	78.0	5.0	0	0	0	1	0	0	0	0	1
2010	225000	127000	1396.0	90.0	5.0	0	1	0	0	1	0	0	0	0
2007	130000	120000	1298.0	88.2	5.0	0	0	0	1	1	0	0	0	0
2017	440000	45000	1197.0	81.86	5.0	0	0	0	1	1	0	0	0	0
2007	96000	175000	1061.0	57.5	5.0	0	0	1	0	1	0	0	0	0
2001	45000	5000	796.0	37.0	4.0	0	0	0	1	0	0	1	0	0
2011	350000	90000	1364.0	67.1	5.0	0	1	0	0	1	0	0	0	0
2013	200000	169000	1399.0	68.1	5.0	0	1	0	0	1	0	0	0	0

Algoritmo de regresión lineal

Attribute	Coefficient
Año	41325.047
kilometraje	-1.375
motor	62.155
poder_maximo	15376.899
asientos	-83764.513
combustible_CNG	-1304207.715
combustible_Diesel	-1342347.092
combustible_LPG	-1137825.371
combustible_Petrol	-1405728.344
propietario_First Owner	-297427.476
propietario_Fourth & Above Owner	-308554.679
propietario_Second Owner	-372519.938
propietario_Test Drive Car	2037632.758
propietario_Third Owner	-350738.963
(Intercept)	-81840138.488

Evaluación del modelo

RMSE: 290222.03

R^2: 0.65

¿Todo bien?

En general…

¿Qué debemos tener en cuenta para utilizar un algoritmo?

Por ejemplo, regresión lineal…

☞ Con respecto a los datos:

- Solo variables numéricas. Pero, si el conjunto de datos tiene variables nominales ¿Qué hacer?
- ¿Qué pasa con la correlación (colinealidad) entre las variables?
- ¿Qué otras características de los datos debemos considerar para este algoritmo? Por ejemplo, ¿se deben escalar las variables numéricas? ¿Es sensible a los valores extremos? ¿Escala bien con el número de datos?

☞ Con respecto a los resultados:

- ¿Cómo interpretar el modelo? ¿Qué significado tienen los coeficientes?

☞ Otros aspectos: control de la complejidad y ajuste de hiperparámetros, suposiciones sobre la función $objetivo$, contextos de aplicación, …

En resumen…

- Los algoritmos de aprendizaje trabajan sobre una clase de modelos (clase de hipótesis). Por ejemplo, la clase de hipótesis del algoritmo de regresión lineal es:

$$y = w_0 + w_1 \times x_1 + w_2 \times x_2 + \cdots + w_d \times x_d$$

- Cada clase de modelos tiene un conjunto de parámetros ajustables. Cada conjunto de posibles valores de estos parámetros define un modelo dentro de esta clase. Por ejemplo, para regresión lineal serán los coeficientes que acompañan a las variables de entrada en la combinación lineal.

- El algoritmo de aprendizaje de la regresión lineal es un procedimiento de optimización sobre una función de costo. Esta función de costo mide la discrepancia entre lo que predice el modelo y el valor real. Las variables de la función de costo son los parámetros de la clase de modelos con la que trabaja el algoritmo.

- La tarea entonces del algoritmo de aprendizaje es determinar los valores de los parámetros que mejor se ajustan a los datos (al hacerlo, implícitamente está seleccionado un modelo de la clase de hipótesis). Este modelo es el resultado del aprendizaje: una aproximación a la función (relación) desconocida que está representada por el conjunto de datos.

- Importante: **encontrar la representación de los datos que es adecuada para el algoritmo**.

¿Cómo resolver una tarea de clasificación?

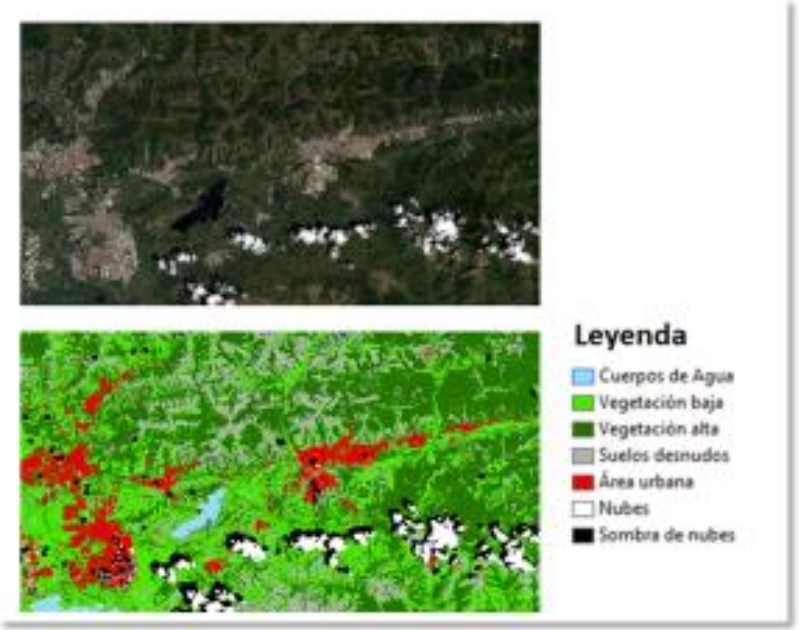

Proyecto: estudio sobre las enfermedades cardiovasculares con técnicas de machine learning.

Según la Organización Mundial de la Salud , las enfermedades cardiovasculares (ECV) son la principal causa de muerte en todo el mundo, y se estima que, para el 2030, 23,6 millones de personas morirán por alguna enfermedad de este tipo. Las ECV son un grupo de trastornos del corazón y de los vasos sanguíneos que incluyen, entre otras afecciones, a la enfermedad coronaria, enfermedad cerebrovascular y enfermedad cardíaca reumática. Cuatro de cada 5 muertes por ECV se deben a ataques cardíacos y accidentes cerebrovasculares, y un tercio de estas muertes ocurren prematuramente en personas menores de 70 años. Un pronóstico temprano podría ayudar a tomar decisiones sobre los cambios en el estilo de vida en pacientes de alto riesgo y, a su vez, reducir las complicaciones.
En este sentido, se quiere llevar a cabo un estudio, tomando como base los datos de los pacientes registrados en una institución médica, que utilice técnicas de machine learning para la construcción de modelos que, no solo aporten en la identificación de los factores que más inciden en el padecimiento de enfermedad cardíaca, sino también puedan predecir qué pacientes están en riesgo de sufrir una ECV.

age	gender	height	weight	systolic blood pressure	diastolic blood pressure	cholesterol	glucose	smoke	Alcohol	active	ECV
18393	2	168	62.0	110	80	normal	normal	0	0	1	0
20228	1	156	85.0	140	90	well above normal	normal	0	0	1	1
18857	1	165	64.0	130	70	well above normal	normal	0	0	0	1
17623	2	169	82.0	150	100	normal	normal	0	0	1	1
17474	1	156	56.0	100	60	normal	normal	0	0	0	0
21914	1	151	67.0	120	80	above normal	above normal	0	0	0	0
22113	1	157	93.0	130	80	well above normal	normal	0	0	1	0
22584	2	178	95.0	130	90	well above normal	well above normal	0	0	1	1
17668	1	158	71.0	110	70	normal	normal	0	0	1	0
19834	1	164	68.0	110	60	normal	normal	0	0	0	0
22530	1	169	80.0	120	80	normal	normal	0	0	1	0

Número de datos: 69.997
Número de variables: 12

https://www.who.int/es/health-topics/cardiovascular-diseases#tab=tab_1

Ciclo de ML

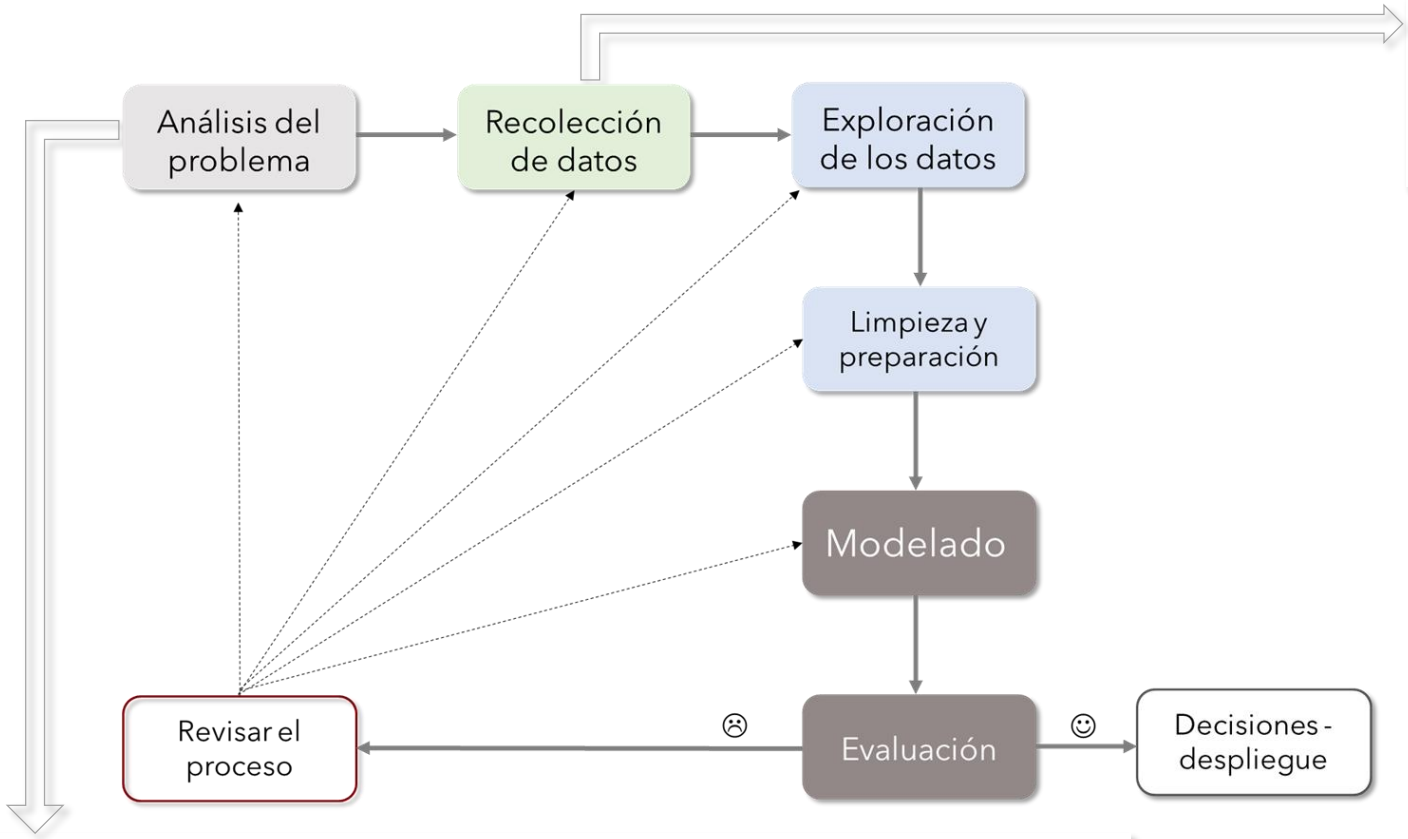

Primera visión de los datos:

Ayuda a determinar si el conjunto de datos es adecuado para resolver el problema.

Del análisis de los datos

Objetivos:

- Predecir qué pacientes están en riesgo de sufrir una ECV
- Identificar los factores que más inciden en el padecimiento de enfermedad cardíaca.

Tareas de aprendizaje:

Para alcanzar el primer objetivo se puede realizar una tarea de clasificación que utilice como variable target "ECV", la cual indica la presencia o ausencia de enfermedad cardiovascular. Dependiendo del algoritmo a utilizar se podría hacer un análisis de las variables más significativas, lo cual podría permitir alcanzar el segundo objetivo. O utilizar alguna librería que permita realizar una interpretación del modelo.

Del análisis del problema

Construcción de un modelo de clasificación

Solución propuesta: modelo de clasificación que permita predecir si un paciente tiene posibilidad de ser diagnosticado con ECV.

Variables de entrada = **x**

Clase = y

age	gender	height	weight	systolic blood pressure	diastolic blood pressure	cholesterol	glucose	smoke	Alcohol	active	ECV
18393	2	168	62.0	110	80	normal	normal	0	0	1	0
20228	1	156	85.0	140	90	well above normal	normal	0	0	1	1
18857	1	165	64.0	130	70	well above normal	normal	0	0	0	1
17623	2	169	82.0	150	100	normal	normal	0	0	1	1
17474	1	156	56.0	100	60	normal	normal	0	0	0	0
21914	1	151	67.0	120	80	above normal	above normal	0	0	0	0
22113	1	157	93.0	130	80	well above normal	normal	0	0	1	0
22584	2	178	95.0	130	90	well above normal	well above normal	0	0	1	1
17668	1	158	71.0	110	70	normal	normal	0	0	1	0
19834	1	164	68.0	110	60	normal	normal	0	0	0	0
22530	1	169	80.0	120	80	normal	normal	0	0	1	0
18815	2	173	60.0	120	80	normal	normal	0	0	1	0
14791	2	165	60.0	120	80	normal	normal	0	0	0	0
19809	1	158	78.0	110	70	normal	normal	0	0	1	0

Algoritmo de clasificación

Modelo de clasificación

ECV = 1 (SI)

ECV = 0 (NO

Nuevo dato (paciente)

Edad	Género	Altura	Peso	Presion sistólica	Presión diastólica	Colesterol	Glucosa	Fumador	Alcohol	Activo
50	F	171	76.0	90	60	Normal	Elevado	NO	NO	SI

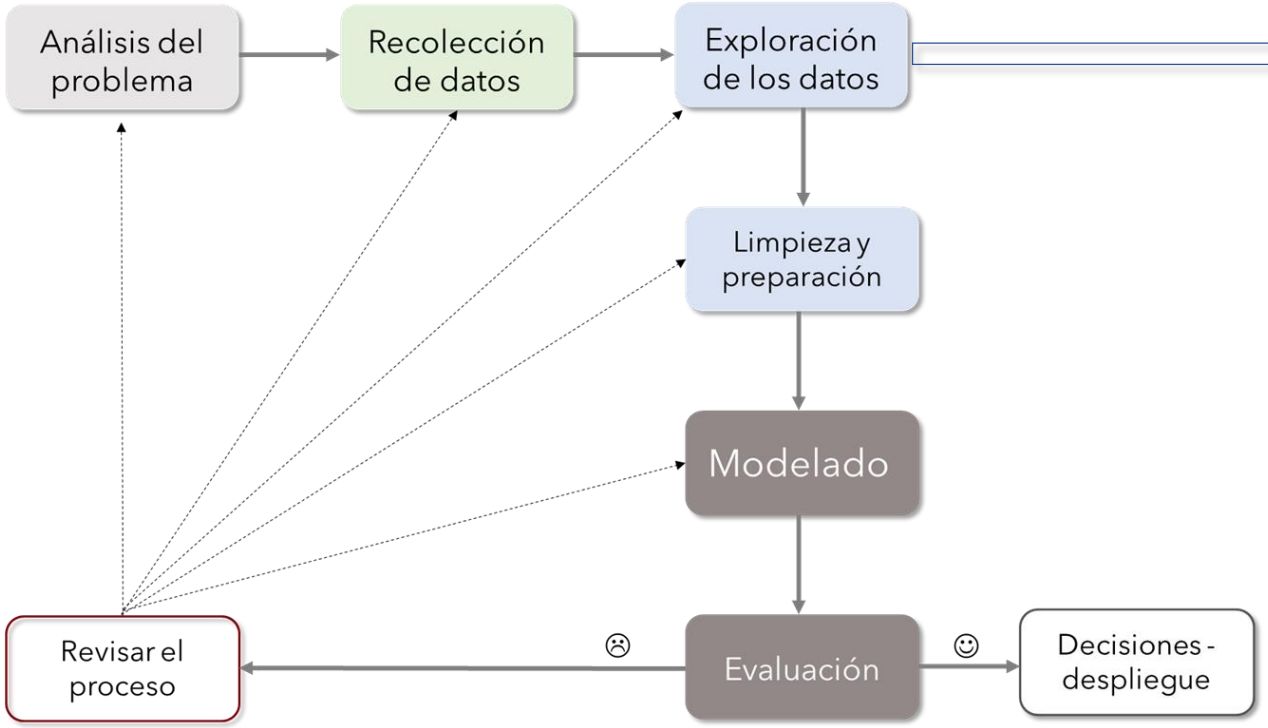

¿Limpieza de datos?

¿Cómo construir una buena representación de los datos para el algoritmo seleccionado?

¿Qué transformaciones aplicar?

Descripción de los datos (perfilamiento)

Importante: Diccionario de los datos

There are 3 types of input features:

Objective: factual information.

Examination: results of medical examination.

Subjective: information given by the patient.

Features:

Age | Objective Feature | age | int (days)

Height | Objective Feature | height | int (cm) |

Weight | Objective Feature | weight | float (kg) |

Gender | Objective Feature | gender | categorical code |

Systolic blood pressure | Examination Feature | ap_hi | int positive |

Diastolic blood pressure | Examination Feature | ap_lo | int positive |

Cholesterol | Examination Feature | cholesterol | normal, above normal, well above normal |

Glucose | Examination Feature | gluc | normal, above normal, well above normal |

Smoking | Subjective Feature | smoke | binary |

Alcohol intake | Subjective Feature | alco | binary |

Physical activity | Subjective Feature | active | binary |

Presence or absence of cardiovascular disease | Target Variable | cardio | binary |

All the dataset values were collected at the moment of medical examination.

Propuesta para la preparación de los datos:

- Las variables “cholesterol” y “gluc” son categóricas. Como solo asumen tres categorías, se puede aplicar una numerización 1-de-n (one-hot).
- Con base en el algoritmo a utilizar, será conveniente normalizar o estandarizar los datos.

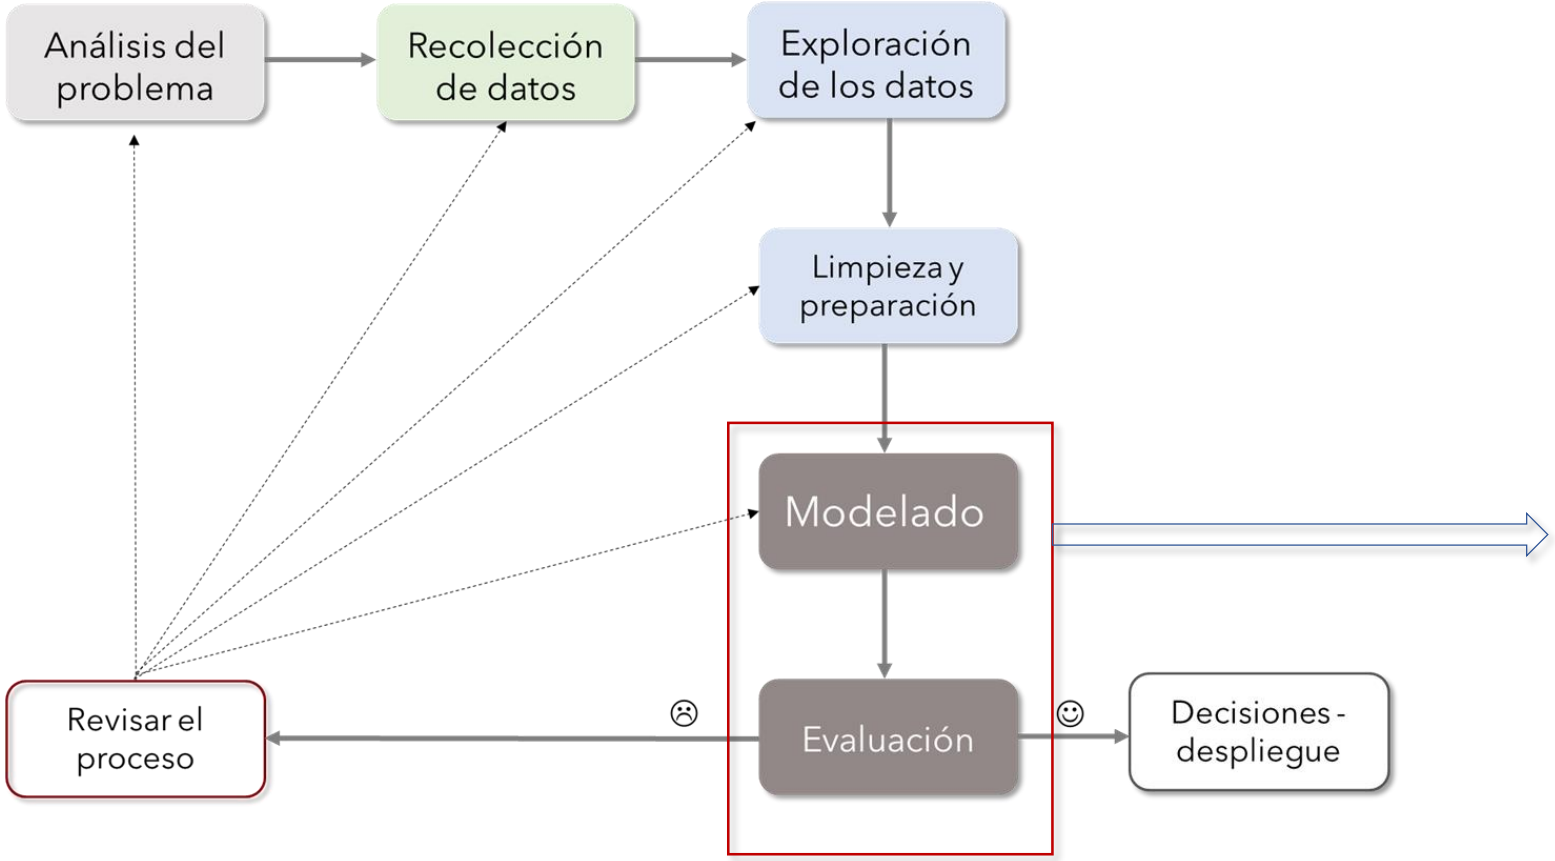

¿Cómo funciona un clasificador?

¿Qué métricas utilizar para evaluar clasificadores?

¿Qué hace un algoritmo de aprendizaje para resolver este problema de clasificación?

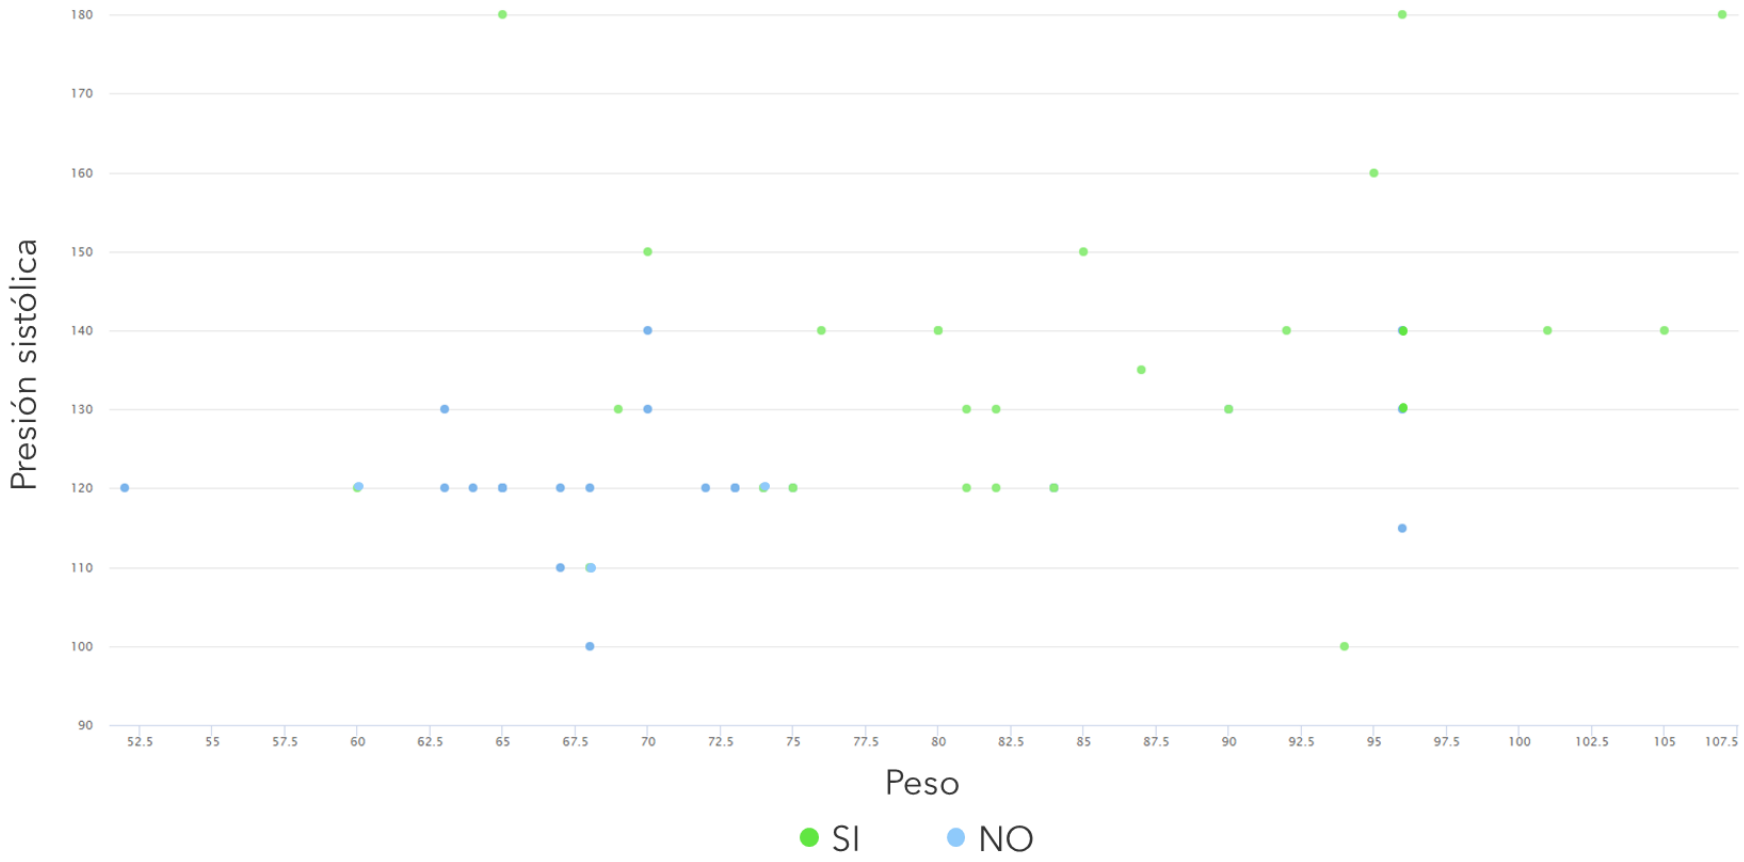

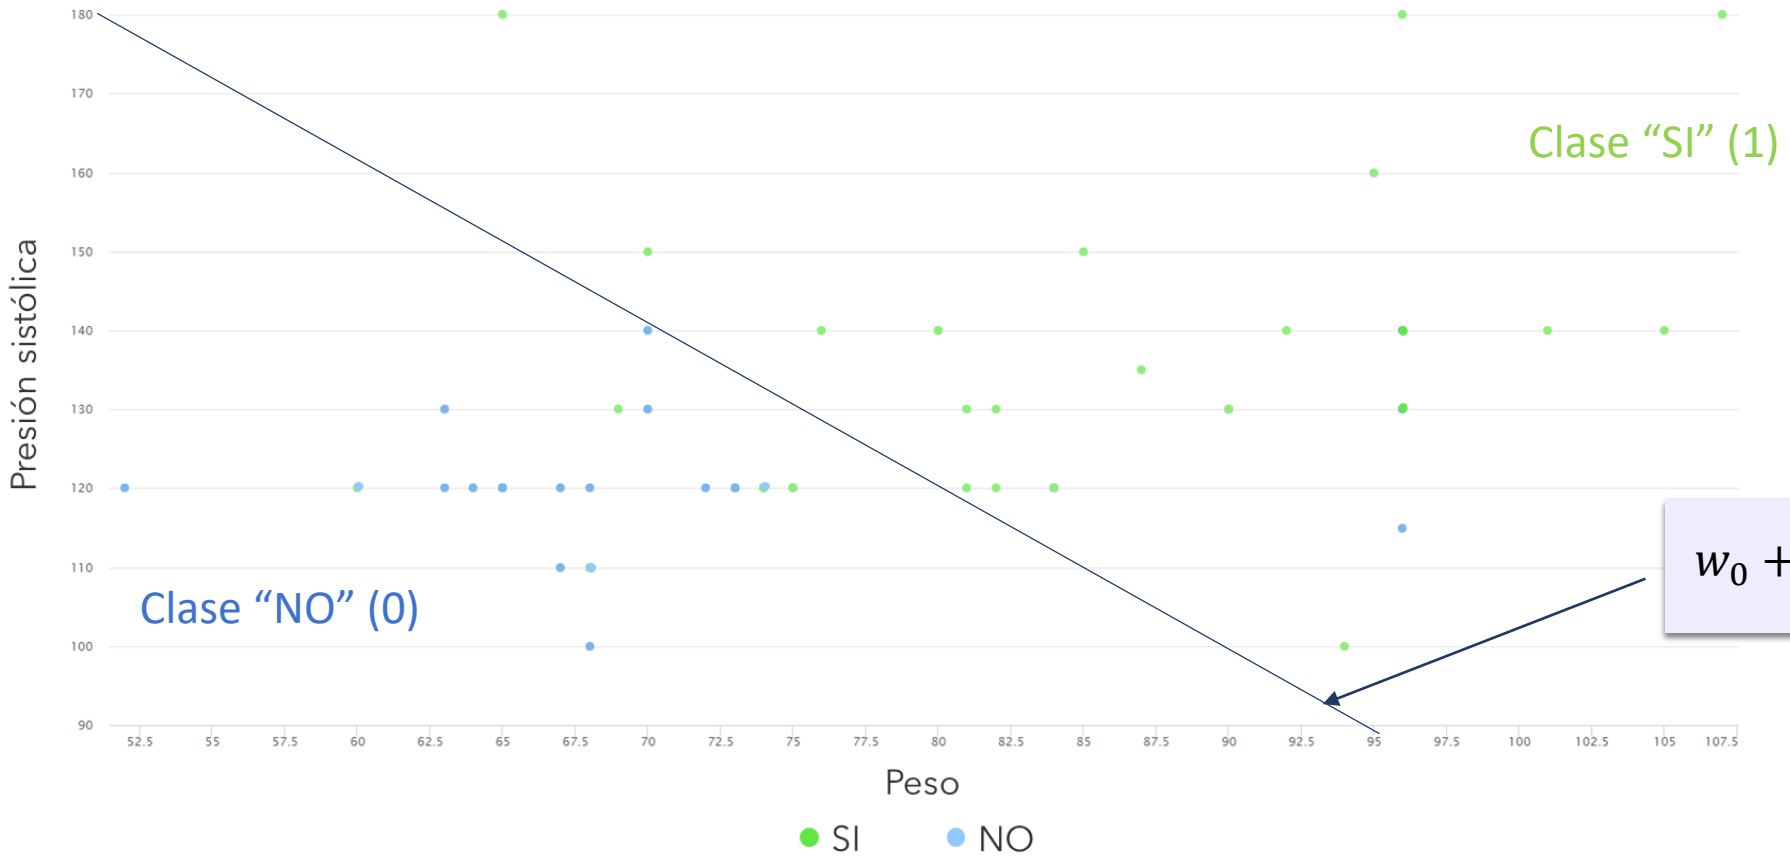

$$w_0 + w_1 x_1 + w_2 x_2 = 0$$

$$\text{Clase estimada} = f_{umbral}(w_0 + w_1 x_1 + w_2 x_2)$$

$$f_{umbral}(h) = \begin{cases} clase\ \text{"SI"} & si\ h \geq 0 \\ clase\ \text{"NO"} & si\ h < 0 \end{cases}$$

umbral

¿Cómo clasificar?

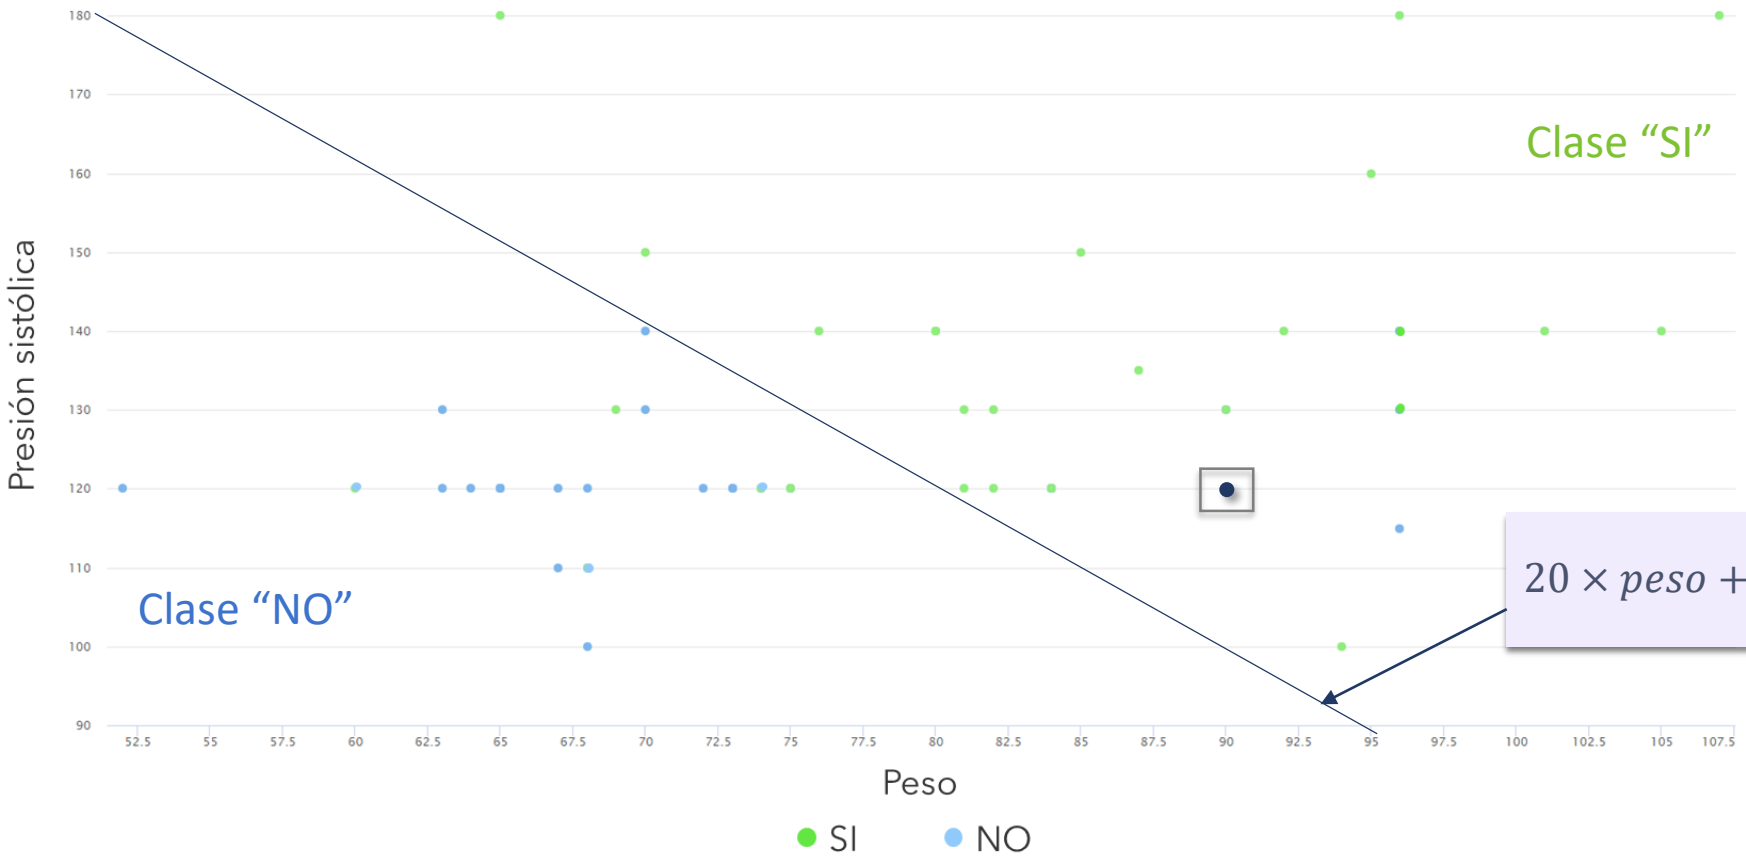

Discriminante lineal

$$20 \times peso + 10 \times presión\ sistólica - 2800 = 0$$

$$\begin{cases} \text{clase SI} \Rightarrow 20 \times peso + 10 \times presión\ sistólica - 2800 \geq 0 \\ \text{clase NO} \Rightarrow 20 \times peso + 10 \times presión\ sistólica - 2800 < 0 \end{cases}$$

$Si\ (90{,}120)$:

$$20 \times 90 + 10 \times 120 - 2800 = 200$$

$\Rightarrow Clase\ SI$

¿Cómo clasificar?

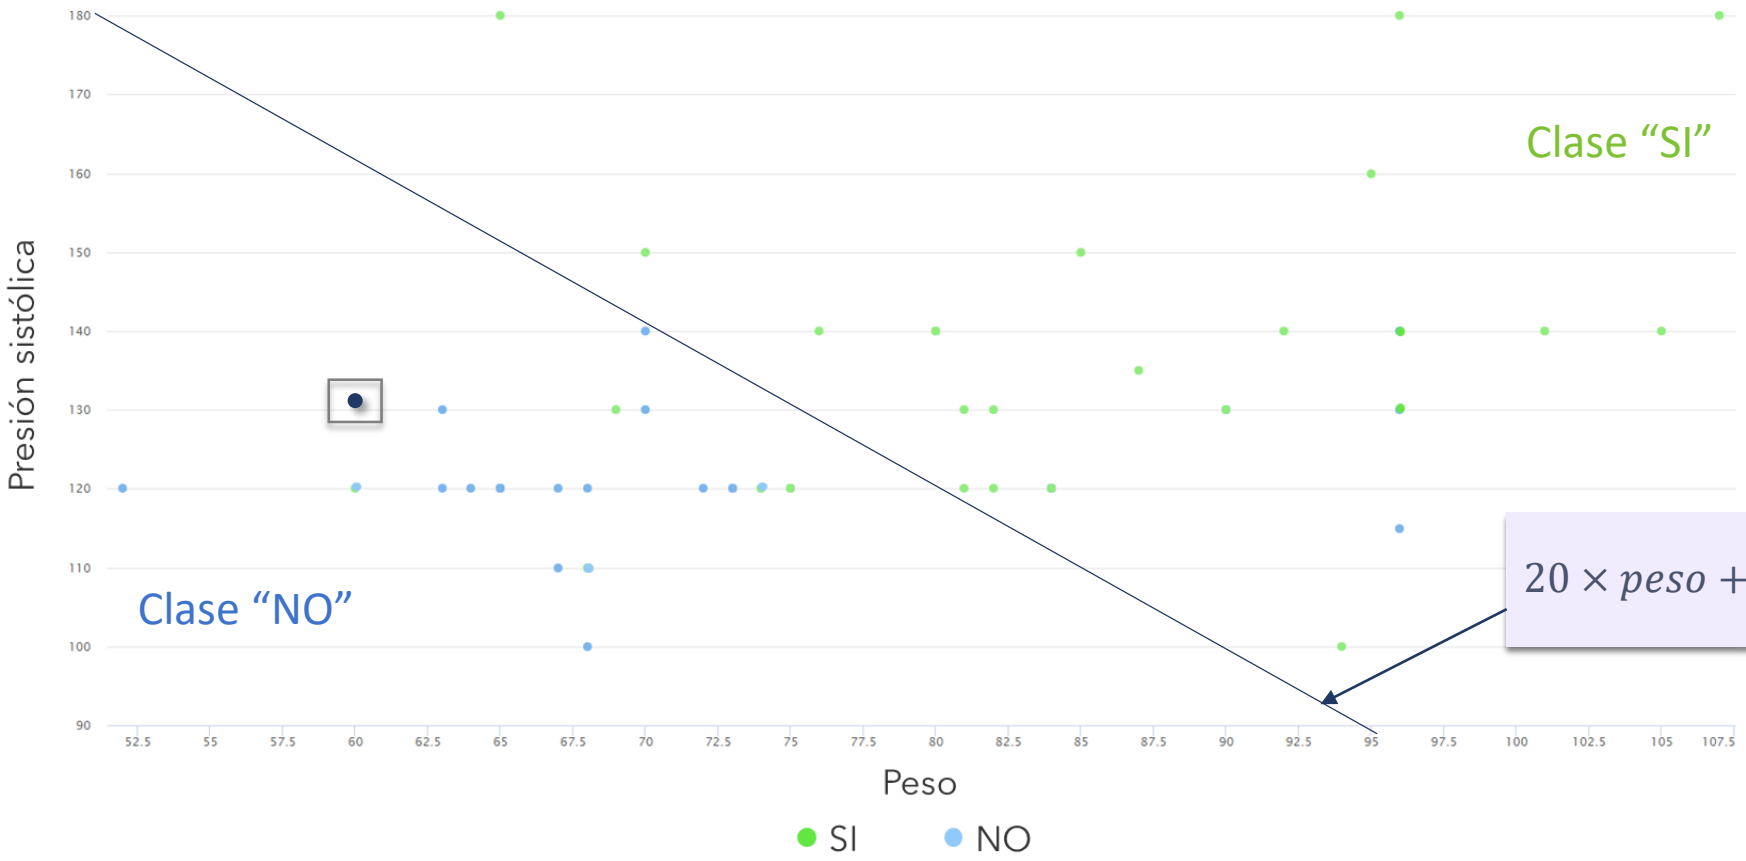

Discriminante lineal

$$20 \times peso + 10 \times presión\ sistólica - 2800 = 0$$

clase SI si: $20 \times peso + 10 \times presión\ sistólica - 2800 \geq 0$

clase NO si: $20 \times peso + 10 \times presión\ sistólica - 2800 < 0$

$Si\ (60{,}130)$:

$20 \times 60 + 10 \times 130 - 2800 =$ -300

$\Rightarrow Clase\ NO$

Algunos algoritmos:

Clasificadores binarios

- Regresión logística
- Máquinas de vectores de soporte

Clasificadores multiclase

- Árboles de decisión
- Redes neuronales
- Basados en probabilidades (Naïve Bayes)
- K-vecinos más cercanos
- Ensembles (metal algoritmos). Ej. Random Forest
- …

En general…

Datos

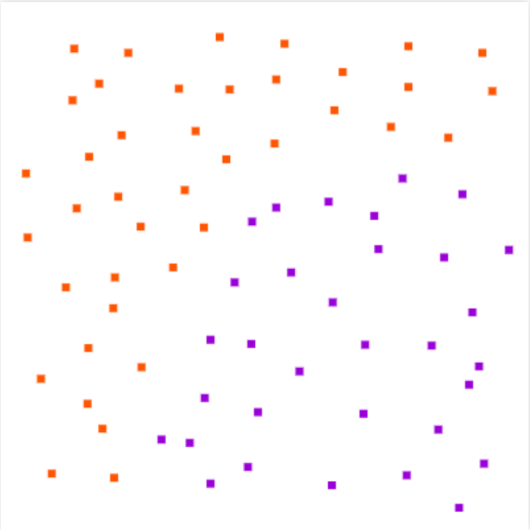

Discriminante lineal

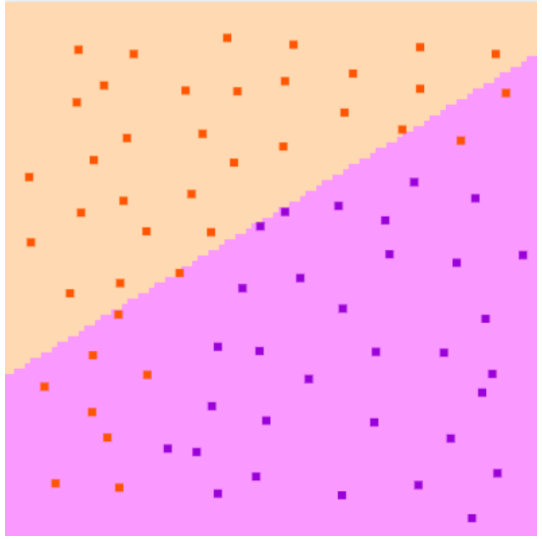

Árbol de decisión

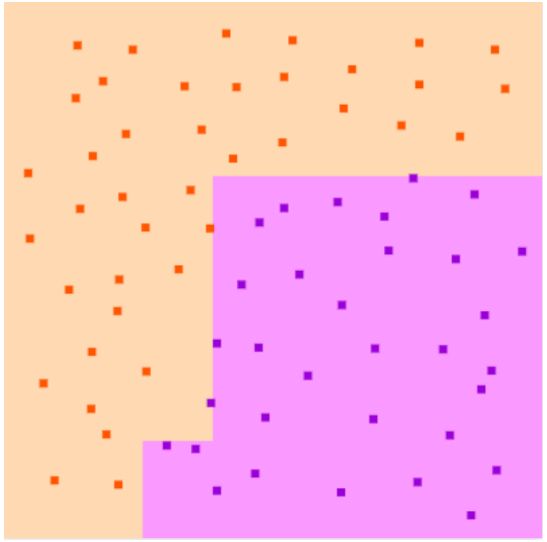

K-vecinos más cercanos

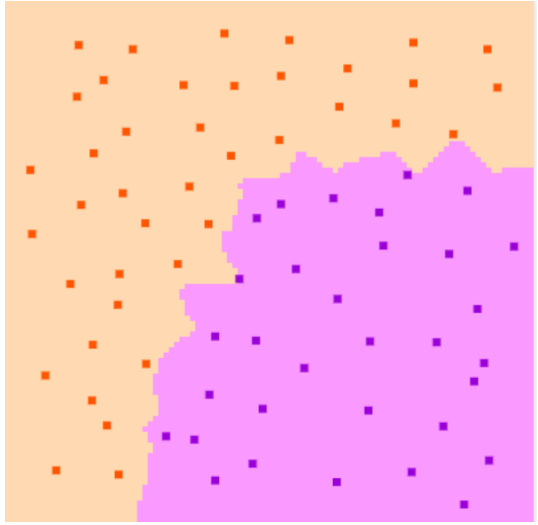

Red neuronal

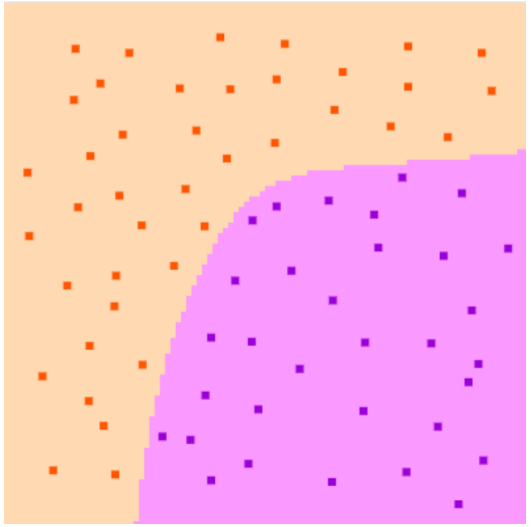

Máquina de vectores de soporte

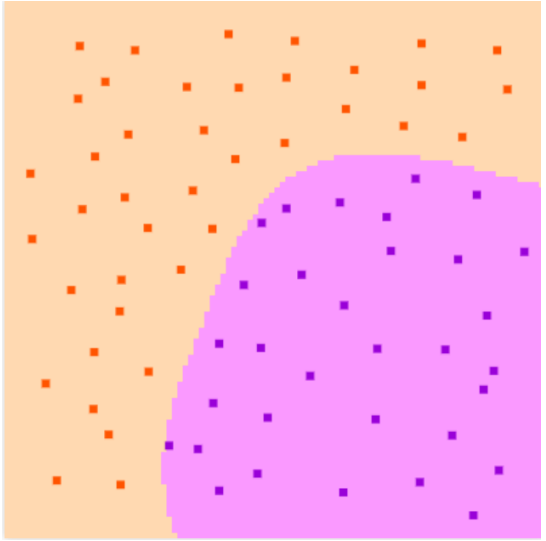

Machine Learning Playground. https://ml-playground.com/

Problema de clasificación de dos clases:

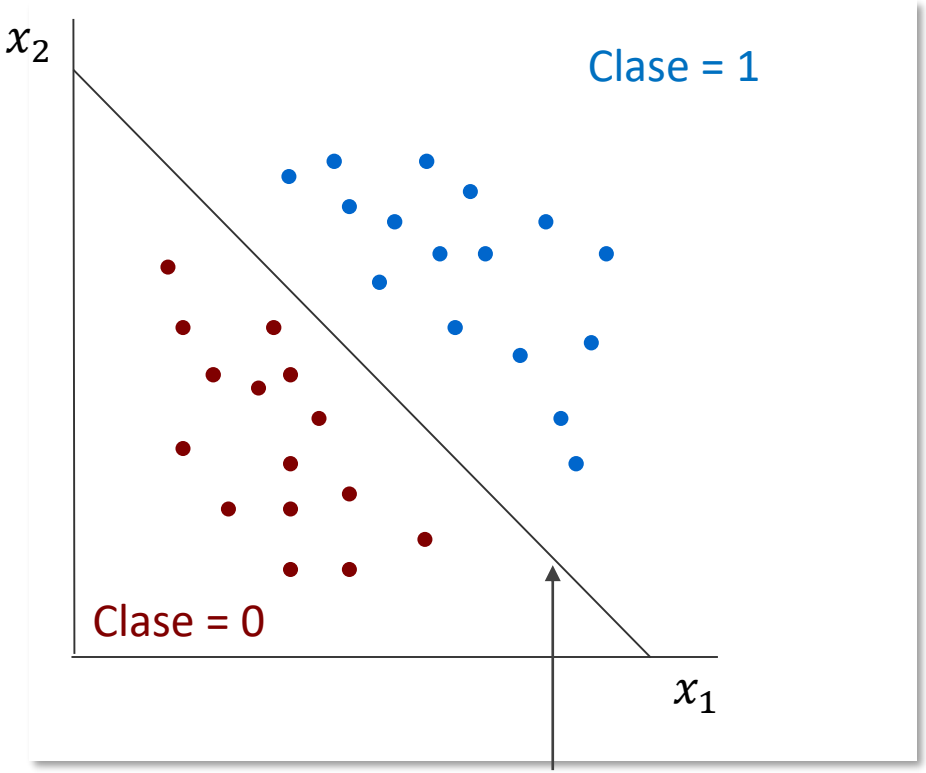

Límite de decisión lineal

$$w_0 + w_1 x_1 + w_2 x_2 = 0$$

En vez de una función umbral:

$$f_{umbral}(w_0 + w_1 x_1 + w_2 x_2)$$

$$f_{umbral}(h) = \begin{cases} clase\ "1" & si\ h \geq 0 \\ clase\ "0" & si\ h < 0 \end{cases}$$

En regresión logística se utiliza la función logística:

$$f_{logística}(w_0 + w_1 x_1 + w_2 x_2)$$

$$f_{logística}(h) = \frac{1}{1 + e^{-(h)}}$$

Rango = [0,1]

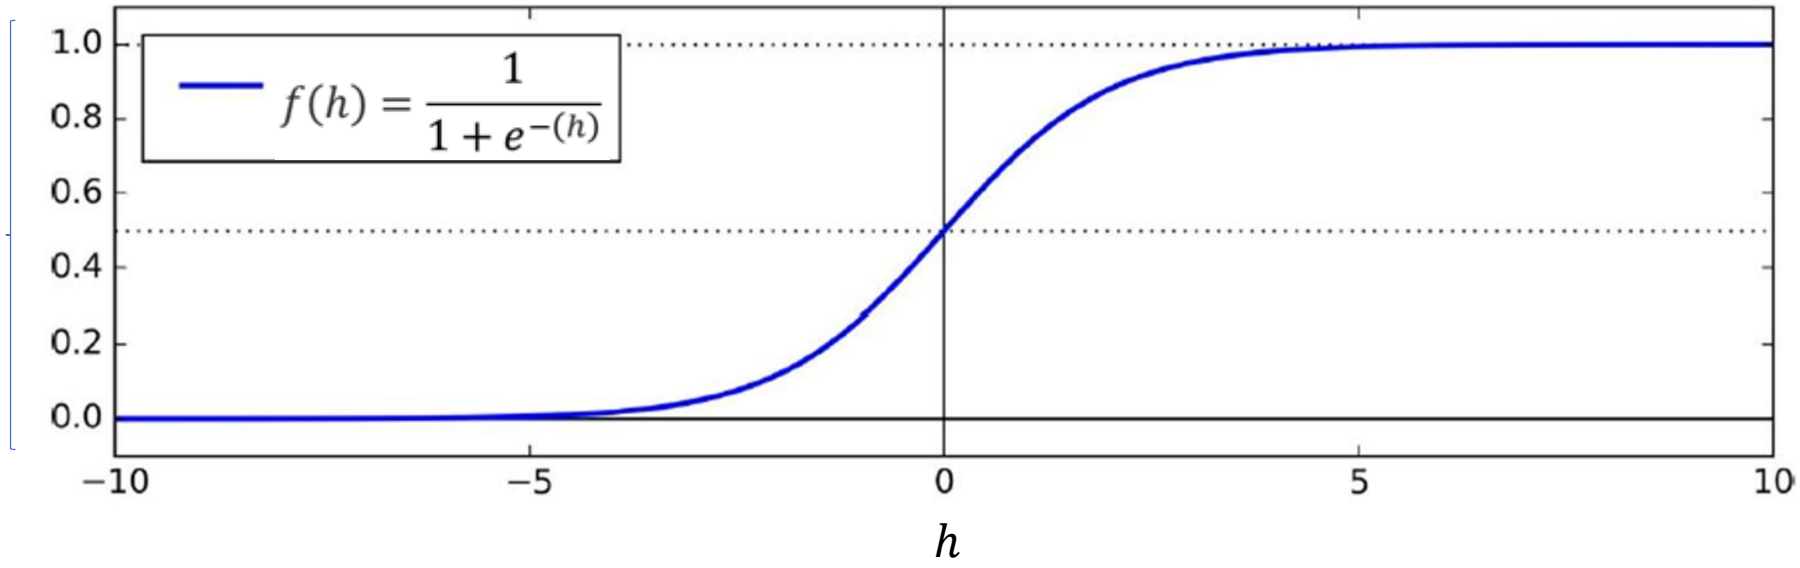

- Puede ser interpretado como la probabilidad de un evento binario.
- Representa la probabilidad de la clase dada la instancia $\boldsymbol{x}$ como:

$$P(y|\boldsymbol{x}) = \frac{1}{1+e^{-(\boldsymbol{w}\cdot\boldsymbol{x}+b)}}) = probabilidad\ estimada\ de\ y = 1, dado\ que\ se\ presenta\ \boldsymbol{x}$$

$$\begin{cases} Clase\ 1\colon\ P(y=1|\boldsymbol{x}) \\ Clase\ 0\colon\ P(y=0|\boldsymbol{x}) = 1 - P(y=1|\boldsymbol{x}) \end{cases}$$

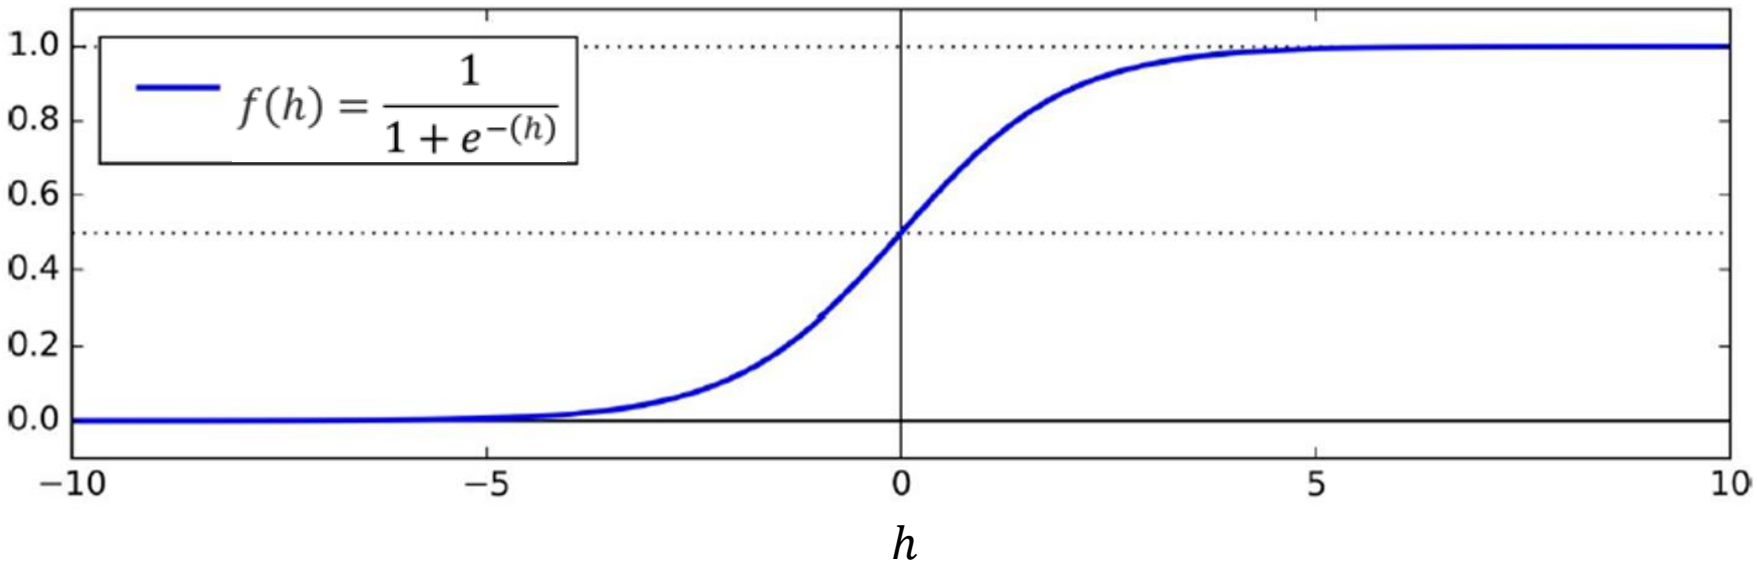

$$Límite\ de\ decisión \Rightarrow \quad \boldsymbol{w} \cdot \boldsymbol{x} = 0$$

$$\theta(\boldsymbol{w} \cdot \boldsymbol{x}) = \frac{1}{1+e^{-(\boldsymbol{w}\cdot\boldsymbol{x}+b)}} = \frac{1}{1+e^{0}} = 0.5$$

- Para clasificar se utiliza un umbral:

$$predice\ clase\ 1 \quad \text{si} \quad f_{logística}(w_0 + w_1x_1 + w_2x_2) \geq 0.5$$

$$predice\ clase\ 0 \quad \text{si} \quad f_{logística}(w_0 + w_1x_1 + w_2x_2) < 0.5$$

$$Límite\ de\ decisión = 0.017 \times peso + 0.066 \times presión\ sistólica - 9.15 = 0$$

$$P(y = 1|\boldsymbol{x}) = \frac{1}{1 + e^{-(0.017 \times peso + 0.066 \times presión\ sistólica - 9.15)}}$$

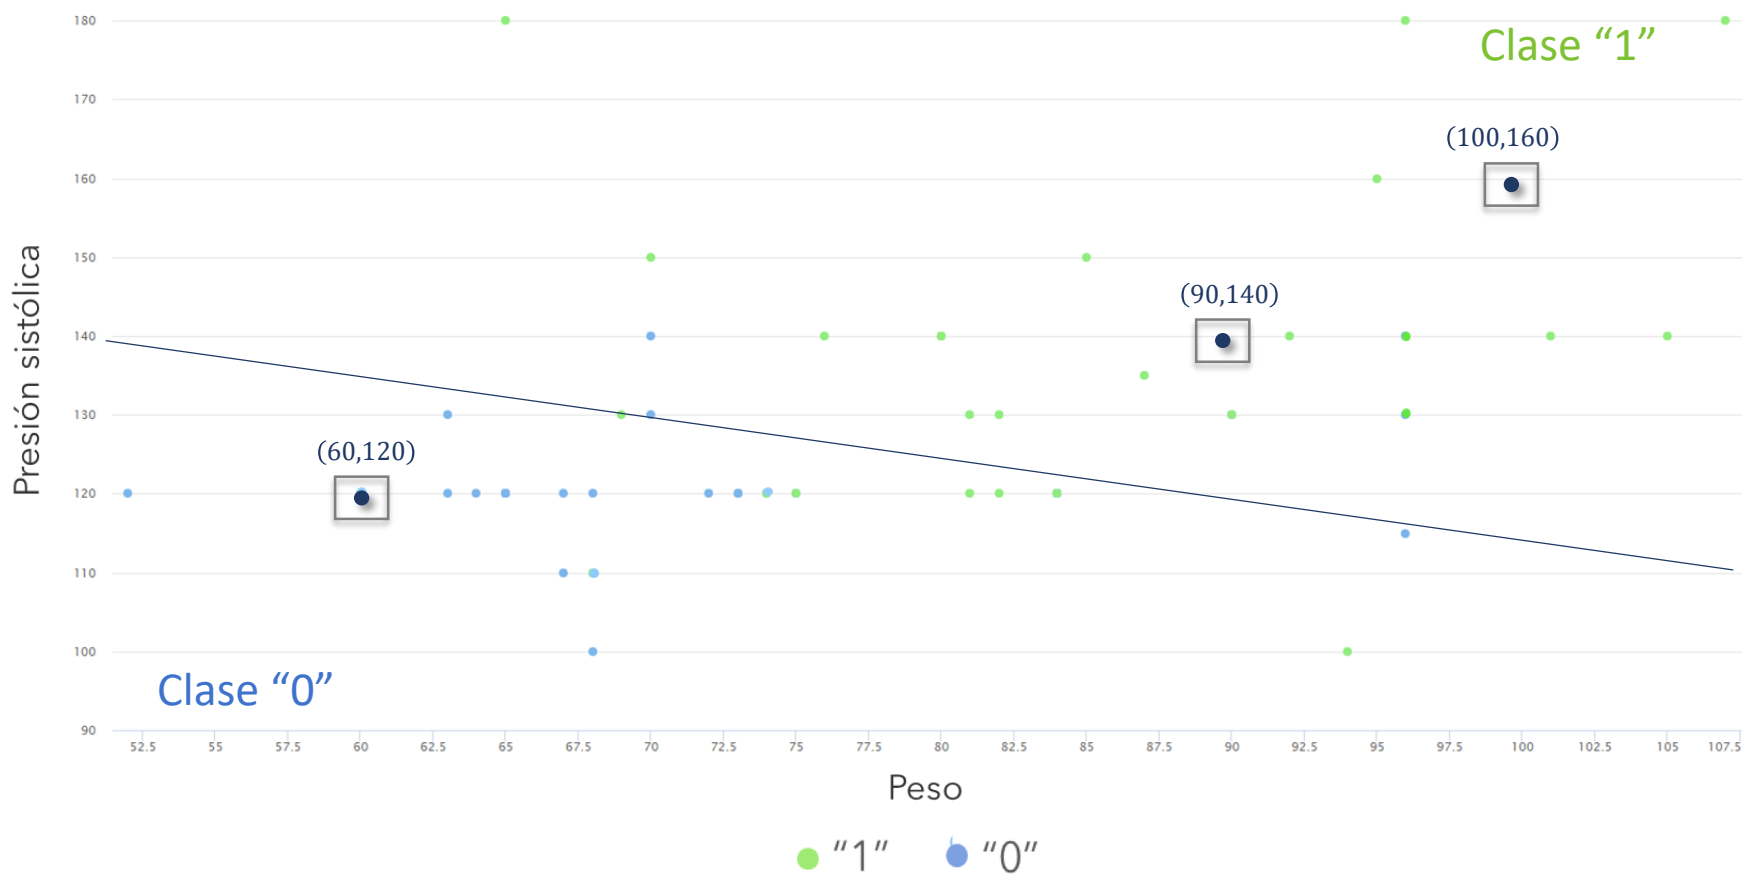

$$clase\ 1: \quad f_{logística}(h) \geq 0.5$$

$$clase\ 0: \quad f_{logística}(h) < 0.5$$

$$P(y = 1|\boldsymbol{x} = (90,140)) = \frac{1}{1 + e^{-(0.017\times 90\ +\ 0.066\times 140\ -\ 9.15)}} = 0.71 \longrightarrow \text{Clase "1"}$$

$$P(y = 1|\boldsymbol{x} = (60,120)) = \frac{1}{1 + e^{-(0.017\times 60\ +\ 0.066\times 120\ -\ 9.15)}} = 0.40 \longrightarrow \text{Clase "0"}$$

$$P(y = 1|\boldsymbol{x} = (100,160)) = \frac{1}{1 + e^{-(0.017\times 100\ +\ 0.066\times 160\ -\ 9.15)}} = 0.96 \longrightarrow \text{Clase "1"}$$

¿Por qué la diferencia en las probabilidades?

¿Cómo determinar los parámetros?

Recordar: el $costo(\hat{y}, y)$ mide la discrepancia entre lo que predice el modelo y el valor real.

$$Costo\ para\ una\ instancia = \begin{cases} -log(\hat{y}) & si\ y = 1 \\ -log(1 - \hat{y}) & si\ y = 0 \end{cases}$$

Si y = 1

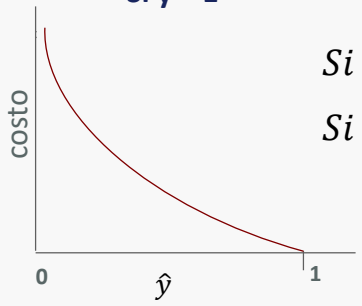

$$Si\ \hat{y} = 1 \Rightarrow\ costo = 0$$

$$Si\ \hat{y} = 0 \Rightarrow\ costo \longrightarrow \infty$$

Si y = 0

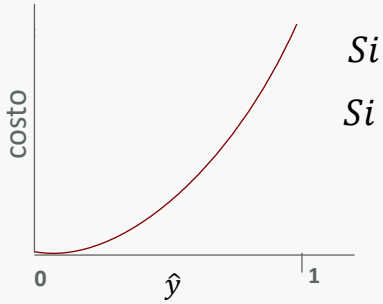

$$Si\ \hat{y} = 0 \Rightarrow\ costo = 0$$

$$Si\ \hat{y} = 1 \Rightarrow\ costo \longrightarrow \infty$$

Otra representación:

$$Costo(\hat{y}, y) = -ylog(\hat{y}) - (1 - y)log(1 - \hat{y})$$

Entonces, función de costo de la regresión logística

$$J(\boldsymbol{W}) = -\frac{1}{N}\sum_{i=1}^{N} y_i log(\hat{y}_i) + (1 - y_i)log(1 - \hat{y}_i)$$

¿Qué es un algoritmo de aprendizaje? Ejemplo: regresión logística.

Aprendizaje supervisado
Tarea de clasificación

Solo atributos numéricos

	x_1	x_2		x_d	y
Instancia 1					
Instancia 2					
Instancia N					

Parámetros del algoritmo:

C, hiperparámetro de regularización

Regresión logística

Procedimiento de Optimización

Función de costo

Algoritmo de descenso por el gradiente

Entrada = Conjunto de datos $D = \{(\boldsymbol{x}_i, y_i)\}_{i=1..N}$

Comienzo_procedimiento

Inicializar los pesos $\boldsymbol{W}(0)$ *y la constante de aprendizaje* α

Para k = 0 hasta num_iteraciones

Calcular el gradiente $g_k = \nabla J(\boldsymbol{w}(k))$

Actualizar los parámetros:

$$\boldsymbol{W}(k+1) = \boldsymbol{W}(k) - \alpha g_k$$

Fin-procedimiento

Salida = $\{\boldsymbol{W}\}$

Modelo estimado

$$\hat{y} = función_{logística}(w_0 + w_1 \times x_1 + w_2 \times x_2 + \cdots + w_d \times x_d)$$

$$parámetros\ del\ modelo = \{w_0, w_1, \ldots, w_d\}$$

$$d = No.\ de\ variables$$

Costo log (cross entropy binaria)

$$J(\boldsymbol{W}) = -\frac{1}{N}\sum_{i=1}^{N} y_i log(\hat{y}_i) + (1 - y_i) log(1 - \hat{y}_i) + C\sum_{j=1}^{d}(w_j)^2$$

Métricas para clasificación

Matriz de confusión.

En un problema de clasificación binaria		Clase predicha	
		Clase = +	Clase = -
Clase actual	Clase = +	VP	FN
	Clase = -	FP	VN

FP = error tipo I
FN = error tipo II

N = 1150		Clase predicha		
		Clase = +	Clase = -	
Clase actual	Clase = +	VP = 210	FN = 70	= 280
	Clase = -	FP = 25	VN = 845	= 870

Para poder medir el rendimiento del modelo sobre los datos se definen métricas o medidas de rendimiento, las cuales dependen de la tarea.

Métrica de rendimiento o índice (medida de evaluación)

$$exactitud\ (accuracy) = \frac{VN + VP}{No.\,total\ de\ datos} = \frac{210 + 845}{1150} = 0.92$$

$$error\ = \frac{FN + FP}{No.\,total\ de\ datos} = \frac{70 + 25}{1125} = 0.08$$

Miden el rendimiento global

- Para determinar el rendimiento sobre cada una de las clases de manera independiente pueden utilizarse otras medidas:

	N = 1150	Clase predicha		
		Clase = +	Clase = -	
Clase actual	Clase = +	VP = 210	FN = 70	= 280
	Clase = -	FP = 25	VN = 845	= 870

- <u>Sensibilidad (*recall*)</u>:

$$Recall = \frac{VP}{VP + FN} = \frac{210}{280} = 0.75$$

  - Indica cuántos ejemplos de la clase positiva fueron clasificados correctamente.
  - También conocida como True Positive Rate (TPR) o Probabilidad de detección (Probability of detection).
  - Puede calcularse por cada clase.
  - Por ejemplo, para a clase negativa:

$$specificicidad = \frac{VN}{VN + FP} = \frac{845}{870} = 0.97$$

- <u>Precisión (*precision*)</u>:

$$Precision = \frac{VP}{VP + FP} = \frac{210}{235} = 0.89$$

  - Indica, de los ejemplos clasificados como positivos, cuántos fueron clasificados correctamente.
  - Puede calcularse para cada clase.
  - Por ejemplo, para la clase negativa:

$$precisión = \frac{VN}{VN + FN} = \frac{845}{915} = 0.92$$

- F-score: *combina la precisión y el recall en un único número*

$$F_1 = \frac{2 \times recall \times precisión}{recall + precisión}$$

Recall	Precisión	F1-score
1	0	0
0	1	0
1	1	1
0.8	0.8	0.8
0.5	0.5	0.5
0.2	0.7	0.31
0.5	0.4	0.44

Tomar en cuenta…

- Existen tareas de aprendizaje para las cuales será necesaria una alta precisión, pero también hay tareas orientadas al *recall*.
- Importante: comprender las necesidades de la aplicación y seleccionar una métrica que se ajuste a los objetivos que se persiguen.

Ejemplo: dos posibles soluciones a un problema de clasificación binario.

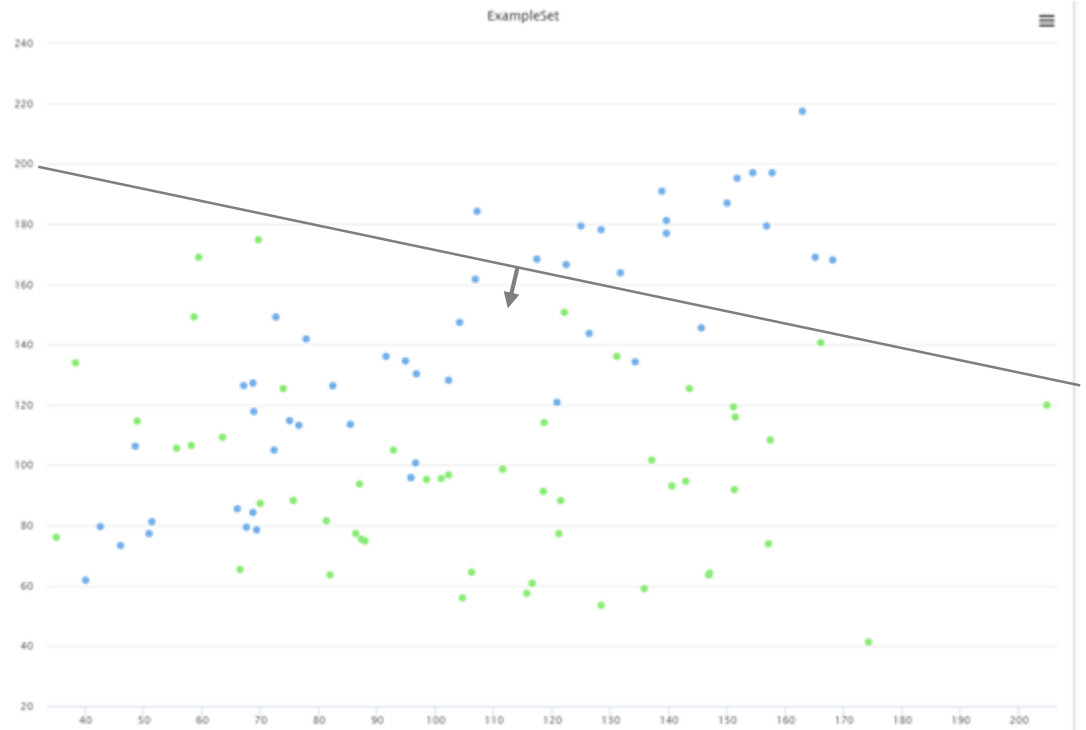

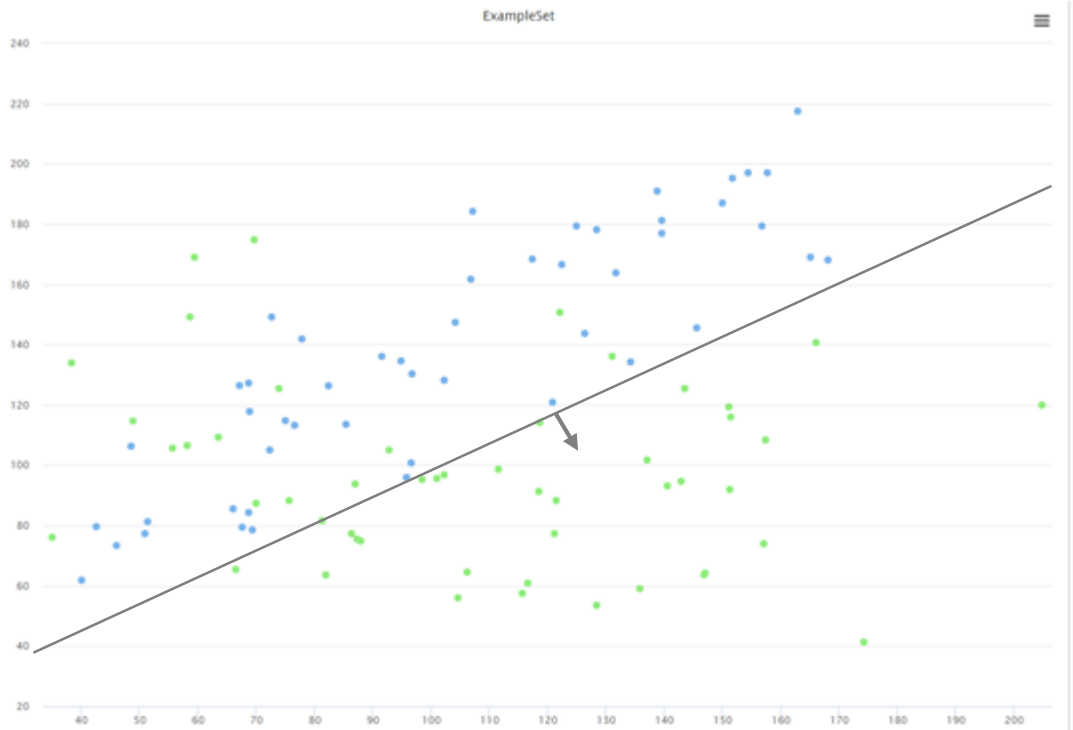

Para la clase positiva (verde):

VP =50	**FN = 0**
FP = 33	**VN = 17**

→

$$Recall = \frac{VP}{FN + VP} = 1.00$$

$$Precision = \frac{50}{FP + VP} = \frac{50}{83} = 0.60$$

VP =32	**FN = 18**
FP = 0	**VN = 50**

→

$$Recall = \frac{VP}{FN + VP} = \frac{32}{50} = 0.64$$

$$Precision = \frac{32}{32} = 1.00$$

Próxima sesión

- Capacidad de generalización, complejidad de modelos y sobreajuste.
- Dilema bias-varianza.
- Regularización. Hiperparámetros.
- Selección de modelos y técnicas de validación.