Sesión 6. Preparación de textos – Modelos probabilísticos

- Clasificación no balanceada
- Preparación de textos
- Clasificadores bayesianos: Naïve Bayes
- Modelos generativos.

Clasificación no balanceada

Imagen creada por ChatGPT

Puede presentarse por diversas razones, algunas de ellas relacionadas con:

- La naturaleza del problema, donde el desbalance es el resultado directo de las características de la población que genera los datos.
- El costo y/o dificultad en la obtención de datos de la clase de interés.
- La utilización de clasificadores binarios para resolver problemas de clasificación multi-clase, donde generalmente se adopta la estrategia de one-vs-all; es decir, se entrena un clasificador por cada clase (datos positivos) con el resto de los datos formando el conjunto de instancias de la otra clase (datos negativos), …

Problema = los algoritmos de aprendizaje tenderán a producir una solución que sólo tendrá un buen desempeño sobre las clases mayoritaria. Esto es debido a que están diseñados para inducir un modelo de clasificación basado en el error que se comete sobre todo el conjunto de entrenamiento, sin tomar en cuenta la representatividad o balance de las clases.

Algunas soluciones

- Re-balanceo del conjunto de datos con técnicas de muestreo.
- Construcción de clasificadores que tomen en cuenta el costo de los errores sobre las diferentes clases.
- Combinación (*ensemble*) de los resultados de varios clasificadores entrenados con diferentes distribuciones de datos, entre otros.

➢ Re-balanceo del conjunto de datos:

El objetivo de estos métodos es construir un nuevo conjunto de aprendizaje donde la clase minoritaria esté mejor representada. Esto puede lograrse de dos formas: mediante el sobre-muestreo (*over-sampling*) de los datos de esta clase o con el sub-muestreo (*under-sampling*) de la clase mayoritaria.

Sobre-muestreo (over-sampling)

- Algunas técnicas de generación de datos: utilizar ruido aleatorio (se generan copias agregando un poco de ruido), utilizar la distribución de los datos (se generan nuevas instancias a partir de la distribución observada de cada variable), técnica del vecino más próximo (a partir de los k vecinos más cercanos a una instancia seleccionada de manera aleatoria, se genera un nuevo dato. Ejemplo: SMOTE[1].

Sub-muestreo (under-sampling)

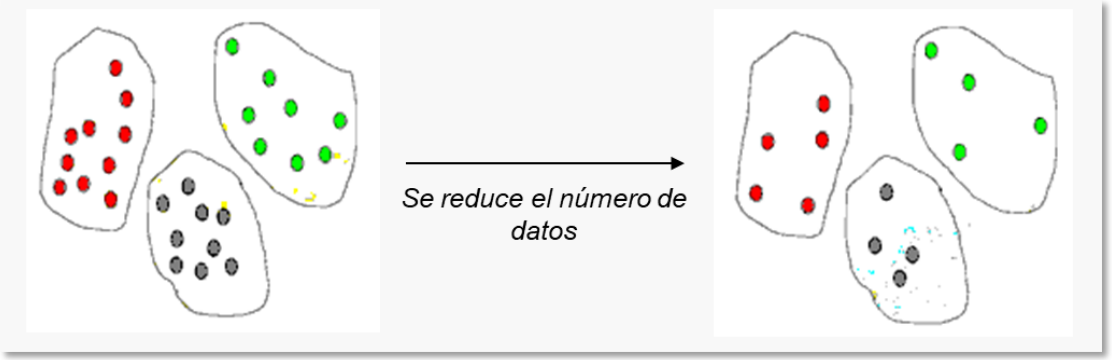

- Algunas técnicas de muestreo: muestreo aleatorio simple, muestreo aleatorio estratificado.

[1]Chawla, N., Bowyer, K., Hall, L., Kegelmeyer, W. (2002). *SMOTE: Synthetic Minority Over-sampling TEchnique*. Journal of Artificial Intelligence Research. 16:341-378

https://imbalanced-learn.org/stable/

Importante. La aumentación se realiza sobre los datos originales.

Por ejemplo, aumentación de imágenes con transformaciones.

Elgendy, M. (2020). Deep Learning for Vision Systems. Manning Publications.

Por ejemplo, aumentación de textos.

El modelo predice el riesgo de enfermedad cardiovascular utilizando datos clínicos del paciente

El modelo estima el riesgo de patología cardiovascular utilizando datos clínicos del paciente

El modelo predice riesgo de enfermedad cardiovascular con datos clínicos.

El modelo predice el posible riesgo de enfermedad cardiovascular utilizando datos clínicos detallados del paciente.

Por ejemplo, aumentación con modelos generativos.

Imágenes reales

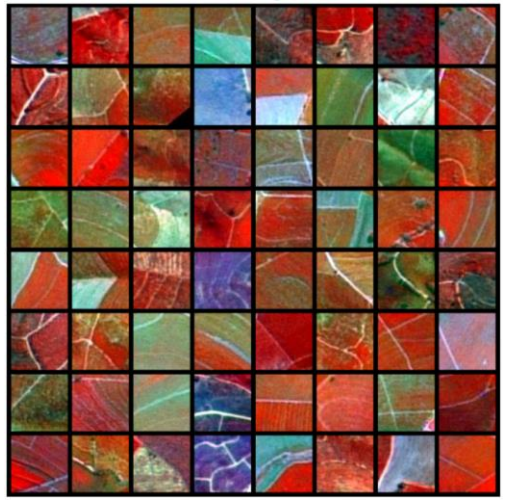

Modelo generativo

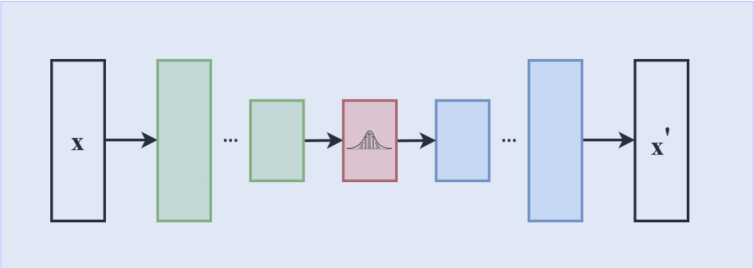

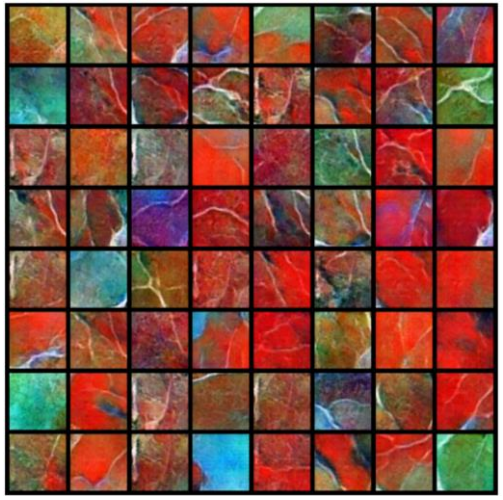

Imágenes falsas (generadas)

Nicolás Ruíz (2025). Redes generativas de adversarios aplicadas a la generación de datos de cultivos de café sobre imágenes de satélite.

➢ **Aprendizaje sensitivo al costo**:

- En algunas aplicaciones, el costo o penal asociado a los ejemplos mal clasificados puede ser diferente entre diferentes clases. Por ejemplo, en el diagnóstico de enfermedades, clasificar un paciente sano cuando en realidad está enfermo (falso negativo) tiene consecuencias muy diferentes al caso de categorizar un paciente enfermo aún cuando no lo está (falso positivo).
- Para determinar el modelo de clasificación se incorpora entonces esta información en el proceso de aprendizaje; el objetivo será entonces minimizar el costo total de los errores sobre el conjunto de datos. Esto puede lograrse ponderando el espacio de datos de acuerdo a los costos de las diferentes clases, ajustando algunos parámetros del algoritmo con base en estos errores, entre otros.
- En escenarios no balanceados, esta estrategia se puede utilizar de manera similar; en este caso, se asigna un mayor peso a los errores sobre la clase minoritaria y se desarrolla un modelo que minimice el costo total sobre el conjunto de entrenamiento.

Ejemplo: SVM basada en costo.

Para el caso de las SVM, la información de los costos en los dos tipos de errores puede ser introducida en la formulación del problema de aprendizaje (problema de optimización), utilizando dos parámetros de regularización de la siguiente forma[1]:

$$\begin{cases} minimizar: \ \frac{1}{2}\|\boldsymbol{w}\|^2 + C^+ \sum_{i|y_i=+1} \xi_i + C^- \sum_{i|y_i=-1} \xi_i \\ sujeto\ a: \ y_i\,(\boldsymbol{w}\,.\boldsymbol{x} + b) \geq 1 - \xi_i; \ \xi_i \geq 0; \ i = 1\,..\,N \end{cases}$$

Donde: $C^+ = \frac{C \times N}{2N_{pos}}, \ C^- = \frac{C \times N}{2N_{neg}}$

$N = número\ de\ datos$

$N_{pos} = número\ de\ datos\ positivos$

$N_{neg} = número\ de\ datos\ negativos$

[1]Veropoulos, K., Campbell, C., Cristianini, N. (1999). *Controlling the sensitivity of support vector machines*. Proc. Int. Joint Conf. on Artificial Intelligence. 55–60.

- **Métodos de *ensembles***:
  - Los métodos *ensembles* consisten de un conjunto de modelos cuyas decisiones son combinadas para proporcionar una clasificación a un nuevo dato.
  - En el campo del aprendizaje no balanceado, los *ensembles* se utilizan principalmente para combinar los resultados de clasificadores entrenados con datos con diferentes distribuciones, producto de aplicar submuestreo y/o sobre muestreo

Importante: utilizar métricas adecuadas.

- ❑ Recall (sensibilidad)
- ❑ Precisión
- ❑ F1-score
- ❑ AUC-ROC
- ❑ Balanced Accuracy

Preparación de textos

¿Cómo representar las palabras y los documentos?

- ☞ Representación de documentos como un vector numérico.
- ☞ Representación de palabras como un vector numérico. A partir de esta representación, generar el vector para el documento.

Ejemplo:

- D1: “ Las cosas podían haber sucedido de cualquier manera y, sin embargo, sucedieron así” (El camino, Miguel Delibes)
- D2: “Muchos años después, frente al pelotón de fusilamiento, el Coronel Aureliano Buendía, había de recordar aquella tarde remota en que su padre lo llevó a conocer el hielo” (Cien años de soledad, Gabriel García Márquez).
- D3: “Constituía un placer especial ver las cosas consumidas, ver los objetos ennegrecidos y cambiados” (Fahrehneit 451, Ray Bradbury).
- D4: “Al día siguiente no murió nadie” (Las intermitencias de la muerte, José Saramago).

a) Modelo Bag-of-Word (BOW)

b) Modelo One-Hot

c) Modelos de vectores semánticos (Word embedding),…

a) Modelo de bolsa de palabras (Bag-of-Word, BOW) para representación de documentos

"En un lugar de la mancha, de cuyo nombre no quiero acordarme…"

También conocido como modelo de espacio de vectores

Para los documentos ejemplos:

	Al	años	aquella	Aureliano	cosas	conocer	constituía	consumidas	cualquier	de	después	…	embargo	ennegrecido	especial	frente	haber	había	hielo	…	lo	llevó	manera	murió	nadie	no	objetos	padre	placer	tarde	recordar	remota	…	sucedieron	un	ver	y
D1					1				1	1			1				1						1														1
D2	1	1		1		1				1	1					1		1	1		1	1						1		1	1						
D3					1		1	1							1														1						1	1	
D4	1																							1	1	1											

Se utilizan diferentes esquemas de ponderación (pesado de términos), por ejemplo, binario, frecuencia absoluta, tf-idf,….

Limpieza y tokenización

- Los tokens identifican partes en las cuales se puede dividir un texto.
- Pueden ser de diferente granularidad, dependiendo de la aplicación (párrafos, frases, n-gramas, palabras, …)
- Es importante determinar los delimitadores que serán utilizados para la identificación de los tokens (espacio en blanco, tab, …) y las excepciones.

Eliminación de palabras no informativas

- Las palabras que son más frecuentes a lo largo de la colección de documentos no son buenas discriminantes.
- Identificar y eliminar estas palabras (artículos, pronombres, conjunciones, preposiciones, …).
- Para esta tarea se utiliza un diccionario de palabras frecuentes (importante: en el diccionario también pueden incluirse otras palabras que, dependiendo del contexto de la aplicación, se consideran que no son discriminantes)
- Este paso es dependiente del idioma.

Lematización/ stemming

- Premisa: formas morfológicas de una misma palabra tienen el mismo significado.
- El efecto de la lematización/stemming es una reducción de la dimensionalidad.
- Algunos tipos: a) *Flexionales* (eliminan las flexiones morfológicas de número, género, tiempos verbales,…). b) *A la raíz* (eliminan todas las derivaciones, sufijos y prefijos, asociados a una palabra).
- Dependiendo de la aplicación, este paso podría no ser necesario.
- El algoritmo también es dependiente del idioma.
- Algunos algoritmos: para stemming (Porter Stemmer, Snowball Stemmer, ….), para lematizar (WordNet, Stanza, …)

Generación de vectores

- El conjunto de palabras resultante = atributos para construir una matriz de datos (en la cual cada fila representa un documento).
- El modelo requiere ahora construir el vector de características para cada documento del corpus.
- Algunos modelos: binario, por frecuencias, tf-idf,….

	t_1	…	t_j	…	t_K
d_1	$w_{1\,1}$	…	w_{1j}	…	w_{1K}
…	…	…	…	…	…
d_i	w_{i1}	…	w_{ij}	…	w_{iK}
…	…	…	…	…	…
d_N	$w_{N\,1}$	…	w_{Nj}	…	w_{NK}

N = Número de documentos en el corpus

K = número de términos

Modelo binario:

$w_{ij} = 1$ *si el término j se encuentra en el documento i*

$w_{ij} = 0$ *si el término j no se encuentra en el documento i*

Modelo de frecuencias absolutas:

$w_{ij} = tf_{ij} =$ *Número de veces que el término j aparece en el documento i*

Modelo de frecuencias relativas:

$$w_{ij} = \frac{tf_{ij}}{d_i} = \frac{\text{Número de veces que el término } j \text{ aparece en el documento } i}{\text{Número de términos en el documento } i}$$

Modelo tf-idf:

$$w_{ij} = tf_{ij} \times idf_j \qquad \text{donde } idf_j = \log\left(\frac{N}{df_j}\right) = \text{frecuencia inversa de documento}$$

$df_j =$ *Número de documentos que contienen al término j*

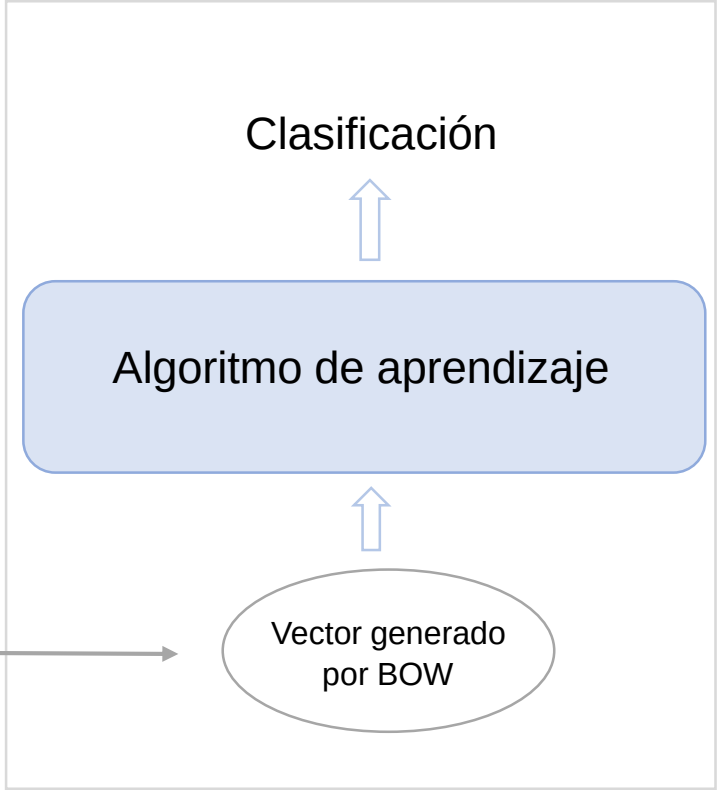

b) Codificación one-hot, para representación de palabras

- Para un diccionario de n palabras => vector n-dimensional, en el cual a cada palabra le corresponde un índice (posición).
- Cada palabra se presenta entonces con un vector de longitud n, con un valor de 1 en la posición que le corresponde y 0 en el resto.
- No hay información de contexto (relaciones entre palabras).

Para los documentos ejemplos

	Al	años	aquella	Aureliano	cosas	conocer	constituía	consumidas	cualquier	de	después	⋮	embargo	ennegrecido	especial	frente	haber	había	hielo	⋮	lo	llevó	manera	murió	nadie	no	objetos	padre	placer	tarde	recordar	remota	⋮	sucedieron	un	ver	y
Al	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
años	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
aquella	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
Aureliano	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
⋮																																					
conocer	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
constituía	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
⋮																																					
embargo	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
ennegrecido	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
⋮																																					
un	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0
ver	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0
y	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1

c) Word embeddings

Incrustación (*embedding*): representación numérica densa (vector de números reales) que captura características relevantes de datos complejos como texto, imágenes, videos, entre otros.

- **Incrustación de palabras** (*word embedding*) = representación vectorial semántica de palabras.
- Toma en cuenta el contexto de las palabras y es capaz de tratar con diferentes aspectos del significado de una palabra (con base en el contexto).

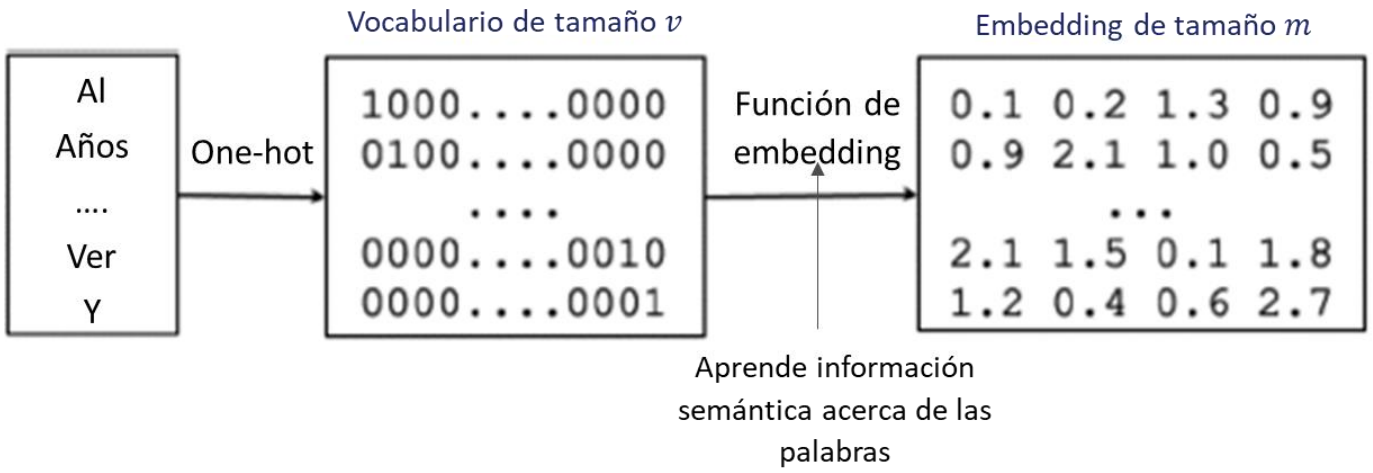

Representa una palabra por un vector en un espacio $m-dimensional$ (espacio semántico).

Pueden ser:

- Estáticos. Independientes del contexto. Es decir, cada palabra tendrá una única representación vectorial, independientemente del contexto en el que aparece. Ejemplo: Word2vec, Glove, …
- Dinámicos. Dependientes del contexto o contextuales, toma en cuenta la secuencia de las palabras. Es decir, la representación de una palabra dependerá del contexto en el que aparece. Ejemplo: Bert, …

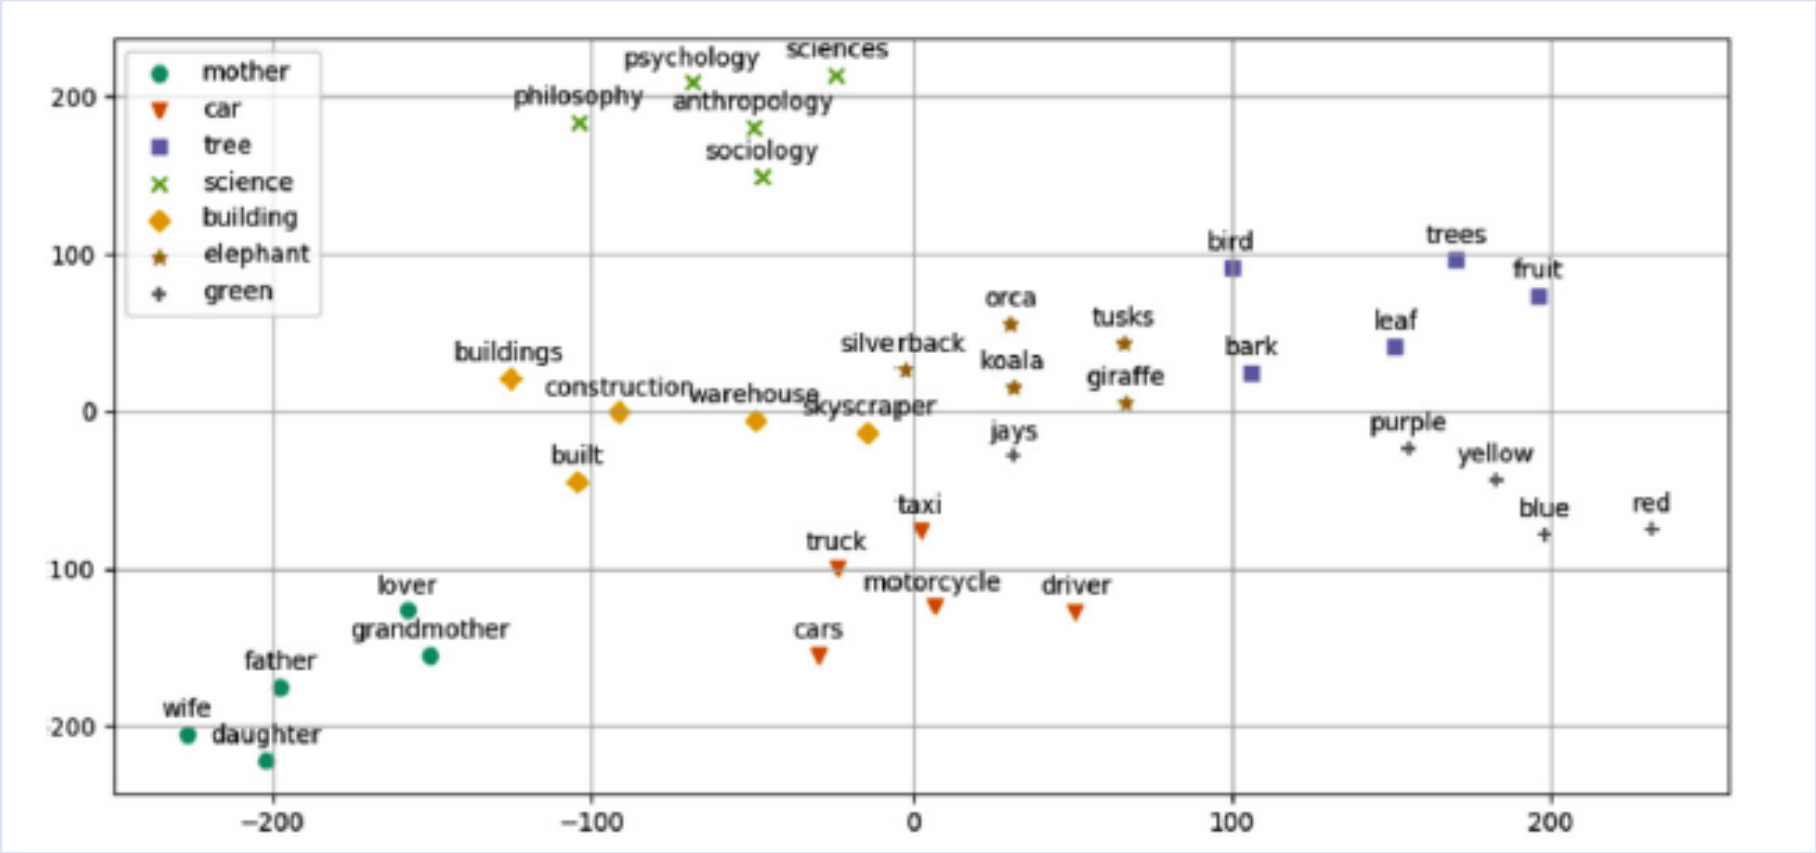

El *embedding* define una palabra tomando en cuenta qué otras palabras ocurren en su entorno.

Visualización de *embeddings* con t-SNE

Ivan Vasilev (2023). Python Deep Learning. Understand how deep neural networks work and apply them to real-world tasks. Packt Publishing.

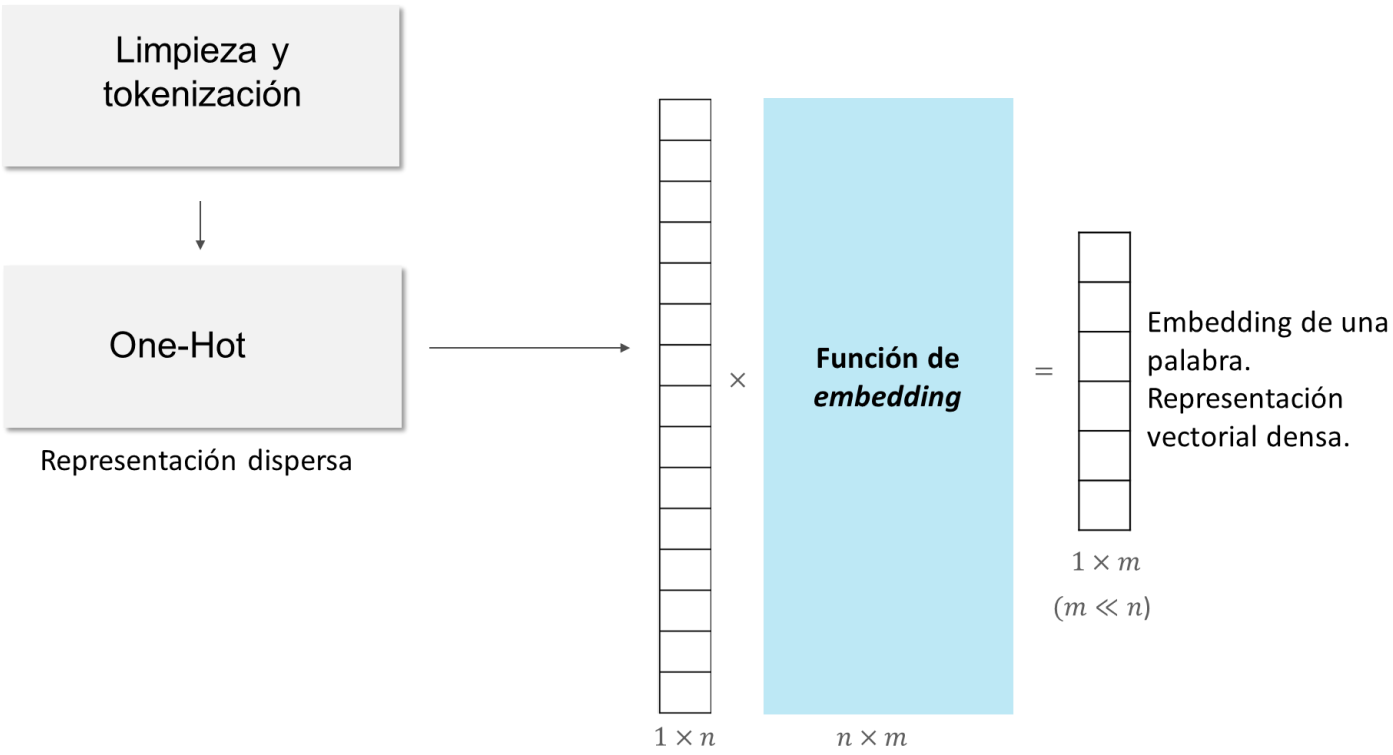

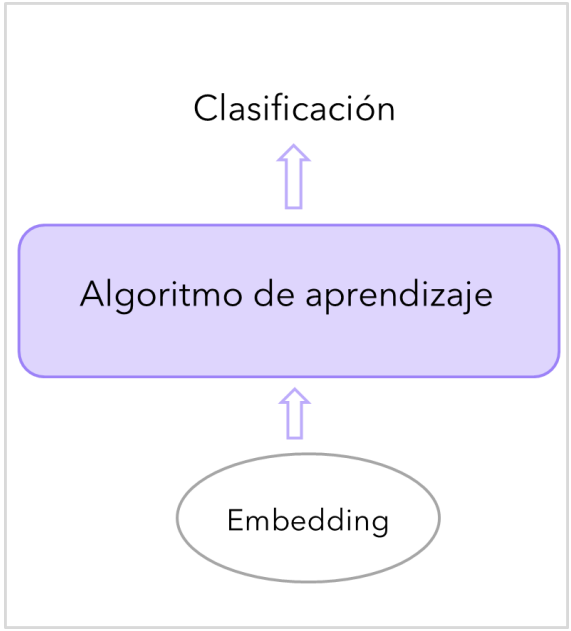

También:

Todavía recuerdo aquel amanecer en que mi padre me llevó por primera vez a visitar el Cementerio de los Libros Olvidados. Desgranaban los primeros días del verano de 1945 y caminábamos por las calles de una Barcelona atrapada bajo cielos de ceniza y un sol de vapor que se derramaba sobre la Rambla de Santa Mónica en una guirnalda de cobre líquido…

Modelo embedding de sentencias

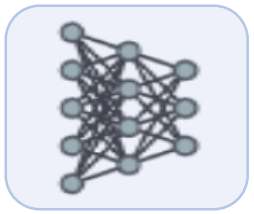

1.12	0.21	0.98	2.04

- Importancia del tokenizador:

"Todavía recuerdo aquel amanecer en que mi padre me llevó por primera vez a visitar el Cementerio de los Libros Olvidados. Desgranaban los primeros días del verano de 1945 y caminábamos por las calles de una Barcelona atrapada bajo cielos de ceniza y un sol de vapor que se derramaba sobre la Rambla de Santa Mónica en una guirnalda de cobre líquido…" (La sombra del viento, Carlos Ruíz Zafón).

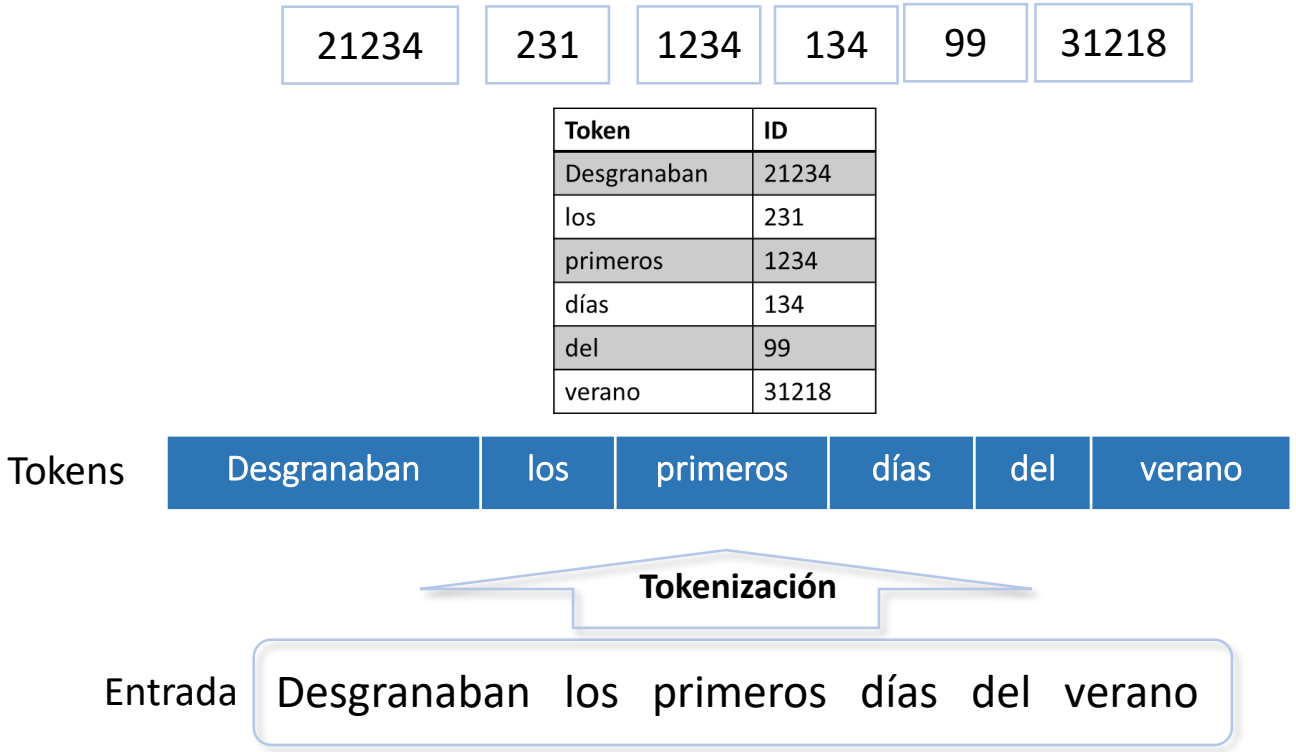

Token	ID
Desgranaban	21234
los	231
primeros	1234
días	134
del	99
verano	31218

Ejemplo de tokenizadores:

Texto: Desgranaban los primeros días del verano

| | | |

Ejemplo:

GPT-4o & GPT-4o mini | GPT-3.5 & GPT-4 | GPT-3 (Legacy)

"Todavía recuerdo aquel amanecer en que mi padre me llevó por primera vez a visitar el Cementerio de los Libros Olvidados. Desgranaban los primeros días del verano de 1945 y caminábamos por las calles de una Barcelona atrapada bajo cielos de ceniza y un sol de vapor que se derramaba sobre la Rambla de Santa Mónica en una guirnalda de cobre líquido..."

Clear | Show example

Tokens 87 **Characters** 352

"Todavía recuerdo aquel amanecer en que mi padre me llevó por primera vez a visitar el Cementerio de los Libros Olvidados. Desgranaban los primeros días del verano de 1945 y caminábamos por las calles de una Barcelona atrapada bajo cielos de ceniza y un sol de vapor que se derramaba sobre la Rambla de Santa Mónica en una guirnalda de cobre líquido..."

Text | Token IDs

[1100, 150407, 50597, 102519, 65229, 49610, 32559, 469, 661, 3997, 45398, 668, 94332, 1382, 19480, 7094, 261, 59854, 650, 78120, 139114, 334, 1403, 14246, 2199, 12431, 1429, 2426, 13, 3196, 85404, 14236, 1403, 52774, 19067, 1083, 63505, 334, 220, 8034, 20, 342, 86785, 121896, 1382, 1996, 82028, 334, 1969, 23360, 192991, 1194, 29462, 50853, 365, 334, 34941, 7885, 342, 537, 1887, 334, 46102, 661, 458, 42219, 313, 4216, 4844, 557, 145843, 1675, 334, 15430, 391, 57090, 469, 1969, 1704, 380, 19757, 2529, 334, 85190, 94998, 49068, 220]

Text | Token IDs

GPT-4o & GPT-4o mini | GPT-3.5 & GPT-4 | GPT-3 (Legacy)

"Todavía recuerdo aquel amanecer en que mi padre me llevó por primera vez a visitar el Cementerio de los Libros Olvidados. Desgranaban los primeros días del verano de 1945 y caminábamos por las calles de una Barcelona atrapada bajo cielos de ceniza y un sol de vapor que se derramaba sobre la Rambla de Santa Mónica en una guirnalda de cobre líquido..."

Clear | Show example

Tokens 105 **Characters** 352

"Todavía recuerdo aquel amanecer en que mi padre me llevó por primera vez a visitar el Cementerio de los Libros Olvidados. Desgranaban los primeros días del verano de 1945 y caminábamos por las calles de una Barcelona atrapada bajo cielos de ceniza y un sol de vapor que se derramaba sobre la Rambla de Santa Mónica en una guirnalda de cobre líquido..."

Text | Token IDs

[2118, 51, 347, 402, 7583, 1421, 53570, 79376, 1097, 276, 94218, 665, 1744, 9686, 62120, 757, 54295, 1832, 4247, 44769, 21205, 264, 4034, 277, 658, 62432, 261, 822, 409, 2537, 5806, 3714, 12225, 1325, 5670, 13, 3959, 68163, 39265, 2537, 27909, 437, 46180, 1624, 2807, 5770, 409, 220, 6393, 20, 379, 6730, 258, 59660, 10808, 4247, 5252, 1652, 645, 409, 5203, 28035, 30670, 391, 2649, 63512, 12088, 301, 437, 409, 66031, 17528, 379, 653, 2092, 409, 38752, 1744, 513, 294, 618, 309, 12273, 15482, 1208, 15504, 65826, 409, 16376, 386, 93063, 665, 5203, 1709, 404, 43078, 3315, 409, 34928, 265, 32850, 447, 5362, 51279, 220]

Text | Token IDs

Tokenizer (https://platform.openai.com/tokenizer)

Ejemplo. Predicción del sentimiento de mercado para crudos pivotes con base en el análisis de noticias.

Problema. El desarrollo de fórmulas para valoración de crudos es de gran importancia en la industria internacional del petróleo ya que estas permiten optimizar los ingresos por exportación de materia prima no renovable. Un aspecto a destacar de este proceso es su complejidad, debido a la necesidad de análisis y ponderación (generalmente expuesto a críticas y revisiones de expertos) de una gran cantidad de aspectos técnicos, económicos y políticos en un contexto internacional, y a la poca información pertinente.

En algunos países, las fórmulas de precios para los crudos pivotes consideran un factor de ajuste K, de estimación mensual, el cual refleja el comportamiento coyuntural del mercado y la estrategia de colocación de los crudos de exportación. La estimación del factor K consiste en realizar un ajuste a las fórmulas de precios para los crudos pivote en los mercados de interés, a fin de evitar posibles distorsiones que puedan generarse debido a la disparidad de condiciones entre los países consumidores, productores y exportadores de crudos. La respectiva estimación involucra un análisis global del mercado petrolero y la ponderación de factores cualitativos relevantes.

Pregunta: ¿Cómo determinar mensualmente el sentimiento del mercado para ajustar las fórmulas de precio de los crudos pivotes?

Propuesta de solución: Realizar un análisis de las noticias económicas relacionadas con el tema mediante modelos de machine learning y procesamiento de lenguaje natural ¿Por qué? Las noticias de la web pueden ser usadas para rastrear con precisión no solo fenómenos sociales sino también las tendencias financieras.

- **Recolección de los datos:**

El corpus estuvo constituido por 2217 documentos de noticias que podían, según los expertos, influir en el sentimiento del mercado petrolero (16 meses).

Noticia	Crudo boscán
Se espera que el mantenimiento de crudo REFQ4 sea relativamente ligero en el futuro y se mantendrá así durante los primeros meses del primer trimestre de 2016. Dada la reciente recuperación de margen esperamos que CEGM continúe aumentando las carreras hasta muy por encima del 90%.	B
Se espera que el crudo de WTS Midland regrese a una prima contra WTI Cushing una vez que las operaciones de reanudación del oleoducto y mantenimiento local disminuyan. Esto aumentará los precios.	N
Una abundancia de fondos de torre de vacío baratos (VTBs) en el USG agregó presión a la baja a los mercados de asfalto en masa. La gran cantidad compradores que buscan recibir entregas finales, para terminar la temporada de pavimentación estaban retrasando las compras con la esperanza de pagar precios más bajos la próxima semana. Barcazas del Golfo de Estados Unidos se escucharon vendiendo tan bajo como $210-220/st en la parte posterior de la demanda débil una disminución de $20/st de la semana pasada. Una importante refinería de la costa del Golfo anunció que se estaría manteniendo en unidades no reveladas lo que podría aumentar el exceso de VTBs en la región y establecer el escenario para más debilitamiento a corto plazo en la mayoría de los mercados.	B

- **Preparación de los textos:**

☞ Traducción de algunas noticias desde el idioma inglés al idioma español.

☞ Eliminación de caracteres no imprimibles, acentos, números, símbolos, signos de puntuación.

☞ Separación de noticias en tokens (*tokenizacion*), utilizando bi-gramas y tri-gramas. Se consideró solo analizar aquellos tokens que aparecieran en al menos el 1% del conjunto de noticias y en a lo sumo el 90% de estas.

☞ Eliminación de palabras vacías (*stopwords*), parte de la lista fue suministrada por los expertos.

☞ Conversión a minúsculas.

☞ Ejecución de expresiones regulares para homologar expresiones escritas de diferentes maneras, como por ejemplo:

- betun ! bitumen
- grado liviano ! crudo liviano
- usa ! eeuu

☞ Construcción de la matriz de términos con ponderación diferentes ponderaciones (por ejemplo, tf-Idf).

☞ **Reducción de la dimensionalidad**: por selección de variables aplicando métodos filtros y por frecuencias.

Extracto de la matriz resultante:

Row No.	a_mercado	a_categoria	abiertas	abril	aceleramiento	acido	actividad	actividad.construccion	actividad.pavimentacion	acuerdo	.....	vlcc	waf	wcs	a_boscan
1	CEGM	Refinación	0	0	0	0	0	0	0	0		0	0	0	B
2	CEGM	Refinación	0	0	0	0	0	0	0	0.188		0	0	0	N
3	CEGM	Crudo	0	0	0	0	0	0	0	0		0	0	0	N
4	CEGM	Crudo	0	0	0	0	0	0	0	0		0	0	0	N
5	CEGM	Crudo	0	0	0	0	0	0	0	0		0	0	0	N
6	CEGM	Crudo	0	0	0	0	0	0	0	0		0	0	0	N
7	CEGM	Crudo	0	0	0	0	0	0	0	0		0	0	0	N
8	CEGM	Crudo	0	0	0	0.176	0	0	0	0		0	0	0.204	S
9	CEGM	Crudo	0	0	0	0	0	0	0	0		0	0	0	B
10	CEGM	Crudo	0	0	0	0	0	0	0	0		0	0	0	B
11	CEGM	Estacionalidad	0	0	0	0	0	0	0	0		0	0	0	B
12	NOE	Crudo	0	0	0	0	0	0	0	0		0	0	0	N
13	NOE	Crudo	0	0	0	0	0	0	0	0		0	0	0	N
14	NOE	Crudo	0	0	0	0	0	0	0	0		0	0	0	N
15	NOE	Crudo	0	0	0	0.144	0	0	0	0		0	0	0	N
16	NOE	Crudo	0	0	0	0	0	0	0	0		0	0	0	N
17	NOE	Crudo	0	0	0	0	0.050	0	0.074	0.051		0	0	0	B
18	Asia	Refinación	0	0	0	0	0	0	0	0		0	0	0	N
19	Asia	Refinación	0	0	0	0	0	0	0	0		0	0	0	N
20	Asia	Refinación	0	0	0	0.237	0	0	0	0		0.257	0	0	N
21	Asia	Crudo	0.486	0	0	0	0	0	0	0		0	0	0	N
22	Asia	Crudo	0	0	0	0	0	0	0	0		0	0	0	N
23	Asia	Crudo	0	0	0	0	0	0	0	0		0	0	0	N
24	Asia	Crudo	0	0	0	0.176	0	0	0	0		0	0	0	N
25	Asia	Crudo	0	0	0	0	0	0	0	0		0	0	0	N

⋮

Pipeline de preparación textos

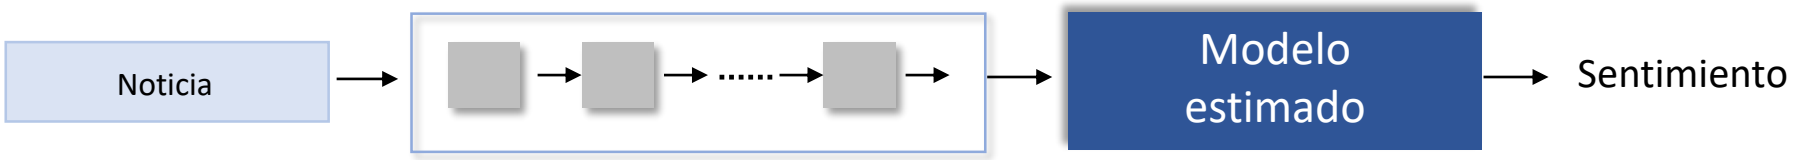

Se recomienda mantener el valor del factor k para el crudo Boscán

NOTICIAS CLASIFICADAS

Show 5 entries

Search:

MERCADO	CATEGORÍA	NOTICIA	Sentimiento	Prob_Baja	Prob_Neutro	Prob_Alza
CEGM	Refinación	Se espera que el mantenimiento de crudo REFQ4 sea relativamente ligero en el futuro y se mantendrá así durante los primeros meses del primer trimestre de 2016. Dada la reciente recuperación de margen esperamos que CEGM continúe aumentando las carreras hasta muy por encima del 90%	Baja	99.71	0.29	0.00
CEGM	Refinación	Los grados de Permian se mantuvieron con descuentos contra el WTI de Midland debido principalmente al intensivo mantenimiento de las refinerías en la zona central de EEUU. A pesar de las caídas en los números de taladros en los EEUU la producción sigue creciendo de acuerdo con los datos del gobierno de dicho país debido a que las áreas más productivas se han convertido en el foco de las operaciones. El número de taladros en Permian ha caído en cada una de las seis últimas semanas.	Neutro	11.14	88.85	0.01
CEGM	Crudo	Se espera que el crudo de WTS Midland regrese a una prima contra WTI Cushing una vez que las operaciones de reanudación del oleoducto y mantenimiento local disminuyan. Esto aumentará los precios de la fórmula venezolana.	Neutro	0.00	99.69	0.31
CEGM	Crudo	La comercialización de crudo LLS para diciembre comenzó la sesión con una prima de 85 centavos por barril sobre el WTI. El Mars para diciembre se comercializó con descuentos de $4/barril a $3.75/barril fortaleciéndose junto al LLS después de haber sido comercializado un día antes a -4.20/-4.10 $/b. Ambos crudos el LLS y el Mars estuvieron lo más fuertes que han estado desde el 27 de octubre durante la segunda sesión de los cargamentos de las primeras ventanas de diciembre.	Neutro	0.22	99.78	0.00
CEGM	Crudo	La prima del crudo de Alaska Slope Norte (ANS) con respecto al WTI CMA Nymex de diciembre se fortaleció en unos 13 centavos por barril después del fin de semana para reflejar el descuento de $2.03/barril contra el CMA ICE Brent de Diciembre establecido la última vez que fue comercializado este crudo para entrega en diciembre en la Costa Oeste de los EEUU el 27 de Octubre.	Neutro	0.21	99.79	0.00

Reducción de la dimensionalidad y visualización

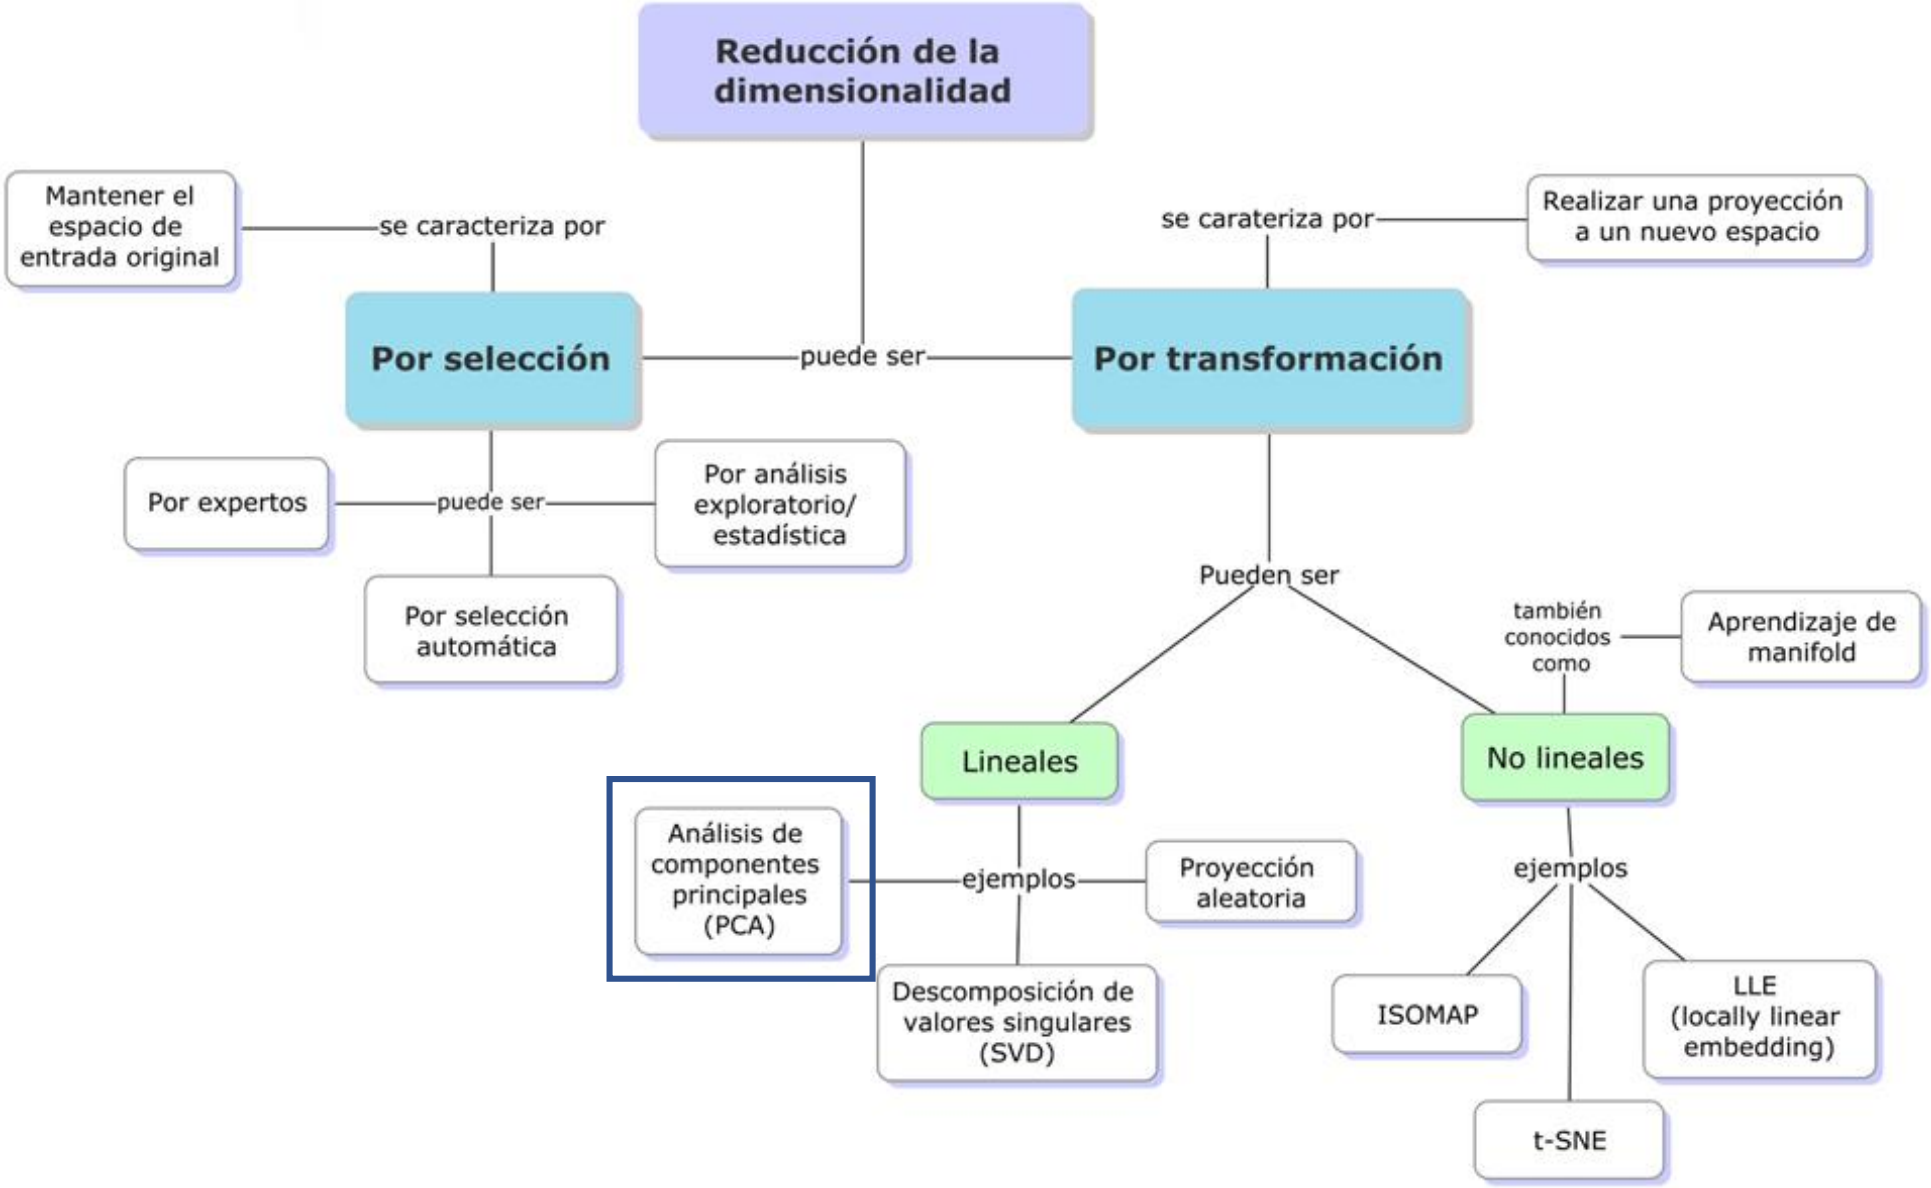

Ejemplo: conjunto de imágenes MNIST

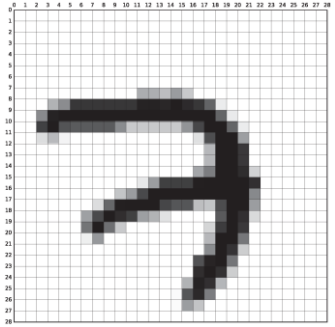

Vector numérico de 784 elementos

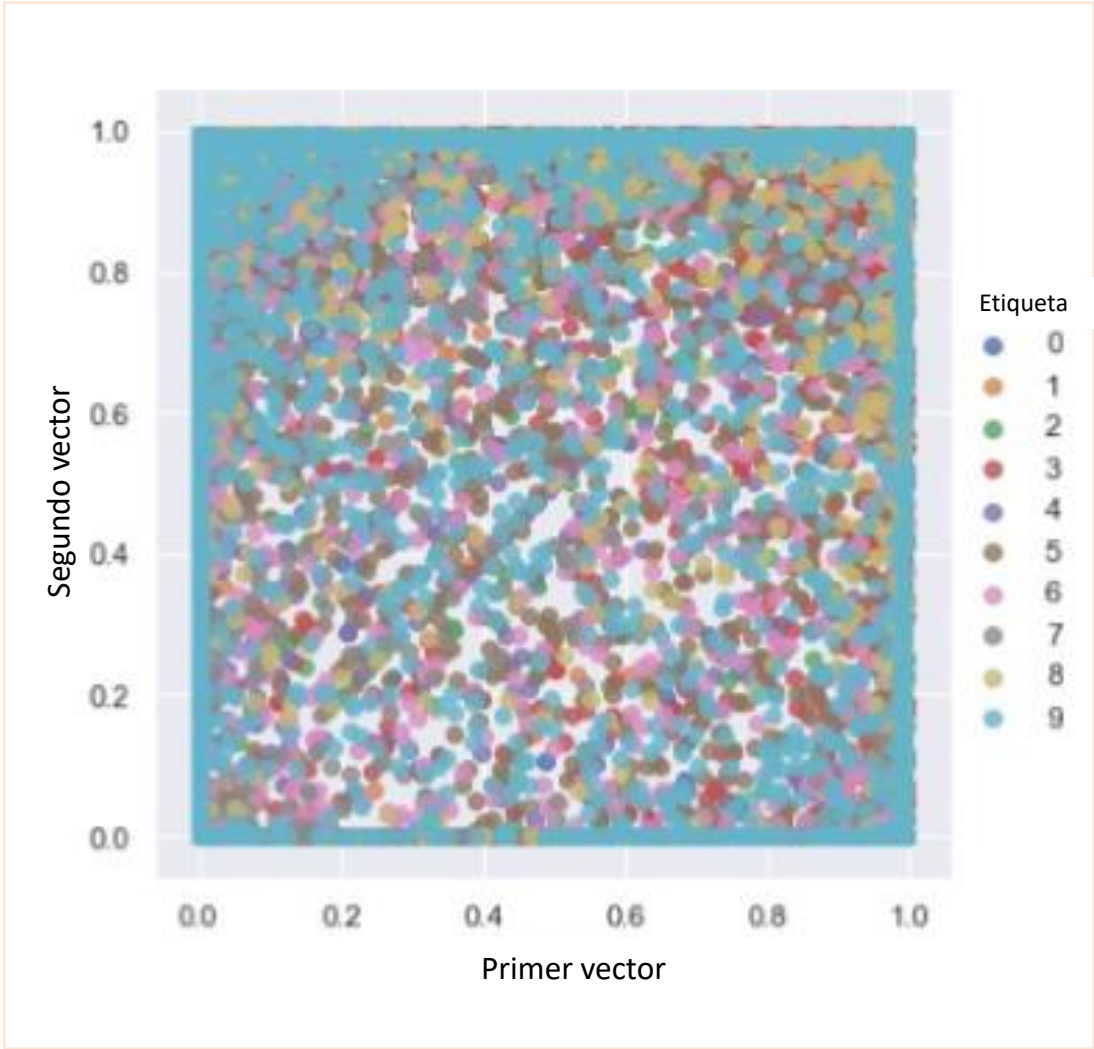

Patel, A. (2019). Hands-On Unsupervised Learning Using Python. O'Reilly.

PCA

Encuentra una combinación lineal de características que mejor explica la varianza de los datos.

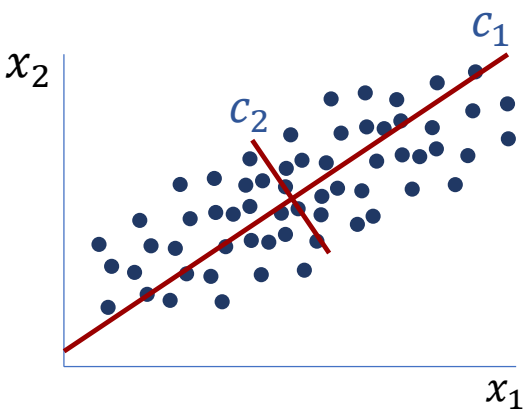

Al aplicar PCA al conjunto de datos MNIST:

Con 154 componentes se explica el 95% de la variabilidad en los datos

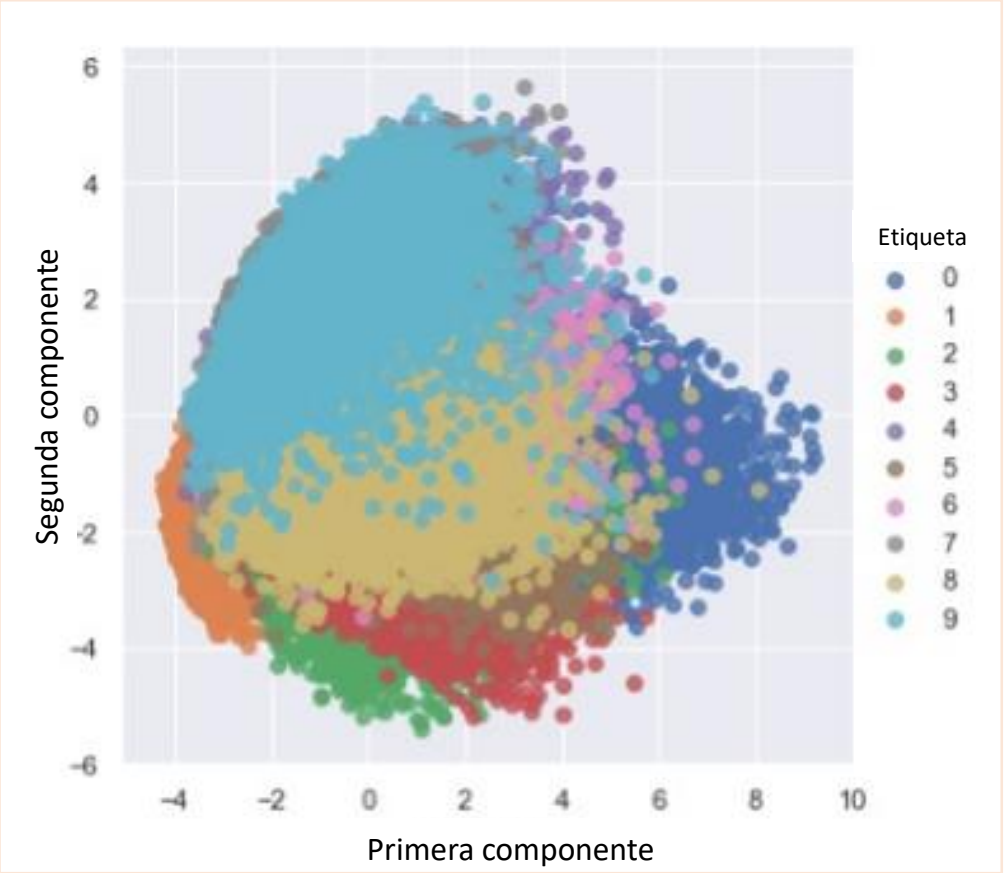

$$X_{nuevo} = X_{original} A_{proyección}$$

$$X_{nuevo} == \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & \vdots \\ x_{N1} & x_{N2} & \cdots & x_{Np} \end{bmatrix} \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1m} \\ a_{21} & a_{22} & \cdots & a_{2m} \\ \vdots & \vdots & \vdots & \vdots \\ a_{p1} & a_{p2} & \cdots & a_{pm} \end{bmatrix} = \begin{bmatrix} c_{11} & c_{12} & \cdots & c_{1m} \\ c_{21} & c_{22} & \cdots & c_{2m} \\ \vdots & \vdots & \vdots & \vdots \\ c_{N1} & c_{N2} & \cdots & c_{Nm} \end{bmatrix}$$

¿Cómo se determinan las componentes?

$$Datos = X = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1p} \\ x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \vdots & \vdots \\ x_{N1} & x_{N2} & \dots & x_{Np} \end{bmatrix} = [\boldsymbol{x}_1 \quad \boldsymbol{x}_2 \quad \dots \quad \boldsymbol{x}_p]$$

p = dimensionalidad del espacio de entrada
N = número de datos

Observación: matriz de datos centrados (con la media)

A partir de esta matriz se construye el conjunto de componentes:

$$\begin{bmatrix} x_{11} & x_{12} & \dots & x_{1p} \\ x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \vdots & \vdots \\ x_{N1} & x_{N2} & \dots & x_{Np} \end{bmatrix} \longrightarrow \begin{bmatrix} c_{11} & c_{12} & \dots & c_{1p} \\ c_{21} & c_{22} & \dots & c_{2p} \\ \vdots & \vdots & \vdots & \vdots \\ c_{N1} & c_{N2} & \dots & c_{Np} \end{bmatrix} = [\boldsymbol{c}_1 \quad \boldsymbol{c}_2 \quad \dots \quad \boldsymbol{c}_p]$$

Cada componente $\boldsymbol{c}_i$ $(i = 1..p)$ es una combinación lineal de las variables originales:

$$\boldsymbol{c}_i = a_{1i}\boldsymbol{x}_1 + a_{2i}\boldsymbol{x}_2 + \dots + a_{pi}\boldsymbol{x}_p$$

Hay que determinar el conjunto de coeficientes de cada combinación lineal

Procedimiento: para la primera componente se busca la dirección que explique la mayor cantidad de variación (varianza máxima). Luego se busca la segunda componente, ortogonal a la primera, que explique la mayor varianza residual. Y así sucesivamente ….

a) Primera componente principal:

$$\boldsymbol{c}_1 = a_{11}\boldsymbol{x}_1 \;+\; a_{21}\boldsymbol{x}_2 \;+\; \dots \;+\; a_{p1}\boldsymbol{x}_p$$

Se debe cumplir,

$$\begin{cases} 1.\ ortonormalidad \;\Rightarrow\; a_1 a_1' \;=\; 1 \\ 2.\ Varianza\ máxima \end{cases}$$

Y se tiene,

$$\begin{bmatrix} c_{11} \\ c_{21} \\ \vdots \\ c_{N1} \end{bmatrix} = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1p} \\ x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \vdots & \vdots \\ x_{N1} & x_{N2} & \dots & x_{Np} \end{bmatrix} \begin{bmatrix} a_{11} \\ a_{21} \\ \vdots \\ a_{p1} \end{bmatrix} \;\Rightarrow\; \boldsymbol{c}_1 \;=\; \boldsymbol{X}\boldsymbol{a}_1$$

Entonces,

$$\boldsymbol{var}(\boldsymbol{c}_1) \;=\; \frac{1}{N}\boldsymbol{c}_1'\boldsymbol{c}_1 \;=\; \frac{1}{N}\boldsymbol{a}_1' X' X \boldsymbol{a}_1 \;=\; \boldsymbol{a}_1'\left[\frac{1}{N}X'X\right]\boldsymbol{a}_1 \qquad pero\ \ \frac{1}{N}X'X \;=\; S \;=\; matriz\ de\ covarianzas\ de\ X$$

$$\Rightarrow\; var(\boldsymbol{c}_1) \;=\; \boldsymbol{a}_1' S \boldsymbol{a}_1$$

El problema de optimización será:

$$\begin{cases} maximizar \quad var(\boldsymbol{c}_1) \;=\; \boldsymbol{a}_1' S \boldsymbol{a}_1 \\ sujeto\ a: \quad \boldsymbol{a}_1' \boldsymbol{a}_1 \;=\; 1 \end{cases}$$

Resolviendo este problema de optimización con restricciones queda,

$$\Rightarrow \quad (S \;-\; \lambda I)\boldsymbol{a}_1 \;=\; 0$$

Para que el sistema tenga una solución distinta de cero la matriz $(S \;-\; \lambda I)$ tiene que ser singular (determinante igual a cero):

Solución = autovalor λ_1 a partir del cual se obtiene el autovector $\boldsymbol{a}_1$.

- *El vector $\boldsymbol{a}_1$ representa la mejor combinación lineal de las variables originales.*
- *Sobre c_1 se presenta la mayor dispersión de los datos (mayor varianza).*
- *Además, se cumple que:*

$$Var(\boldsymbol{c_1}) \;=\; \frac{1}{N}\boldsymbol{a}_1' X' X \boldsymbol{a}_1 \;=\; a_1' S a_1 \;=\; \boldsymbol{a}_1' \lambda I \boldsymbol{a}_1 \;=\; \lambda_1$$

b) Segunda y siguientes componentes:

Para obtener la segunda componente:

$$\begin{cases} maximizar \quad var(\boldsymbol{c}_2) \;=\; \boldsymbol{a}_2' S \boldsymbol{a}_2 \\ sujeto\ a: \quad \boldsymbol{a}_2'\boldsymbol{a}_2 \;=\; 1, \qquad \boldsymbol{a}_2'\boldsymbol{a}_1 \;=\; 0 \end{cases}$$

Y así sucesivamente …. Entonces, para obtener todas las componentes:

$$SA \;=\; \Lambda A \quad \Rightarrow \quad S \;=\; A\Lambda A'$$

Matriz de autovectores

Matriz diagonal de autovalores

Diagonzalización de la matriz de covarianzas de X

Algoritmo PCA

Entrada = {X: conjunto de datos}

Comienzo_procedimiento

Construir la matriz de datos centrados (sustracción de la media)

Calcular la matriz de covarianzas

Determinar los autovalores y autovectores

Seleccionar las componentes y construir el vector de características

Derivar el nuevo conjunto de datos X_{final}

Fin-procedimiento

Salida = {X_{final}}

Los autovectores representan las direcciones que recogen las relaciones más significativas entre las variables del conjunto de datos.

- Cada autovalor λ_i representa la varianza de su correspondiente autovector $\boldsymbol{a}_i$, donde,

$$varianza\ total \ = \sum \lambda_i \ = \ Traza(\Lambda) \ = \ Traza\ (S) \ = \sum var(\boldsymbol{x}_i)$$

Y el porcentaje de variación que recoge la componente $\boldsymbol{c}_i$ es:

$$\frac{\lambda_i}{Traza(\Lambda)}$$

Al conocer el aporte de cada componente se puede decidir cuántas se van a retener para representar a los datos (reducir la dimensionalidad)

- *El vector de características contiene los autovectores que se van a retener.*

$$vector\ de\ caraterísticas \ = \ A_m = [\boldsymbol{a}_1 \quad \boldsymbol{a}_2 \quad \cdots \quad \boldsymbol{a}_m]$$

- *¿Cómo se construye la nueva matriz de datos?*

$$X_{final} \ = \ XA_m \ = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & \vdots \\ x_{N1} & x_{N2} & \cdots & x_{Np} \end{bmatrix} \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1m} \\ a_{21} & a_{22} & \cdots & a_{2m} \\ \vdots & \vdots & \vdots & \vdots \\ a_{p1} & a_{p2} & \cdots & a_{pm} \end{bmatrix} = \boxed{\begin{bmatrix} c_{11} & c_{12} & \cdots & c_{1m} \\ c_{21} & c_{22} & \cdots & c_{2m} \\ \vdots & \vdots & \vdots & \vdots \\ c_{N1} & c_{N2} & \cdots & c_{Nm} \end{bmatrix}} \leftarrow$$

Se utiliza para el aprendizaje

Otro ejemplo. Clasificación de imágenes.

Se construyen atributos para caracterizar las imágenes

	x_1	x_2		x_d	y
Instancia 1					
Instancia 2					
Instancia N					

MediaR	MediaG	MediaB	VarianzaR	VarianzaG	VarianzaB	ModaR	ModaG	ModaB	MinColorR	MinColorG	MinColorB	MaxColorR	MaxColorG	MaxColorB	clase
188.775	202.036	198.634	10191.6	8006.02	7399.92	255	255	255	0	0	0	255	255	255	Anime
624.823	470.758	35.287	5749.8	4908.72	3961.99	0	0	0	0	0	0	255	255	255	Anime
208.878	209.354	205.973	7058.98	6033.56	4658.32	255	255	255	0	0	0	255	255	255	Anime
203.822	196.62	164.104	6376.2	5781.83	10689.2	255	255	255	0	0	0	255	255	255	Anime
766.348	634.352	262.795	10890.3	7569.6	1567.46	0	0	0	0	0	0	255	255	255	Anime
100.87	107.311	966.386	10503.4	6825.12	6347.79	0	0	0	0	0	0	255	255	255	Rostros
136.111	110.625	915.102	4523.27	4982.81	5403.52	190	0	0	0	0	0	255	255	255	Rostros
120.871	120.871	120.871	5737.89	5737.89	5737.89	0	0	0	0	0	0	255	255	255	Rostros
841.543	739.308	687.086	9362.48	7794.1	6971.85	0	0	0	0	0	0	255	255	255	Rostros
181.218	148.438	139.582	1905.79	4022.34	7920.06	215	215	235	0	0	0	255	238	255	Rostros
227.758	227.758	227.758	4003.92	4003.92	4003.92	255	255	255	0	0	0	255	255	255	Texto
235.81	235.81	235.81	4602.57	4602.57	4602.57	255	255	255	0	0	0	255	255	255	Texto
221.105	220.857	221.185	6115.31	6242.12	6096.01	255	255	255	0	0	0	255	255	255	Texto
241.294	240.137	241.092	2129.5	2427.63	2167.52	255	255	255	0	0	0	255	255	255	Texto
215.189	215.189	215.189	7709.28	7709.28	7709.28	255	255	255	0	0	0	255	255	255	Texto
219.15	219.15	219.15	6180.64	6180.64	6180.64	255	255	255	0	0	0	255	255	255	Texto
637.073	965.668	146.922	4828.55	4312.69	4142.01	0	36	255	0	0	7	255	255	255	Paisajes
120.003	156.883	204.792	3861.15	1828.21	838.248	55	116	221	0	0	7	255	255	255	Paisajes
108.413	129.85	157.473	3710.66	3003.49	3299.83	0	198	255	0	0	6	255	255	255	Paisajes
874.453	80.824	700.003	3069.33	3121.32	4081.63	10	37	0	0	0	0	255	255	255	Paisajes
133.938	86.982	382.943	4692.53	3086.03	687.175	255	42	0	4	0	0	255	232	136	Paisajes

⋮

Se puede aplicar PCA sobre esta matriz de datos:

Component	Standard Deviation	Proportion of Variance	Cumulative Variance
PC 1	397732.655	0.463	0.463
PC 2	322208.525	0.304	0.767
PC 3	261508.425	0.200	0.967
PC 4	106171.369	0.033	1.000
PC 5	2439.581	0.000	1.000
PC 6	770.342	0.000	1.000
PC 7	102.676	0.000	1.000
PC 8	87.806	0.000	1.000
PC 9	53.104	0.000	1.000
PC 10	14.566	0.000	1.000
PC 11	7.218	0.000	1.000
PC 12	4.479	0.000	1.000
PC 13	4.008	0.000	1.000
PC 14	1.908	0.000	1.000
PC 15	1.760	0.000	1.000

Utilizando los primeros tres componentes:

PC1 = 0.728MediaG + 0.541MediaB + 0.42MediaR - 0.035VarianzaB - 0.001VarianzaG...

PC2 = 0.907MediaR + 0.322MediaG + 0.272MediaB + 0.019VarianzaB + 0.001VarianzaR...

PC3 = 0.796MediaB - 0.605MediaG + 0.024MediaR + 0.008VarianzaB + 0.001VarianzaR...

Se utiliza este conjunto de datos para construir el modelo

pc_1	pc_2	pc_3	clase
-565448.229	-517666.244	85617.190	Rostros
-1001090.669	174731.562	-80319.173	Rostros
-33720.088	-296130.162	-567118.777	Rostros
385432.760	-46746.586	107883.330	Rostros
330794.385	-42467.226	100350.742	Rostros
-41317.624	-304864.502	-583158.886	Rostros
-368164.133	-454053.088	41474.690	Rostros
94484.441	-216283.663	-402200.962	Rostros
332883.224	-70814.961	91798.273	Rostros
-632062.245	156923.630	5965.551	Rostros
118274.421	-253951.654	-401598.486	Rostros
-428411.728	269070.555	166671.296	Rostros
-433409.674	102231.016	577231.758	Paisajes
370367.909	-138067.170	47160.833	Paisajes
485401.005	-69193.604	-2885.077	Paisajes
-188710.654	451605.716	-404169.943	Paisajes
313609.501	-148540.218	-135963.916	Paisajes
227028.248	-187488.461	-202583.986	Paisajes
-399006.326	245350.830	248521.871	Paisajes
552143.401	-156893.957	30644.077	Paisajes
206414.911	-325206.418	-275010.922	Paisajes
68193.282	674092.507	97782.417	Paisajes
-435677.467	-614088.852	78015.737	Paisajes
52514.050	624395.328	62251.836	Paisajes
467283.375	-42349.568	-10573.920	Paisajes

Entonces,

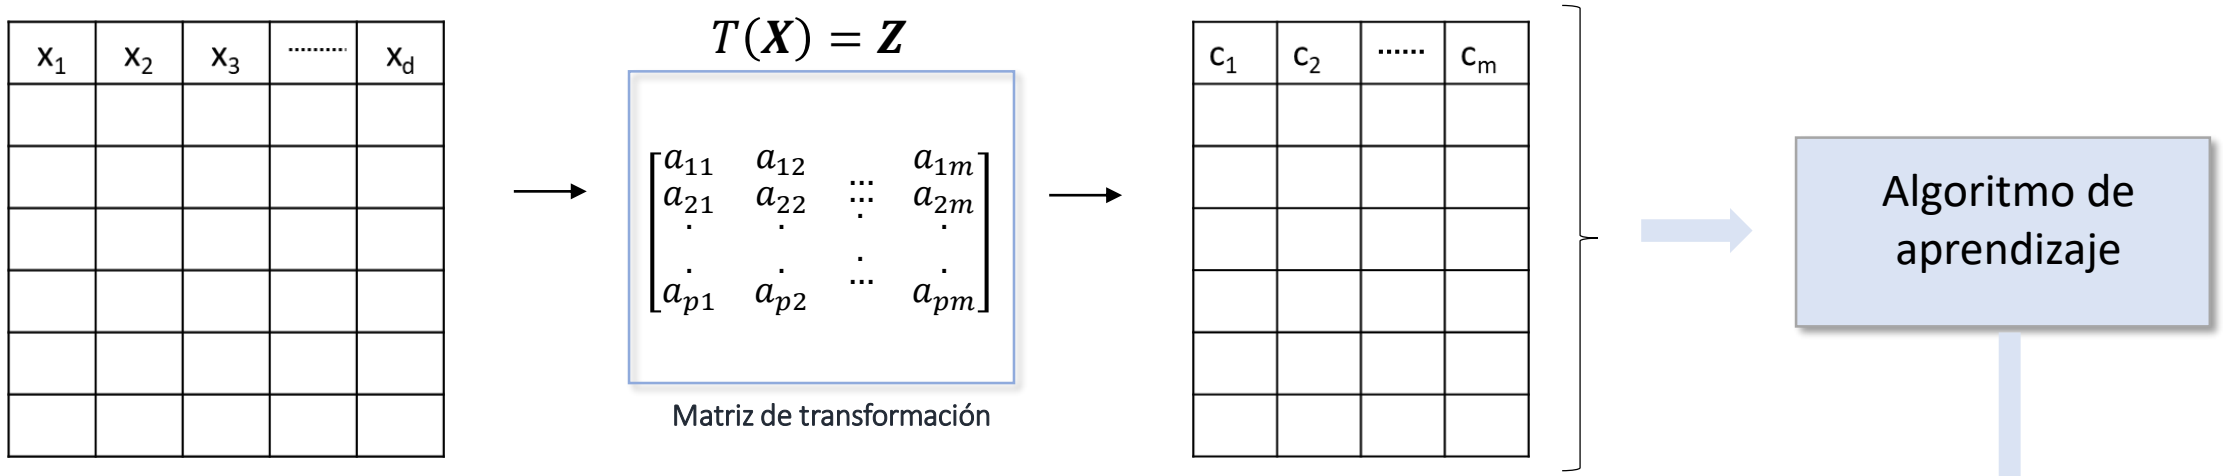

Una vez obtenida la transformación ¿cómo se utiliza para un nuevo dato?

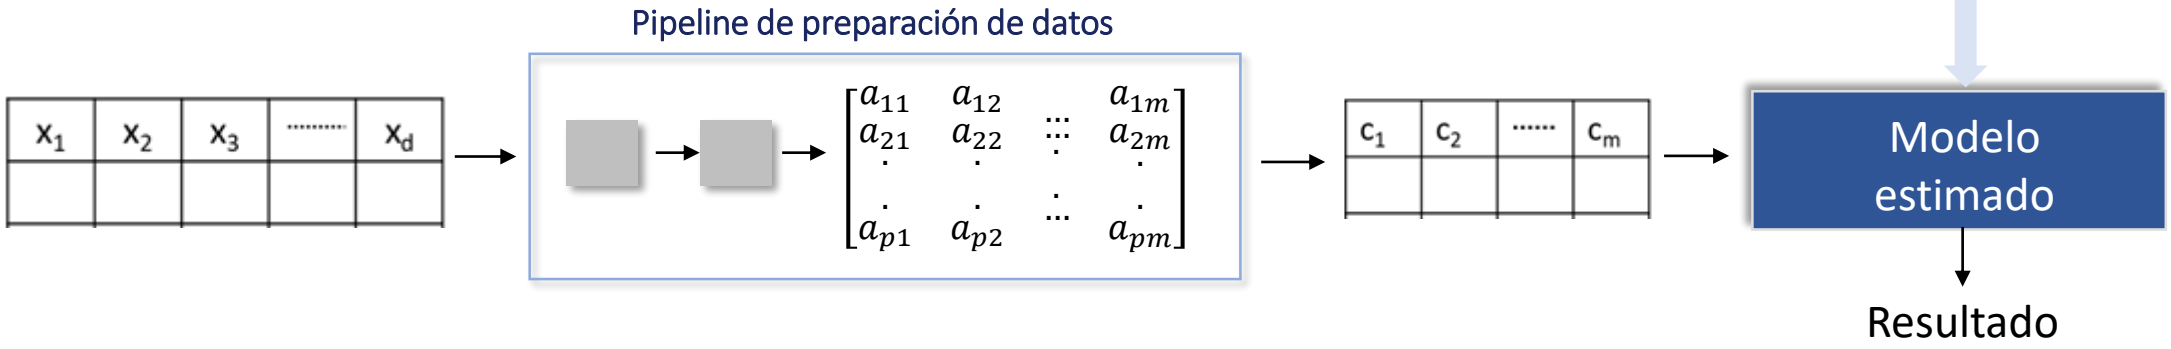

Clasificadores Bayesianos

- Son clasificadores estadísticos basados en el teorema de Bayes.
- Idea: predecir la probabilidad de pertenencia a una clase para una instancia dada (probabilidad de que una instancia sea de una clase particular).
- Algunos clasificadores basados en Bayes:

☞ Bayes ingenuo (*Naïve Bayes*).

☞ Bayes ingenuo Bernoulli (para atributos binarios).

☞ Bayes ingenuo multinomial (para características discretas).

Un repaso: Teorema de Bayes

$E = evento\ observado$

$(A_i)_{i=1..k} = eventos\ mutuamente\ exclusivos\ y\ exhasutivos\ (\boldsymbol{estados})$

E ocurre con cualquiera de los k estados A_i

El teorema establece:

$$P(A_i|E) = \frac{P(E|A_i)P(A_i)}{P(E)}$$

¿En un contexto de clasificación ¿Qué es E? ¿Qué son los estados $(A_i)_{i=1..k}$?

- En el contexto de aprendizaje de un clasificador se tiene,

$$Conjunto\ de\ datos\ = D = \{\boldsymbol{x}_i, y_i\}_{i=1..N} \quad y_i \in \{C_1, C_2, \dots C_k\}$$

$\boldsymbol{x}_i = (v_{i1}, v_{i2}, \dots, v_{id}) \longrightarrow$ *Una instancia $\boldsymbol{x}$ está descrita por los valores de d variables o atributos, donde d es la dimensionalidad del espacio de entrada*

- Entonces, según la regla de Bayes:

$$P(C|\boldsymbol{x}) = \frac{P(\boldsymbol{x}|C)P(C)}{P(\boldsymbol{x})}$$

$$donde: \boldsymbol{x} = instancia = \ evento\ observado$$

$$C \in (C_i)_{i=1..k} = clases = estados$$

$\boldsymbol{P}(C\|\boldsymbol{x}) =$	Probabilidad de que la clase sea C, dado que se presenta la instancia $\boldsymbol{x}$ (*probabilidad a posterior*i de la clase C condicionada a $\boldsymbol{x}$)
$\boldsymbol{P}(C) =$	Probabilidad de la clase C (*probabilidad a priori* de la clase C).
$\boldsymbol{P}(\boldsymbol{x}\|C) =$	Probabilidad de que la instancia sea $\boldsymbol{x}$ dado que la clase es C (*probabilidad a posteriori* de $\boldsymbol{x}$ dada la clase C)
$\boldsymbol{P}(\boldsymbol{x}) =$	Probabilidad de una instancia $\boldsymbol{x}$ (*probabilidad a priori* de $\boldsymbol{x}$)

¿Cómo determinar estas probabilidades a partir de los datos?

Clasificador Bayes Ingenuo

Clasificador Bayes Ingenuo

- Determina la probabilidad de que una instancia pertenezca a una clase C_i, i=1..K, utilizando el teorema de Bayes:

$$P(C_i|\boldsymbol{x}) = \frac{P(\boldsymbol{x}|C_i)P(C_i)}{P(\boldsymbol{x})} \quad \forall i$$

- Regla de decisión:

$$\boldsymbol{x} \in C_i \Leftrightarrow P(C_i|\boldsymbol{x}) > P\left(C_j\middle|\boldsymbol{x}\right) \; para \; 1 \leq j \leq k, j \neq i$$

$$Clase(\boldsymbol{x}) \; = C_i = \underset{1 \leq l \leq k}{argmax} \, P\left(C_j\middle|\boldsymbol{x}\right)$$

- Los valores de $P(\boldsymbol{x}|Ci), P(C)$ pueden estimarse a partir del conjunto de datos, de la siguiente forma:

☞ Probabilidad a priori de cada clase:

$$P(C_i) = \frac{Número\ de\ instancias\ de\ la\ clase\ i\ en\ D}{Número\ total\ de\ instancias\ en\ D}$$

☞ Probabilidad a posteriori de $\boldsymbol{x_j}$:

$$P(\boldsymbol{x}_j|C_i) = \prod_{m=1}^{d} P(v_{jm}|C_i) = P(v_{j1}|C_i) \times P(v_{j2}|C_i) \times \cdots \times P(v_{jd}|C_i)$$

Se asume la independencia condicional entre las variables. Por eso se conoce como “Bayes ingenuo”.

Depende del tipo de variable (numérica, categórica o binaria)

Observación: La probabilidad a priori de $\boldsymbol{x}$ es la misma para cada clase, por lo que no es necesario calcularla

$$\Rightarrow P(C|\boldsymbol{x}) = \frac{P(\boldsymbol{x}|C)P(C)}{P(\boldsymbol{x})}$$

Solo es necesario calcular este término en el numerador

Si el atributo es numérico:

$$P(v_j|C_i) = g(v_j, \mu_{C_i}, \sigma_{C_i}) \qquad donde \quad g(v,\mu,\sigma) = \frac{1}{\sqrt{2\pi\sigma}} e^{\frac{(v-\mu)^2}{2\sigma^2}}$$

☞ **Bayes ingenuo (*Naïve Bayes*)**

En este caso se asume que el atributo numérico sigue un distribución gaussiana, con media μ y desviación estándar σ. Estos estadísticos se estiman a partir de los valores observados de la variable en el conjunto de datos.

Si el atributo es categórico:

$$P(v_j|C_i) = \frac{Número\ de\ instancias\ de\ la\ clase\ C_i\ con\ valor\ v_j\ +\ \alpha}{Número\ de\ instancias\ de\ la\ clase\ C_i\ en\ D\ +\ \alpha k}$$

☞ **Bayes ingenuo multinomial**

Se utiliza una corrección para evitar un denominador = 0. Si α=1 se conoce como suavizado o corrección de Laplace.

Si el atributo es binario:

$$P(v_j|C_i) = \mathrm{P}(j|C_i)\ v_j + (1 - \mathrm{P}(j|C_i)(1 - v_j)$$

☞ **Bayes ingenuo Bernoulli**

Ejemplo. En una tienda de comercio electrónico se dispone de un conjunto de datos de clientes caracterizados por las variables que se indican a continuación. La clase indica si el cliente ha comprado o no un computador.

Edad	Ingreso	Estudiante	Crédito	Clase
Joven	Alto	No	Justo	No compra
Joven	Alto	No	Excelente	No compra
Mediana_edad	Alto	No	Justo	Compra
Mayor	Medio	No	Justo	Compra
Mayor	Bajo	Si	Justo	Compra
Mayor	Bajo	Si	Excelente	No compra
Mediana_edad	Bajo	Si	Excelente	Compra
Joven	Medio	NO	Justo	No compra
Joven	Bajo	Si	Justo	Compra
Mayor	Medio	Si	Justo	Compra
Joven	Medio	Si	Excelente	Compra
Mediana_edad	Medio	No	Excelente	Compra
Mediana_edad	Alto	Si	Justo	Compra
Mayor	Medio	No	Excelente	No compra

Predecir la clase de la siguiente instancia:

$$\boldsymbol{x} = (Joven, Medio, Si, Justo)$$

$$\Rightarrow P(C = No\ Compra|x) = \frac{P(x|C = No\ compra)P(C = No\ compra)}{P(x)}$$

$$\Rightarrow P(C = Compra|x) = \frac{P(x|C = Compra)P(C = compra)}{P(x)}$$

☞ Probabilidad a priori de cada clase:

$$P(C_i) = \frac{Número\ de\ instancias\ de\ la\ clase\ i\ en\ D}{Número\ total\ de\ instancias\ en\ D} \qquad \forall i \quad \Rightarrow \quad \begin{cases} P(No\ compra) = \frac{5}{14} = 0.357 \\ P(Compra) = \frac{9}{14} = 0.643 \end{cases}$$

☞ Probabilidad a posteriori de $\boldsymbol{x}$:

$$P(\boldsymbol{x}|C_i) = \prod_{m=1}^{d} P(v_{jm}|C_i) = P(v_{j1}|C_i) \times P(v_{j2}|C_i) \times \cdots \times P(v_{jd}|C_i) \qquad \forall i$$

$\Rightarrow$ Edad:

$$P(Joven|No\ compra) = \frac{3}{5} = 0.600$$

$$P(Joven|Compra) = \frac{2}{9} = 0.222$$

$\Rightarrow$ Ingreso:

$$P(Medio|No\ compra) = \frac{2}{5} = 0.400$$

$$P(Medio|Compra) = \frac{4}{9} = 0.444$$

Estudiante:

$$P(Si|No\ compra) = \frac{1}{5} = 0.200$$

$$P(Si|Compra) = \frac{6}{9} = 0.667$$

Crédito:

$$P(Justo|No\ compra) = \frac{2}{5} = 0.400$$

$$P(Justo|Compra) = \frac{6}{9} = 0.667$$

$$P(\boldsymbol{x}|No\ compra) = P(Joven|No\ compra) \times P(Medio|No\ compra) \times P(Si|No\ compra) \times P(Justo|No\ compra)$$
$$= 0.600 \times 0.400 \times 0.200 \times 0.400 = 0.019$$

$$P(\boldsymbol{x}|Compra) = P(Joven|Compra) \times P(Medio|Compra) \times P(Si|Compra) \times P(Justo|Compra)$$
$$= 0.222 \times 0.444 \times 0.667 \times 0.677 = 0.044$$

Entonces,

$$P(No\ compra|\boldsymbol{x}) = P(\boldsymbol{x}|No\ compra)P(No\ compra) = 0.019 \times 0.357 = 0.007$$

$$P(Compra|\boldsymbol{x}) = P(\boldsymbol{x}|Compra)P(Compra) = 0.044 \times 0.643 = 0.028$$

Se asigna a la instancia la clase "Compra"

¿Cómo utilizamos Naïve Bayes?

Tarea	Problema de aprendizaje	Parámetros del modelo	Control de la complejidad	Características y contextos de aplicación
Clasificación	Estimar la probabilidad a posteriori de cada clase dado un dato, con base en el Teorema de Bayes: $Clase(\boldsymbol{X}) = C_i = \underset{1 \le l \le k}{argmax}\, P(C_j \mid \boldsymbol{X})$	Probabilidades a priori de cada Clase y Probabilidad a posteriori de X.	No tiene. Sin embargo, el parámetro de suavizado podría producir modelos más simples (a mayor valor de α modelos más simples)	Trabajan bien con atributos numéricos y categóricos. No requieren escalado de las variables numéricas (normalización o estandarización). Rapidez en el entrenamiento y en las predicciones. Trabajan bien con datos numéricos de muy alta dimensión. Escalan bien con el número de datos. Muy utilizados en analítica de textos. Trabajan bien con matrices dispersas. Pueden utilizarse como modelos baseline.

En clasificación de textos, el cálculo de las probabilidades depende del modelo de datos que se esté utilizando:

- Si modelo binario: Bayes Bernoulli
- Si modelo de frecuencias absolutas: Bayes multinomial
- Si modelo tf-idf: Bayes gaussiano (pero también funciona Bayes multinomial)

¿Qué es un modelo generativo?

Un modelo generativo, suena creativo,
aprende del mundo y crea contenido.
No copia, no imita, ¡improvisa en la pista!,
con datos entrena y luego conquista.

Te suelta un texto, te pinta un paisaje,
te arma una imagen, ¡sin maquillaje!
No clasifica ni hace predicción,
¡crea del cero con pura intuición!

IA con ritmo, IA con arte,
aprende patrones pa' luego soltarte.
Si ves que inventa y te deja pensativo...
¡estás frente a un modelo generativo!

ChatGPT

¿Qué se puede generar? Por ejemplo	Herramientas
Texto	GPT, LLAMA, CLAUDE, GEMINI…
Imágenes	DALL-E, StableDifussion, MidJourney,…
Videos	Runway, VEO, Pika,…
Música	MusicLM, MusicGen, Mozart's Touch, Riffusion…
Código	Copilot, Codex, CodeLLama, Cursor,…

Además, pueden ser multimodales.

⇩

En el aprendizaje multimodal ⇒ modelos que pueden trabajar con diferentes tipos de datos.

En el contexto de modelos generativos ⇒ convertir entre dos o más tipos diferentes de datos.

Ejemplo: identificación de autores de pinturas.

Lo que hemos hecho hasta ahora

Modelo discriminativo

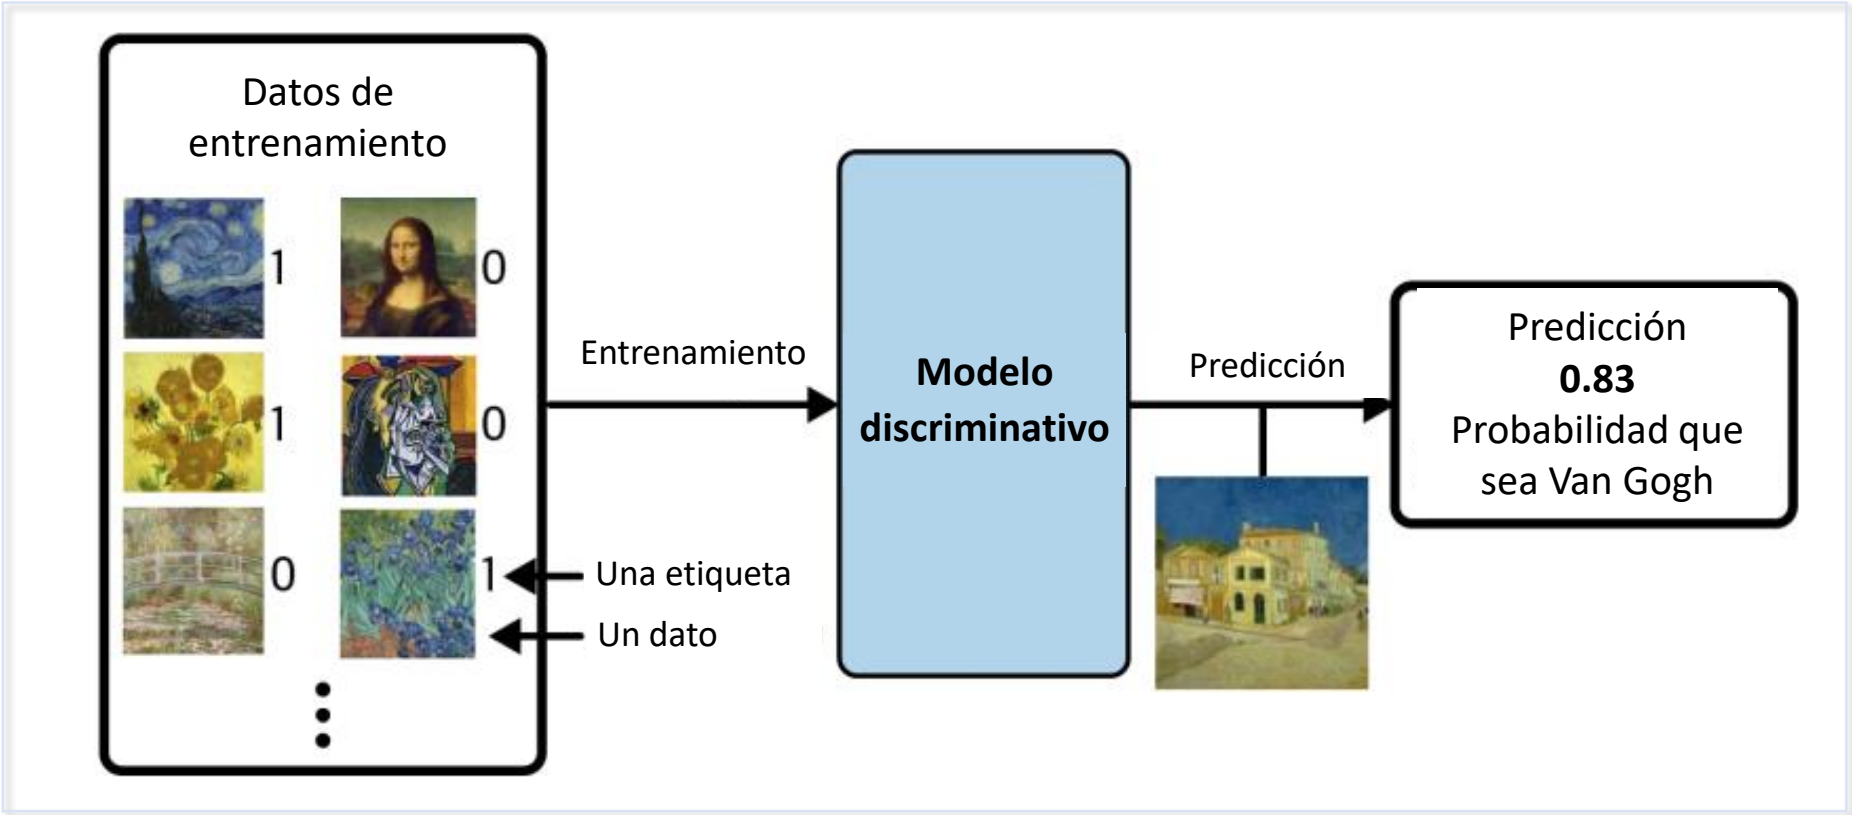

¿Qué se estima? → Probabilidad de una clase y dado un dato $\boldsymbol{x} = \rho(y|\boldsymbol{x})$ ← **Modelo supervisado**

David Foster. (2023). Generative Deep Learning. Teaching Machines to Paint, Write, Compose, and Play. O'Reilly.

En **modelos generativos**:

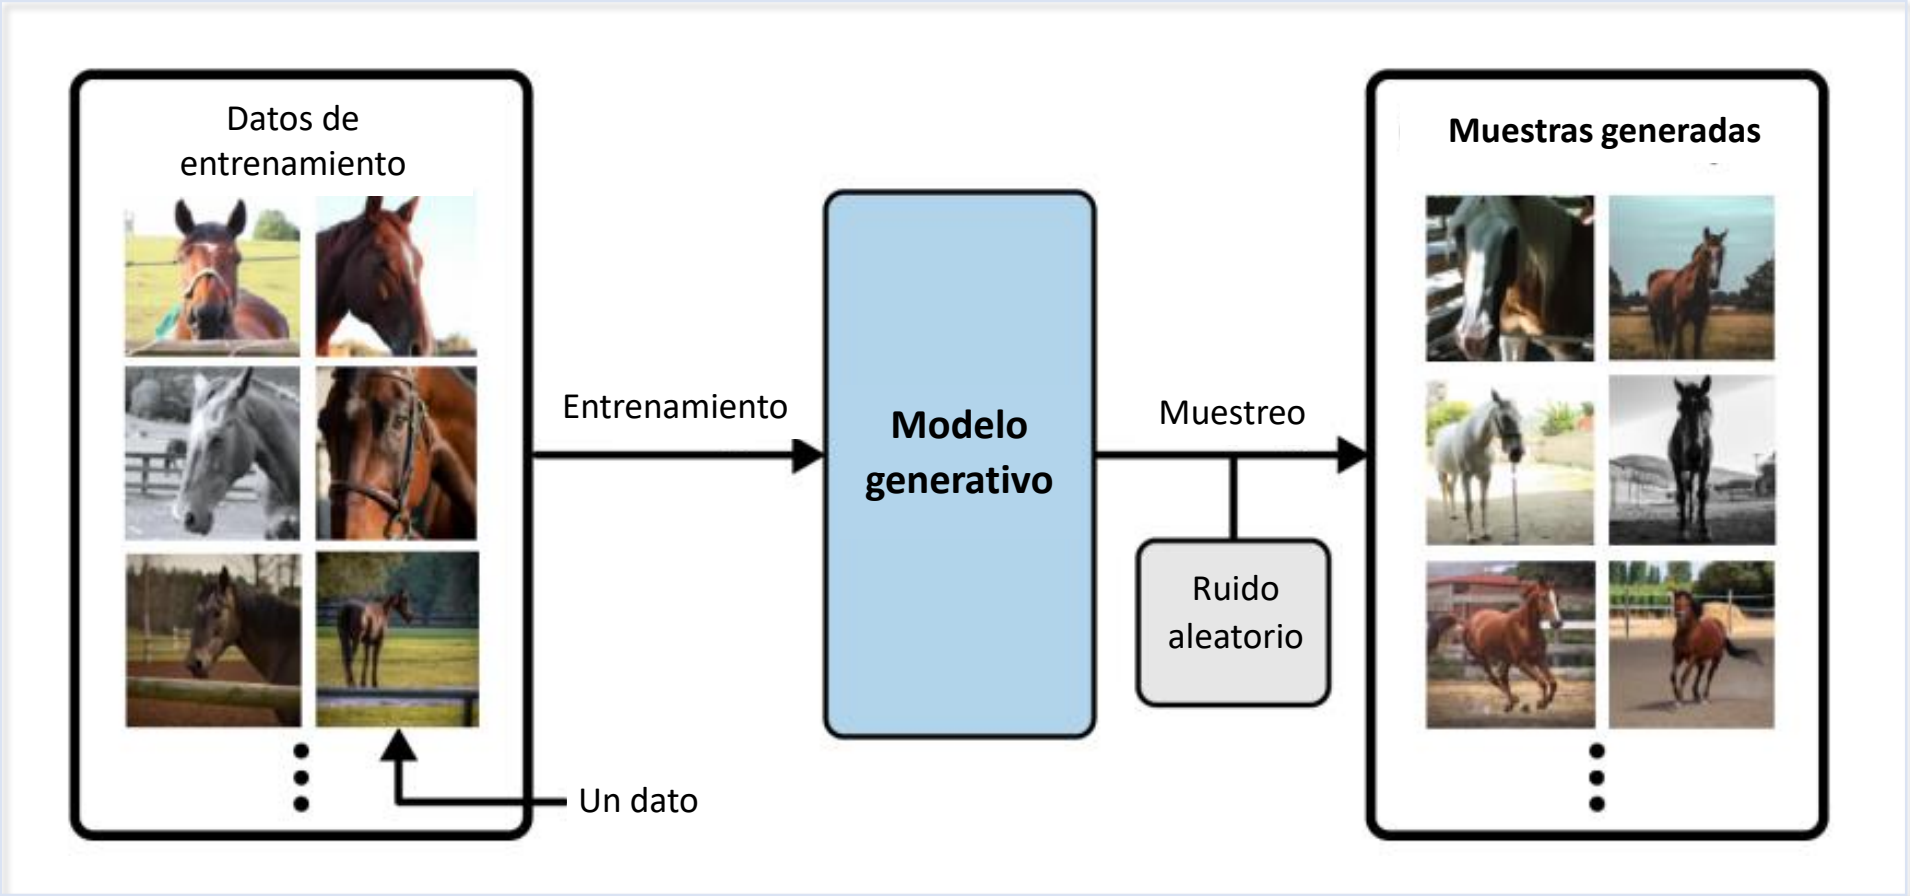

¿Qué se estima? → Probabilidad de observar a $\boldsymbol{x} = \rho(\boldsymbol{x})$ ← **Modelo no supervisado**

Definición:

Un modelo generativo describe cómo se genera un conjunto de datos, en términos de un modelo probabilístico. Realizando un muestreo a partir de esta función de densidad de probabilidad se pueden generar nuevos datos.

Marco general

Datos Generados a partir de una distribución desconocida

ρ_{datos}

⇨

Modelo generativo

ρ_{modelo}

⇨

Muestreo sobre ρ_{modelo}

↓

Durante el aprendizaje se busca que

$$\rho_{modelo} \cong \rho_{datos}$$

↓

Dato nuevo

- **Los datos nuevos deben parecer como si hubiesen sido generados por** ρ_{datos}
- ρ_{modelo} **no debería generar datos que ya ha visto.**

En el ejemplo:

Generados a partir de una distribución desconocida ρ_{datos}

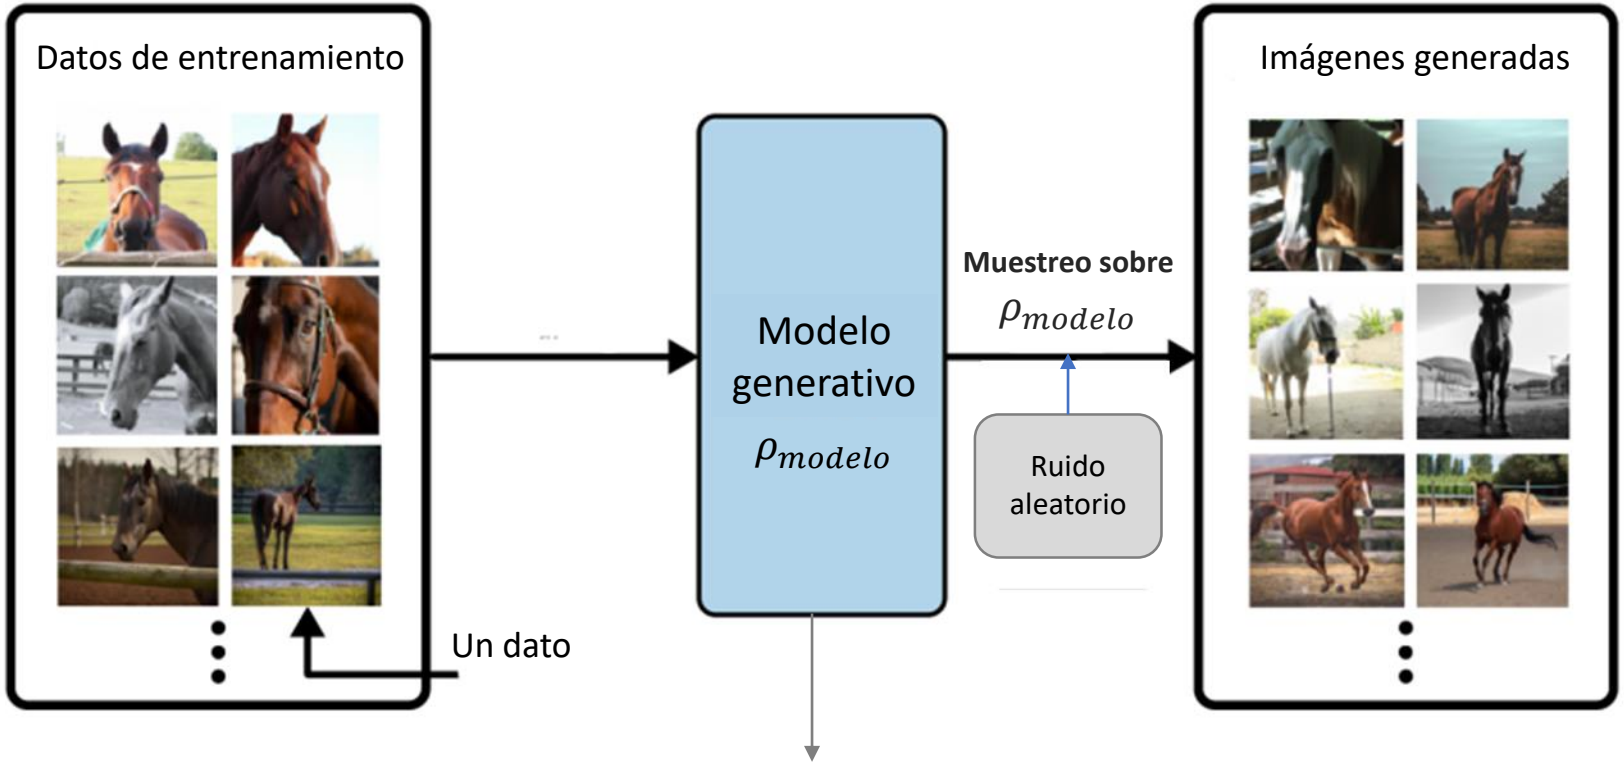

Durante el aprendizaje se busca que

$$\rho_{modelo} \cong \rho_{datos}$$

- Los datos nuevos deben parecer como si hubiesen sido generados por ρ_{datos}
- ρ_{modelo} no debería generar datos que ya ha visto.

Algunos conceptos:

- Espacio muestral. Conjunto de todos los posibles valores que un dato u observación $\boldsymbol{x}$ puede tomar.
- Función de densidad de probabilidad. Una función de densidad de probabilidad (o simplemente función de densidad), $\rho(\boldsymbol{x})$, es una función que asigna un punto $\boldsymbol{x}$ en el espacio muestral a un número entre 0 y 1.
- Modelado paramétrico. Un modelo paramétrico, $\rho_\theta(\boldsymbol{x})$ es una familia de funciones de densidad que puede describirse mediante un número finito de parámetros θ.
- Verosimilitud *(likelihood*). La verosimilitud de un conjunto de parámetros θ es una función que mide la plausibilidad de θ dado una observación $\boldsymbol{x}$.

$$\ell(\theta|\boldsymbol{x}) = \sum_{x \in X} \rho_\theta(\boldsymbol{x})$$

- Estimación de máxima verosimilitud. Técnica que permite estimar los valores de los parámetros θ de la función de densidad $\rho_\theta(\boldsymbol{x})$ que es la más probable para explicar el conjunto de datos.

$$\hat{\theta} = \underset{\theta}{\operatorname{argmax}}\, \ell(\theta|\boldsymbol{x}) = estimado\ de\ máxima\ verosimilitud\ (MLE)$$

Ejemplo: generación de datos con Bayes Ingenuo.

Conjunto de datos (N = 50), número de variables (k = 5)

face_id	accessoriesType	clothingColor	clothingType	hairColor	topType
0	Round	White	ShirtScoopNeck	Red	ShortHairShortFlat
1	Round	White	Overall	SilverGray	ShortHairFrizzle
2	Sunglasses	White	ShirtScoopNeck	Blonde	ShortHairShortFlat
3	Round	White	ShirtScoopNeck	Red	LongHairStraight
4	Round	White	Overall	SilverGray	NoHair
5	Blank	White	Overall	Black	LongHairStraight
6	Sunglasses	White	Overall	SilverGray	LongHairStraight
7	Round	White	ShirtScoopNeck	SilverGray	ShortHairShortFlat

- 7 different hairstyles (*topType*):
  — *NoHair, LongHairBun, LongHairCurly, LongHairStraight, ShortHairShortWaved, ShortHairShortFlat, ShortHairFrizzle*
- 6 different hair colors (*hairColor*):
  — *Black, Blonde, Brown, PastelPink, Red, SilverGray*
- 3 different kinds of glasses (*accessoriesType*):
  — *Blank, Round, Sunglasses*
- 4 different kinds of clothing (clothingType):
  — *Hoodie, Overall, ShirtScoopNeck, ShirtVNeck*
- 8 different clothing colors (*clothingColor*):
  — *Black, Blue01, Gray01, PastelGreen, PastelOrange, Pink, Red, White*

- Espacio muestral. Número de posibles combinaciones: 4.032.
- Para construir el modelo generativo se utilizará Bayes Ingenuo utilizando la distribución multinomial.
- Bayes ingenuo: asume independencia entre las diferentes variables.

David Foster. (2023). Generative Deep Learning. Teaching Machines to Paint, Write, Compose, and Play. O'Reilly.

$\Rightarrow$ $\rho(\boldsymbol{x}) = \prod_{k=1}^{5} p(x_k)$ Los parámetros a estimar serían: $\theta_{kl} = p(x_k = l)$

¿Cuántos parámetros?

- El estimado de máxima verosimilitud es:

$$\widehat{\theta_{kl}} = \frac{n_{kl}}{N}$$

- Para calcular la probabilidad de que el modelo genere algún dato, se multiplican las probabilidades de las características individuales.

p(LongHairStraight, Red, Round, ShirtScoopNeck, White)

= *p(LongHairStraight)* × *p(Red)* × *p(Round)* × *p(ShirtScoopNeck)* × *p(White)*
= 0.46 × 0.16 × 0.44 × 0.38 × 0.44
= 0.0054

- De esta forma se construye la función de densidad completa $\rho_\theta(\boldsymbol{x})$

topType	n	$\hat{\theta}$
NoHair	7	0.14
LongHairBun	0	0.00
LongHairCurly	1	0.02
LongHairStraight	23	0.46
ShortHairShortWaved	1	0.02
ShortHairShortFlat	11	0.22
ShortHairFrizzle	7	0.14
Grand Total	*50*	*1.00*

hairColor	n	$\hat{\theta}$
Black	7	0.14
Blonde	6	0.12
Brown	2	0.04
PastelPink	3	0.06
Red	8	0.16
SilverGrey	24	0.48
Grand Total	*50*	*1.00*

clothingColor	n	$\hat{\theta}$
Black	0	0.00
Blue01	4	0.08
Grey01	10	0.20
PastelGreen	5	0.10
PastelOrange	2	0.04
Pink	4	0.08
Red	3	0.06
White	22	0.44
Grand Total	*50*	*1.00*

accessoriesType	n	$\hat{\theta}$
Blank	11	0.22
Round	22	0.44
Sunglasses	17	0.34
Grand Total	*50*	*1.00*

clothingType	n	$\hat{\theta}$
Hoodie	7	0.14
Overall	18	0.36
ShirtScoopNeck	19	0.38
ShirtVNeck	6	0.12
Grand Total	*50*	*1.00*

Imágenes nuevas:

Pero ¿qué pasa si hay dependencias entre las características?

¿Y si el espacio de entrada es de muy alta dimensionalidad?

Próxima sesión

- Aprendizaje no supervisado
- La tarea de agrupación
- Algoritmo K-medias.
- Métricas para modelos de agrupación.
- Interpretación de modelos de agrupación.