Sesión 1. Fundamentos de machine learning. Regresión lineal

- Qué es el machine learning. Algunas definiciones
- Tipos de aprendizaje y contextos de aplicación.
- Elementos de un sistema de aprendizaje
- Ciclo de machine learning
- La regresión lineal.

¿Qué es el machine learning?

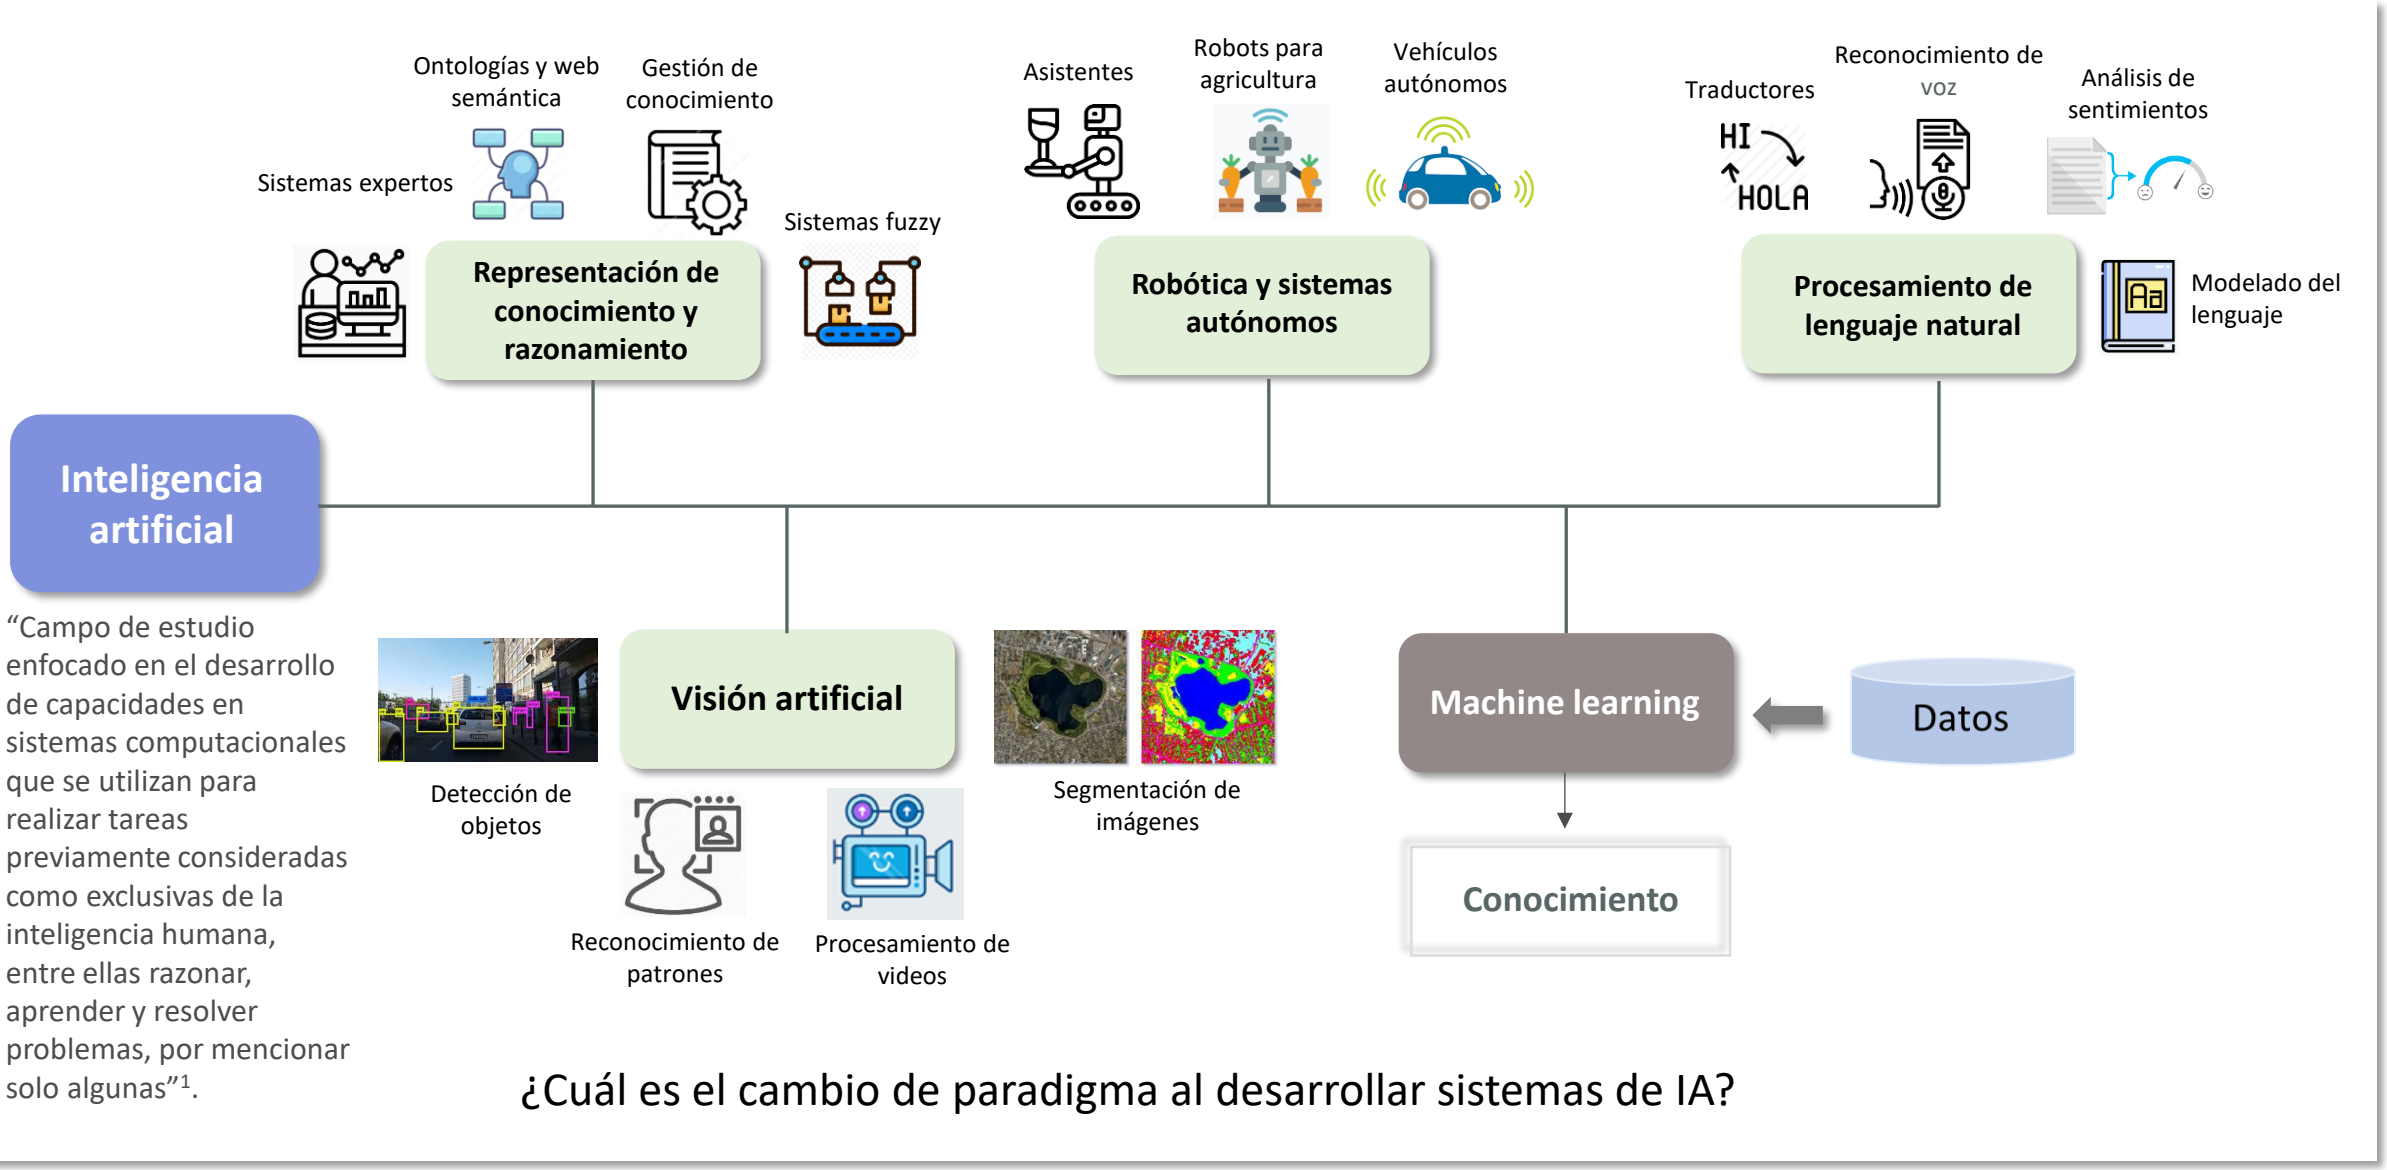

"Campo de estudio enfocado en el desarrollo de capacidades en sistemas computacionales que se utilizan para realizar tareas previamente consideradas como exclusivas de la inteligencia humana, entre ellas razonar, aprender y resolver problemas, por mencionar solo algunas"[1].

¿Cuál es el cambio de paradigma al desarrollar sistemas de IA?

[1]Banco Interamericano de Desarrollo. LA INTELIGENCIA ARTIFICIAL AL SERVICIO DEL BIEN SOCIAL EN AMÉRICA LATINA Y EL CARIBE: panorámica regional e instantáneas de doce países. P. 19. Disponible en: https://publications.iadb.org/es/la-inteligencia-artificial-al-servicio-del-bien-social-en-america-latina-y-el-caribe-panor%C3%A1mica-regional-e-instant%C3%A1neas-de-doce-paises. Fecha de consulta: 29/07/21.

Diagnóstico a partir de imágenes

Filtrado de correos Spam

Sistemas de recomendación

Detección de cambios de la cobertura terrestre

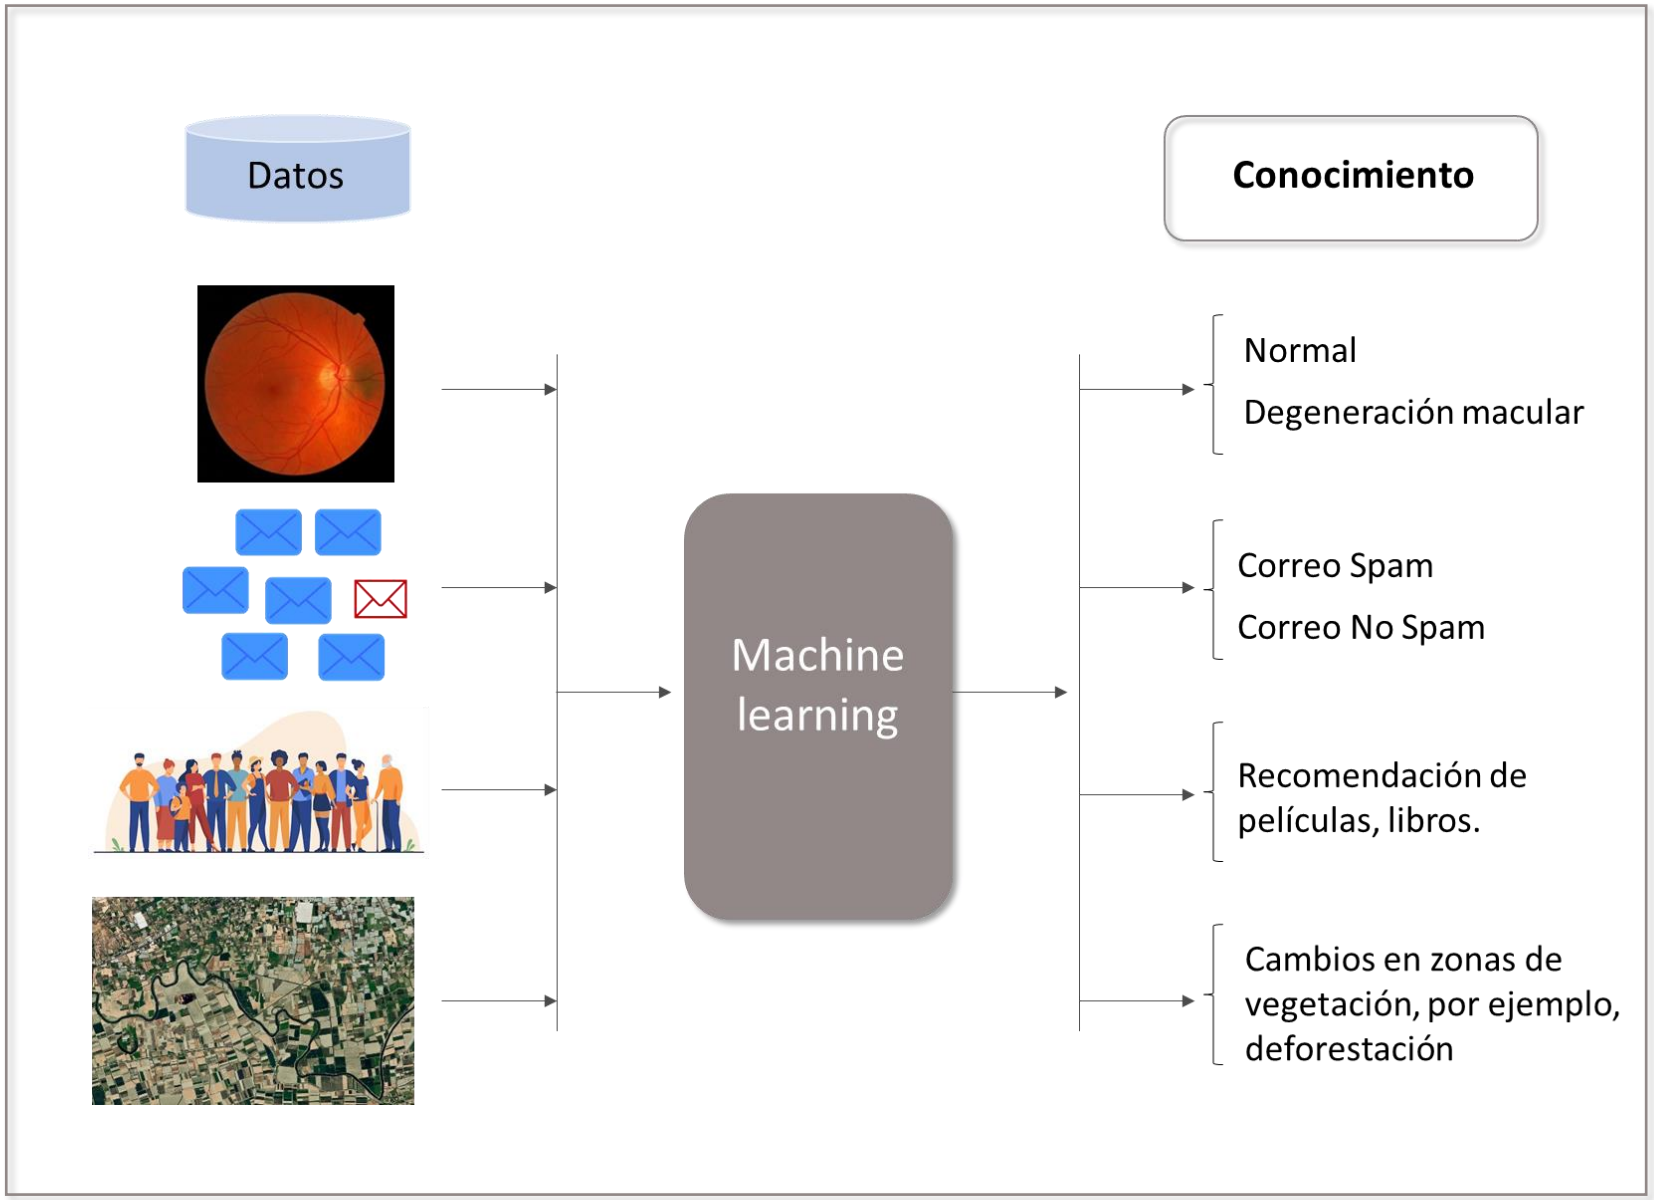

Algunas definiciones…

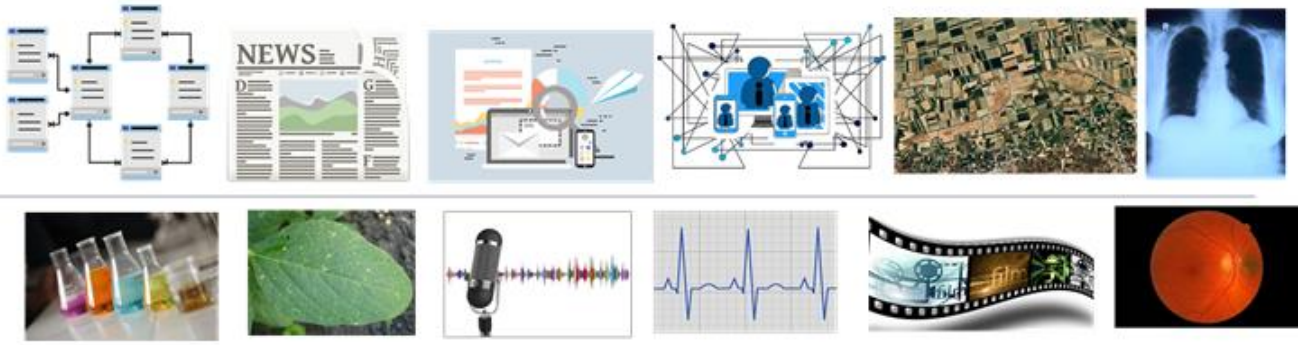

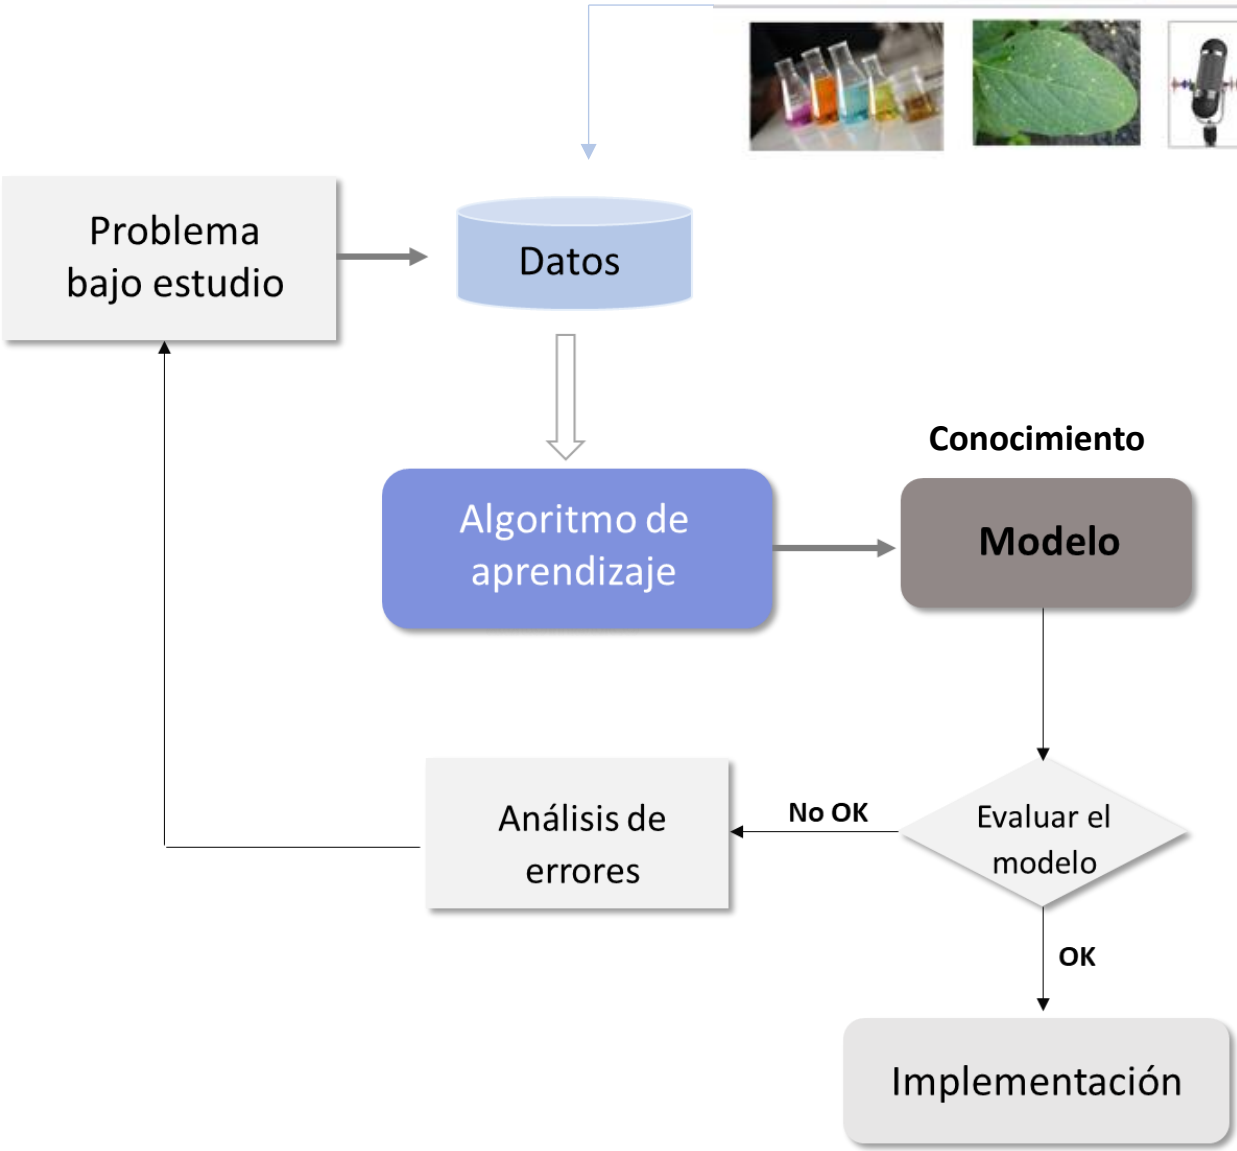

Arthur Samuel (1901 - 1990)

Campo de estudio cuyo objetivo es dotar a los computadores de la habilidad de aprender sin ser programados explícitamente (1959).

(Some studies in machine learning using the game of checkers. IBM Journal of Research and Development, 3(3):210 - 229).

Aurélien Géron

Ciencia (y arte) de programar computadores para que puedan aprender a partir de datos (2025).

(Libro: Hands-on Machine Learning with Scikit-Learn and Pytorch. O'Reilly, 2025)

Tipos de aprendizaje
pueden ser
Supervisado
No supervisado
Por refuerzo
tareas
Clasificación
Regresión
tareas
Agrupación
Análisis de asociación
Detección de anomalías
Reducción de la dimensionalidad

- **Supervisado**

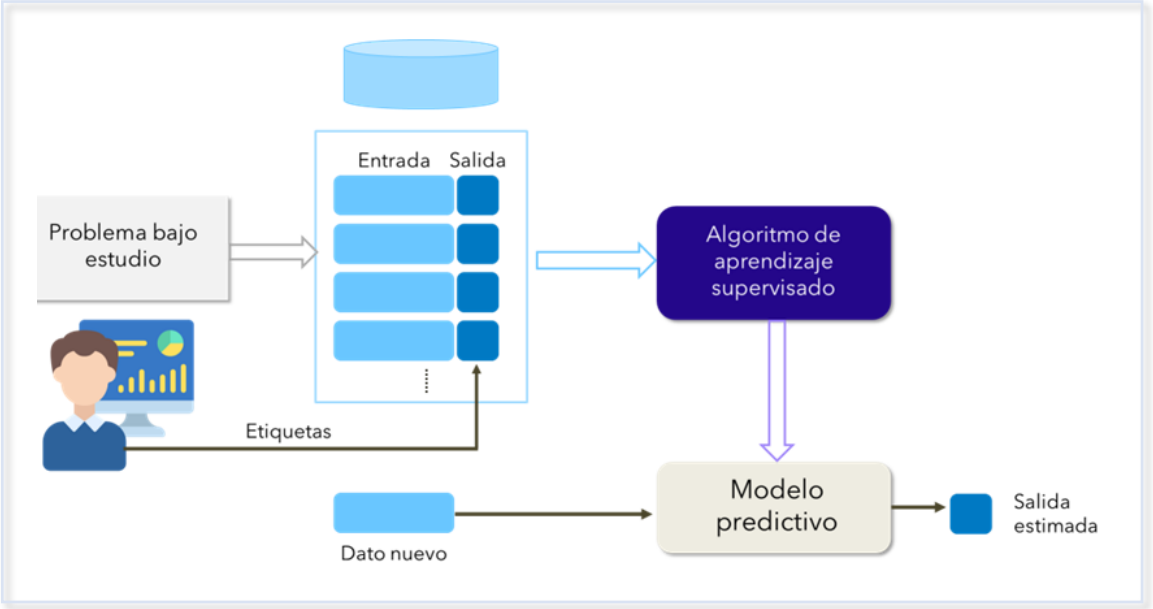

Tarea de regresión

Deep learning for automated skeletal bone age assessment in X-ray images https://www.sciencedirect.com/science/article/abs/pii/S1361841516301840

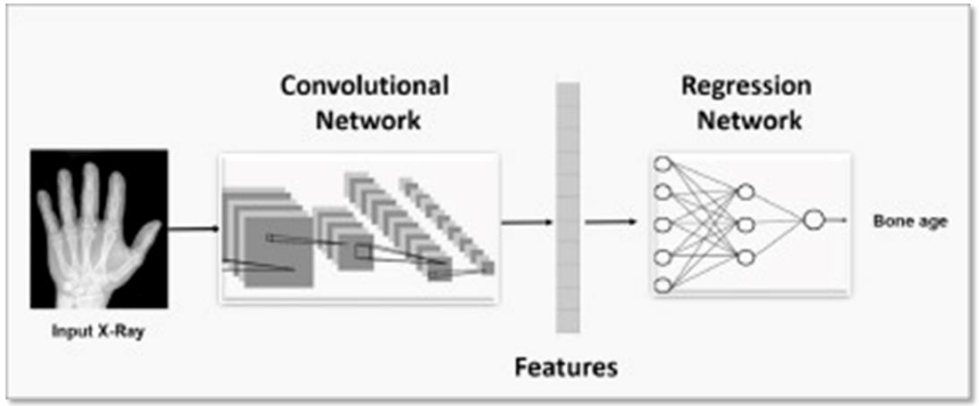

Datos =

Entrada	Salida
Imagen	Edad (valor numérico)

Tarea de clasificación

- Clasificación de binaria.

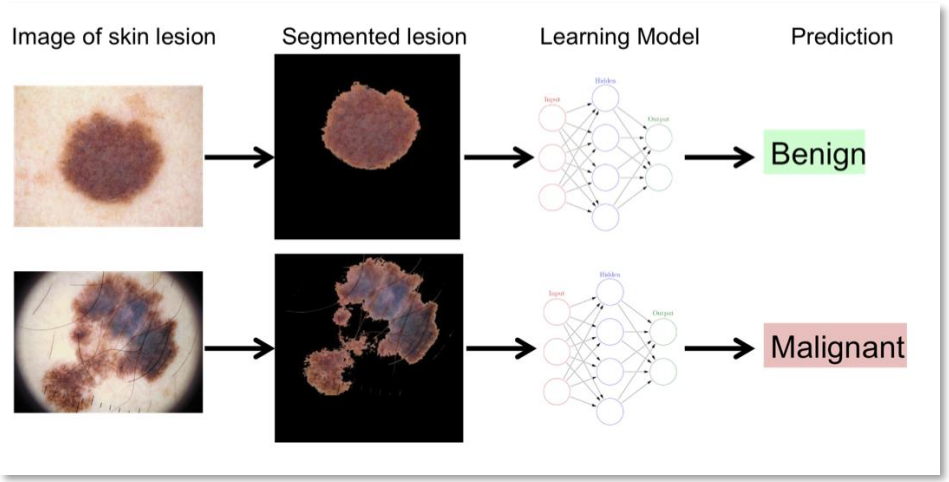

Skin cancer classification with deep learning. https://cs.stanford.edu/people/esteva/nature/

Datos =

Entrada	Salida
Imagen	Diagnóstico

etiqueta de clase (Benign, Malignant)

- Clasificación multiclase:

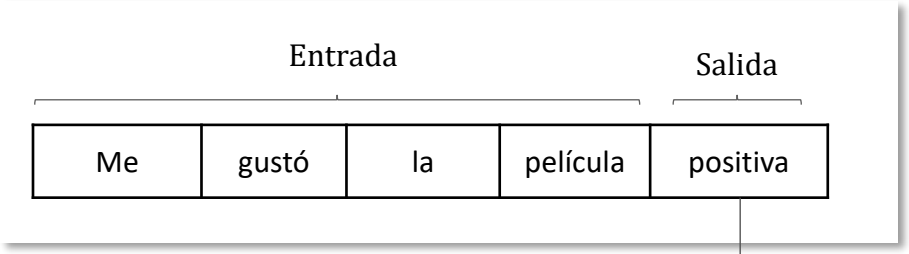

etiqueta de clase (Positiva, Negativa. neutra)

Tarea de regresión

Problema: estimar el área que podría verse afectada por un incendio forestal, lo cual permitiría apoyar en la toma de decisiones asociadas al establecimiento de planes de mitigación. Los datos están relacionados con incendios que han ocurrido en el pasado y con la fecha del evento, así como con variables climáticas, topográficas y de ubicación.

area_quemada	clase_incendio	mes_incendio	vegetacion	Prec_pre_30	Prec_pre_15	Prec_pre_7	Prec_cont
3.0	B	Diciembre	Desierto polar_roca	59.8	8.4	0.0	86.8
60.0	C	Febrero	Bosque tropical perennifolio secundario	168.8	42.2	18.1	124.5
1.0	B	Junio	Bosque tropical perennifolio	10.4	7.2	0.0	0.0
5.2	B	Enero	Matorral abierto	26.0	0.0	0.0	0.0
1.0	B	Noviembre	Matorral abierto	28.4	27.5	1.2	55.4
8.3	B	Marzo	Matorral abierto	76.3	26.2	8.4	40.5
1.0	B	Octubre	Bosque tropical perennifolio secundario	0.0	0.0	0.0	0.0
1.0	B	Julio	Matorral abierto	62.8	4.3	0.0	56.2
1.0	B	Agosto	Bosque tropical perennifolio	0.0	0.0	0.0	0.0
5.0	B	Diciembre	Bosque tropical perennifolio secundario	0.0	0.0	0.0	0.0
40.0	C	Abril	Matorral abierto	0.0	0.0	0.0	0.0
1.0	B	Abril	Bosque templado	52.9	38.4	2.3	30.5
20.0	C	Junio	Matorral abierto	93.7	85.3	41.4	154.3
3.2	B	Julio	Pradera_estepa	3.1	2.8	2.8	0.0
1.0	B	Octubre	Matorral abierto	65.6	51.9	38.4	33.9
15.3	C	Diciembre	Bosque tropical perennifolio	150.8	104.8	17.0	0.0

Algoritmo de aprendizaje → **Modelo de regresión** → ÁREA

Nuevo dato (registro de incendio)

clase_incendio	mes_incendio	vegetacion	Prec_pre_30	Prec_pre_15	Prec_pre_7	Prec_cont
B	Abril	Pradera_estepa	87.5	33.3	31.2	0.0

Tarea de clasificación

Problema: estimar la calidad del agua de una zona determinada, con el fin de apoyar la toma de decisiones sobre su consumo con fines agrícolas. Los datos están relacionados con muestras de agua tomadas de diferentes fuentes, caracterizadas por variables fisicoquímicas y anotadas por los expertos, indicando cuáles son aptas para el consumo y cuáles no.

pH	Dureza	Sólidos	Cloraminas	Sulfatos	Conductividad	Carbono_orgánico	Trihalometanos	Turbidez	Apta
5.63	226.83	28334.49	8.01	293.92	351.16	15.02	35.18	5.05	Sí
5.97	194.8	17350.06	4.47	404.61	406.81	11.54	48.17	4.18	Sí
6.32	180.97	36278.72	9.96	275.59	307.69	18.2	93.59	2.65	Sí
5.99	224.61	29983.12	7.38	329.73	604.63	17.74	65.12	4.84	Sí
10.27	163.62	18894.85	10.07	269.65	446.45	11.86	82.45	3.18	Sí
6.11	249.14	45249.45	7.37	338.77	314.97	11.25	88.66	3.1	Sí
5.74	188.22	26831.61	6.2	318.38	498.14	9.66	53.51	3.32	NO
5.6	177.21	17925.35	8.44	303.73	552.31	10.34	57.82	5.24	NO
7.35	193.63	26736.09	10.42	309.42	557.5	16.52	61.08	3.66	NO
6.26	206.89	31414.53	4.53	349.73	567.03	15.96	73.02	4.01	NO
9.93	208.49	19666.99	8.01	340.24	482.84	11.36	85.83	4.05	NO
7.34	210.12	12810.42	8.87	309.66	412.71	12.39	73.51	3.92	Sí
10.02	210.13	9064.04	7.2	363.56	324.65	10.21	92.64	3.85	Sí
6.33	197.48	23460.82	6.12	303.55	399.56	18.82	62.22	4.04	Sí
8.99	195.81	23728.29	7.51	348.71	551.54	15.25	75.91	4.49	NO
6.11	178.45	30606.22	5.57	260.77	472.26	16.71	46.55	3.68	Sí

Algoritmo de aprendizaje → **Modelo de clasificación** → APTA

Nuevo dato (muestra de agua)

pH	Dureza	Sólidos	Cloraminas	Sulfatos	Conductividad	Carbono_orgánico	Trihalometanos	Turbidez
6.28	205.12	25972.8	8.42	383.67	456.54	13.95	32.8	4.6

- Clasificación multietiqueta.

Entrada:

Salida: [Sí, Sí]

Entrada:

Salida: [No, Sí].

Datos =

Entrada	Salida 1	Salida 2
Imagen	Clase	Clase

Por ejemplo, en detección de objetos

Entrada:

Salida: [tipo de enfermedad, n1, n2, n3, n4]
Donde,
n1, n2: coordenadas de la esquina superior izquierda del cuadro delimitador
n3: ancho del cuadro delimitador
n4: largo del cuadro delimitador

- **No supervisado**

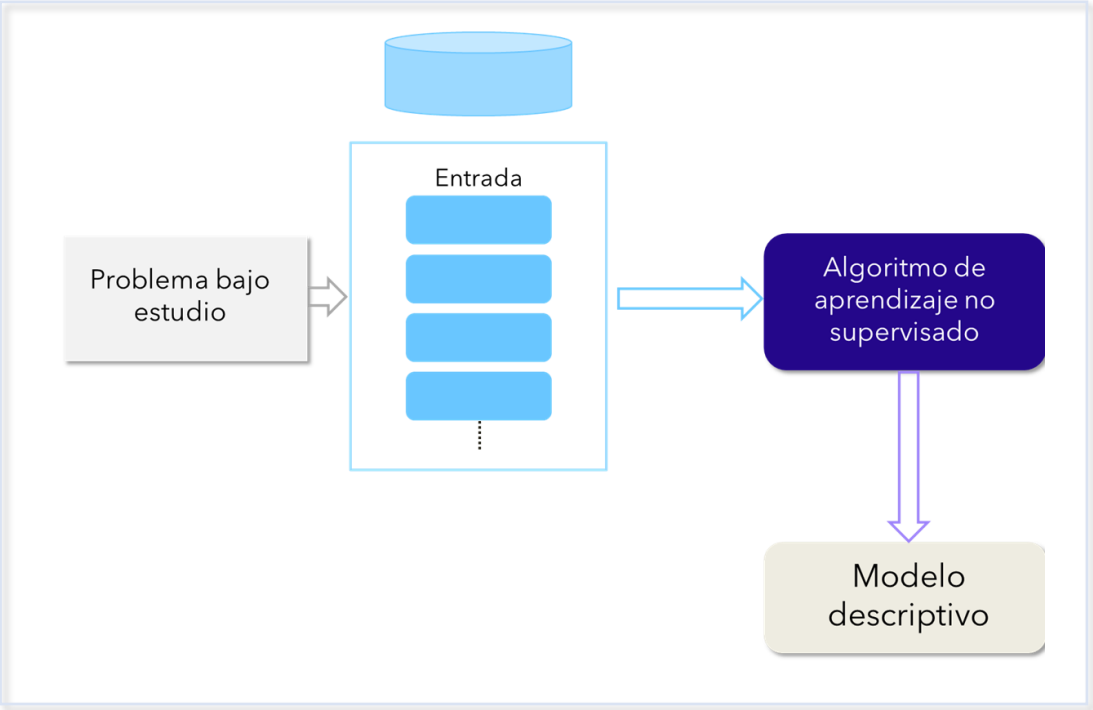

Agrupación

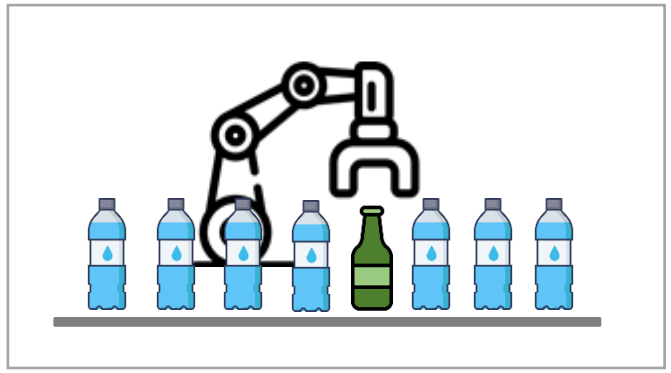

Detección de anomalías

Análisis de asociación

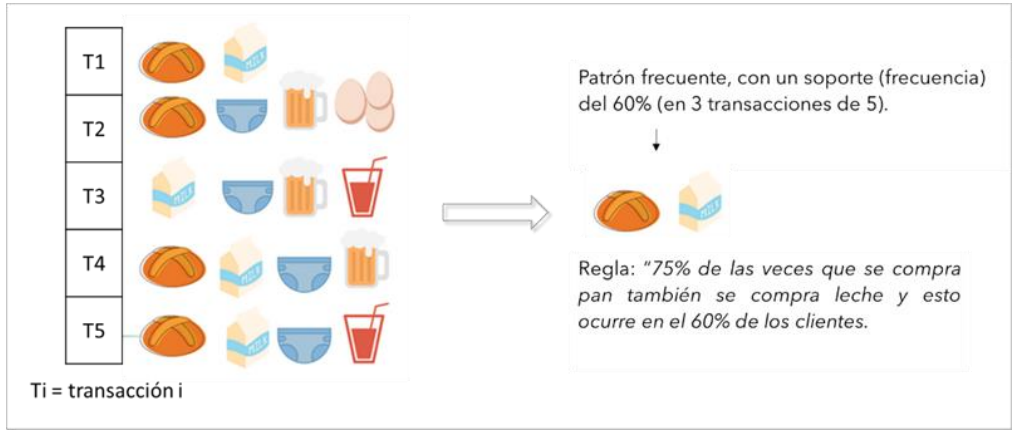

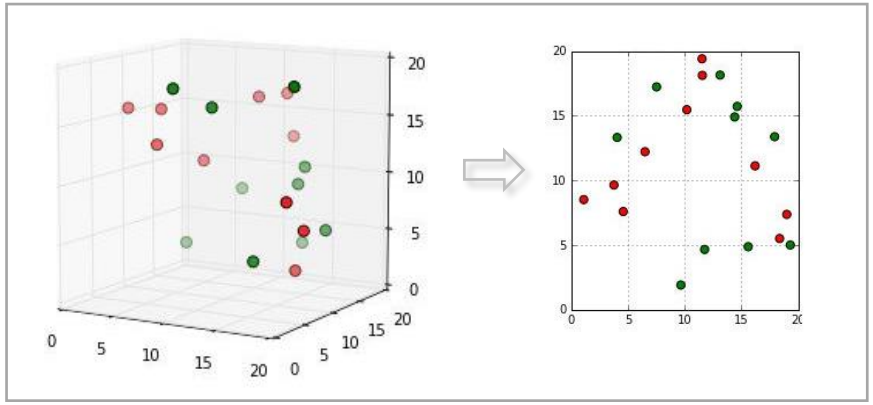

Reducción de la dimensionalidad

Tarea de agrupación

Problema: determinar perfiles o patrones de comportamiento con el fin de desarrollar campañas personalizadas

Productos frescos (gasto anual)	Productos lácteos (gasto anual)	Comestibles (gasto anual)	Congelados (gasto anual)	Papel_detergentes (gasto anual)	Delicateses (gasto anual)
12669	9656	7561	214	2674	1338
7057	9810	9568	1762	3293	1776
6353	8808	7684	2405	3516	7844
13265	1196	4221	6404	507	1788
22615	5410	7198	3915	1777	5185
9413	8259	5126	666	1795	1451
12126	3199	6975	480	3140	545
7579	4956	9426	1669	3321	2566
5963	3648	6192	425	1716	750
6006	11093	18881	1159	7425	2098
3366	5403	12974	4400	5977	1744
13146	1124	4523	1420	549	497
31714	12319	11757	287	3881	2931
21217	6208	14982	3095	6707	602
24653	9465	12091	294	5058	2168
10253	1114	3821	397	964	412
1020	8816	12121	134	4508	1080

Algoritmo de agrupación → **Modelo de agrupación** →

Grandes compradores de productos frescos

Compradores de productos lácteos, comestibles y delicateses.

Compradores de productos congelados, papel y detergentes

Por refuerzo

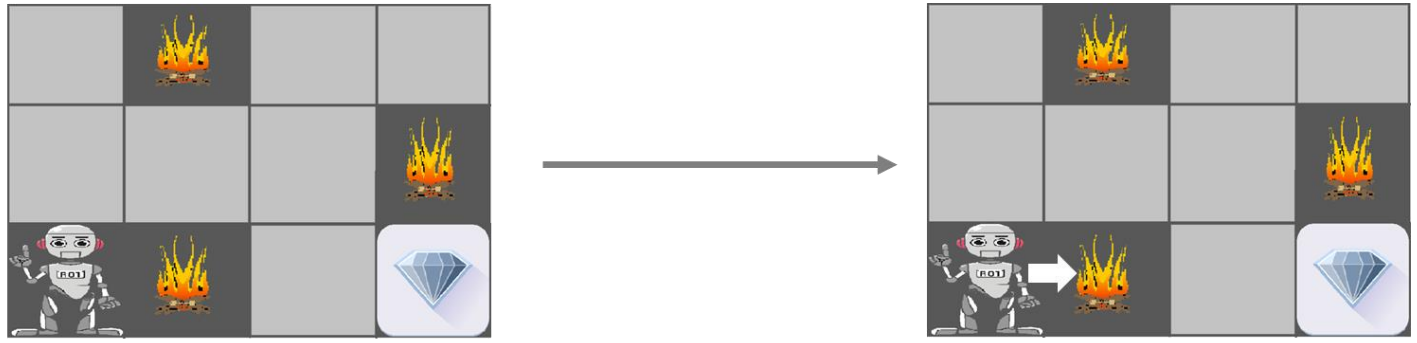

1. Observa el ambiente.
2. Selecciona una acción siguiendo una política. Por ejemplo, ir a la derecha.

3. Ejecuta la acción
4. Obtiene una recompensa o penalización. En este caso, una penalización.
5. Actualiza la política (paso de aprendizaje).

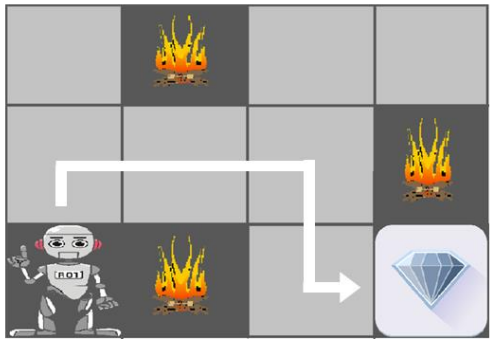

Estos pasos se repiten hasta que se aprenda la mejor estrategia.

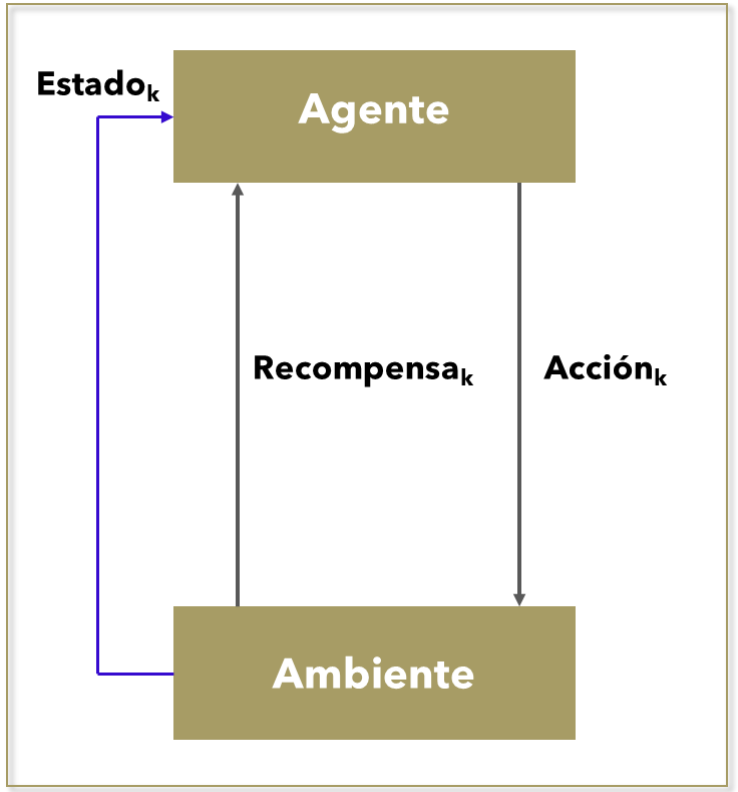

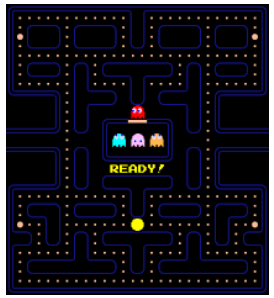

Elementos de un sistema de aprendizaje

Objetivo: desarrollar un modelo de clasificación que, para un nuevo dato caracterizado por los valores de ancho y longitud de sépalo, y ancho y longitud de pétalo, realice una predicción sobre el tipo de planta Iris más probable (Iris-setosa, Iris-virginica o Iris-versicolor).

LongitudSépalo	AnchoSépalo	LongitudPétalo	AnchoPétalo	Clase
4.3	3,0	1.1	0.1	Iris-setosa
4.8	3,0	1.4	0.1	Iris-setosa
4.9	3.1	1.5	0.1	Iris-setosa
4.9	3.1	1.5	0.1	Iris-setosa
4.9	3.1	1.5	0.1	Iris-setosa
⋮				
6.3	2.5	4.9	1.5	Iris-versicolor
6.9	3.1	4.9	1.5	Iris-versicolor
6,0	3.4	4.5	1.6	Iris-versicolor
6.3	3.3	4.7	1.6	Iris-versicolor
6,0	2.7	5.1	1.6	Iris-versicolor
⋮				
6.5	3,0	5.5	1.8	Iris-virginica
6.4	3.1	5.5	1.8	Iris-virginica
6.3	2.9	5.6	1.8	Iris-virginica
6.7	2.5	5.8	1.8	Iris-virginica
7.2	3.2	6,0	1.8	Iris-virginica

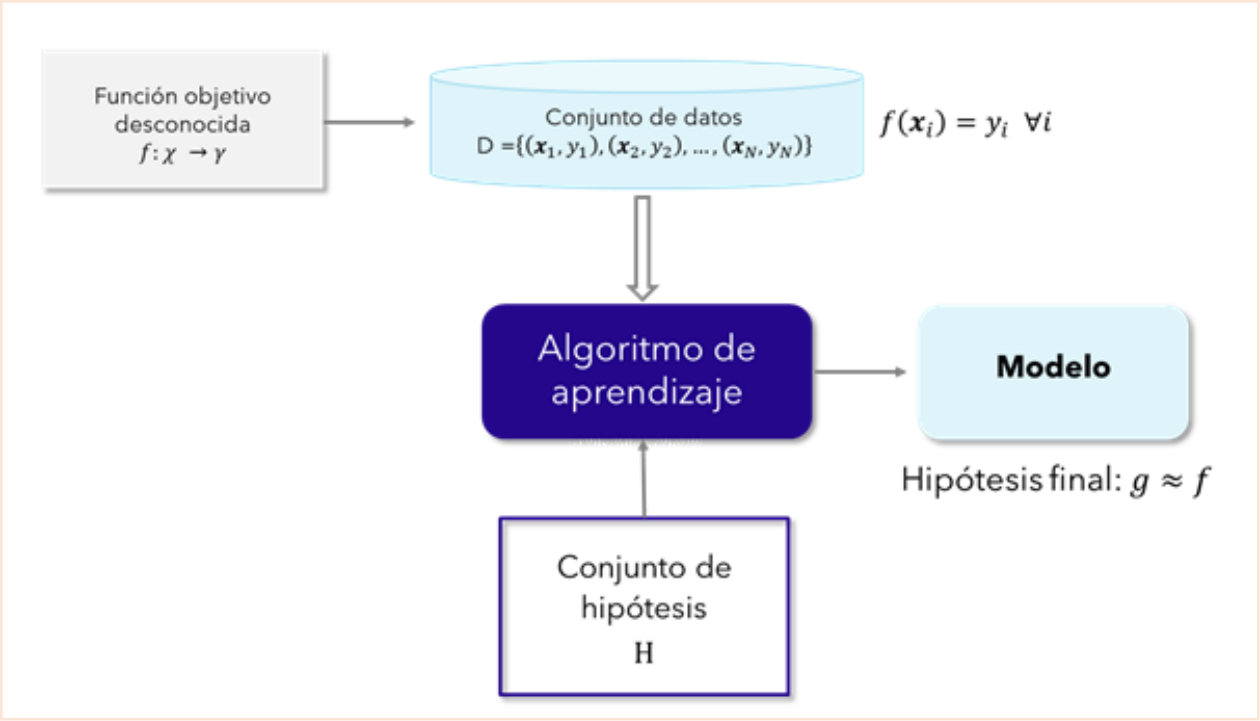

- *Función objetivo*: fórmula fundamental $f\colon X \rightarrow Y$, que relaciona las dimensiones del pétalo y sépalo (espacio X) con el tipo planta Iris (espacio Y).
- *Conjunto de datos*: conjunto de registros $(\boldsymbol{x_i}, y_i)_{i=1..150}$, asociados a plantas que han sido identificadas por los expertos, tal que $f(\boldsymbol{x_i}) = y_i$.
- *Algoritmo de aprendizaje*: procedimiento para estimar, a partir del conjunto de datos, el modelo que aproxima a f. Implícitamente selecciona una hipótesis del conjunto H.
- *Conjunto de hipótesis*: Conjunto de todas las hipótesis candidatas. Por ejemplo, puede ser el conjunto de todas las funciones lineales.
- *Hipótesis final*: modelo g que aproxima a f, es decir, $g \approx f$.

Algoritmo de aprendizaje

Mecanismo de aprendizaje

Lenguaje de representación

Clase de hipótesis H, definida sobre un conjunto de parámetros *ajustables* Ω

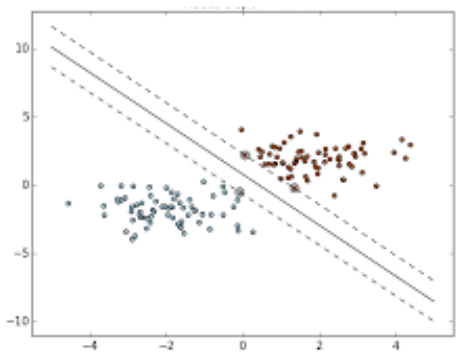

Basados en funciones lineales

$$P(C_1|X) = \frac{P(X|C_1)P(C_1)}{P(X)}$$

$$P(C_2|X) = \frac{P(X|C_2)P(C_2)}{P(X)}$$

$$\vdots$$

$$P(C_k|X) = \frac{P(X|C_k)P(C_k)}{P(X)}$$

Basados en probabilidades

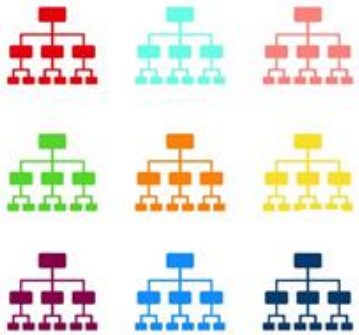

Basadas en combinación de modelos

Máquinas de vectores de soporte
Regresión logística, …

Naïve Bayes, …

Random Forest
Gradient Boosting ….

C4.5
CART,…

RIPPER,…

Perceptron multicapa (MLP),…

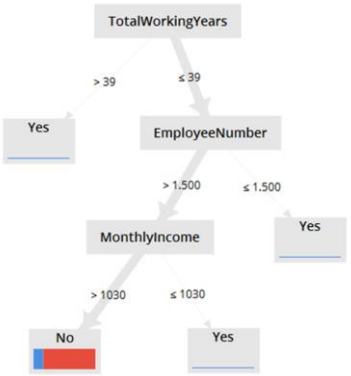

Basados en árboles

```
If Astigmatismo = No
  and ProducciónLágrimas = Normal
  and Prescipción = Hipermetropia then Blandos
If Astigmatismo = No
  and ProducciónLágrimas = normal
  and Edad = Joven then Blandos
If Edad = Pre-presbicia
  and Astigmatismo = No
  and ProducciónLágrimas = Normal then Blandos
If Astigmatismo = Si
  and ProducciónLágrimas = Normal
  and Prescipción = Miopia then Duros
If Edad = Joven
  and Astigmatismo = Si
  and ProducciónLágrimas = Normal then Duros
If ProducciónLágrimas = Reducida then Ninguno
If Edad = Presbicia
  and ProducciónLágrimas = Normal
  and Prescipción = Miopia
  and Astigmatismo = No then Ninguno
If Prescipción = Hipermetropía
  and Astigmatismo = Si
  and Edad = Pre-Presbicia then Ninguno
If Edad = Presbicia
  and Prescipción = Hipermetropía
  and Astigmatismo = Si then Ninguno
```

Basados en reglas

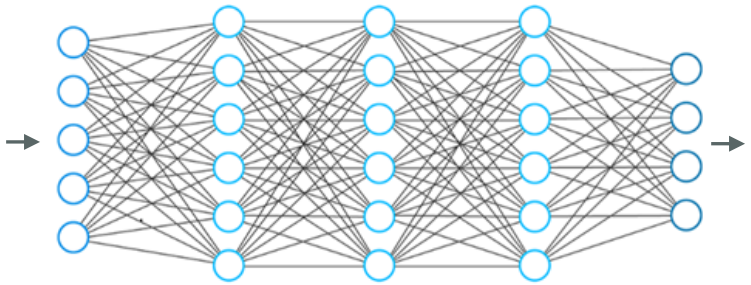

Redes neuronales

LongitudSépalo	AnchoSépalo	LongitudPétalo	AnchoPétalo	Clase
4.3	3,0	1.1	0.1	Iris-setosa
4.8	3,0	1.4	0.1	Iris-setosa
4.9	3.1	1.5	0.1	Iris-setosa
4.9	3.1	1.5	0.1	Iris-setosa
4.9	3.1	1.5	0.1	Iris-setosa
⋮				
6.3	2.5	4.9	1.5	Iris-versicolor
6.9	3.1	4.9	1.5	Iris-versicolor
6,0	3.4	4.5	1.6	Iris-versicolor
6.3	3.3	4.7	1.6	Iris-versicolor
6,0	2.7	5.1	1.6	Iris-versicolor
⋮				
6.5	3,0	5.5	1.8	Iris-virginica
6.4	3.1	5.5	1.8	Iris-virginica
6.3	2.9	5.6	1.8	Iris-virginica
6.7	2.5	5.8	1.8	Iris-virginica
7.2	3.2	6,0	1.8	Iris-virginica

Algoritmos basados en árboles de decisión. Ejemplo: C4.5

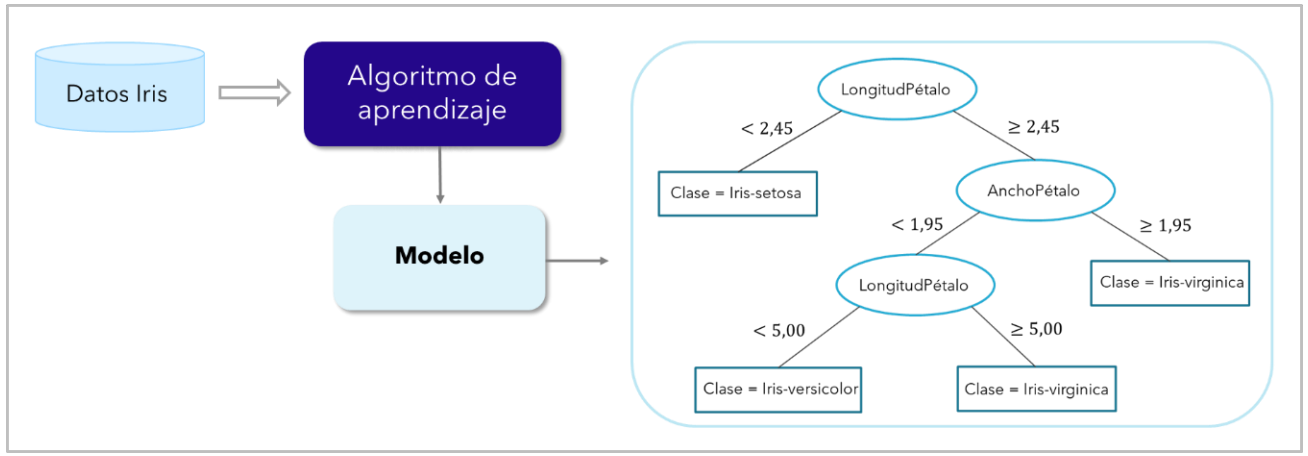

Algoritmos basados en reglas. Ejemplo: RIPPER

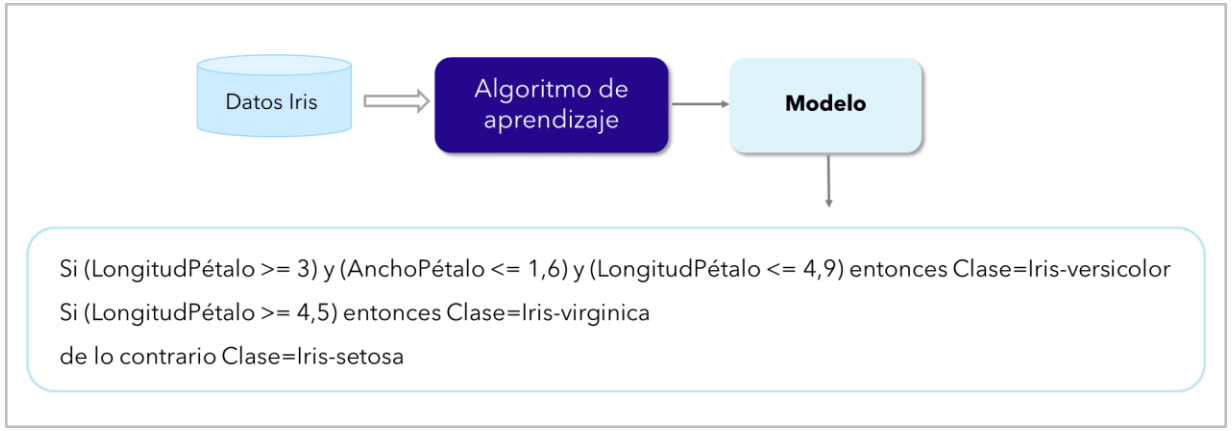

Algoritmos basados en funciones lineales. Ejemplo: Regresión logística

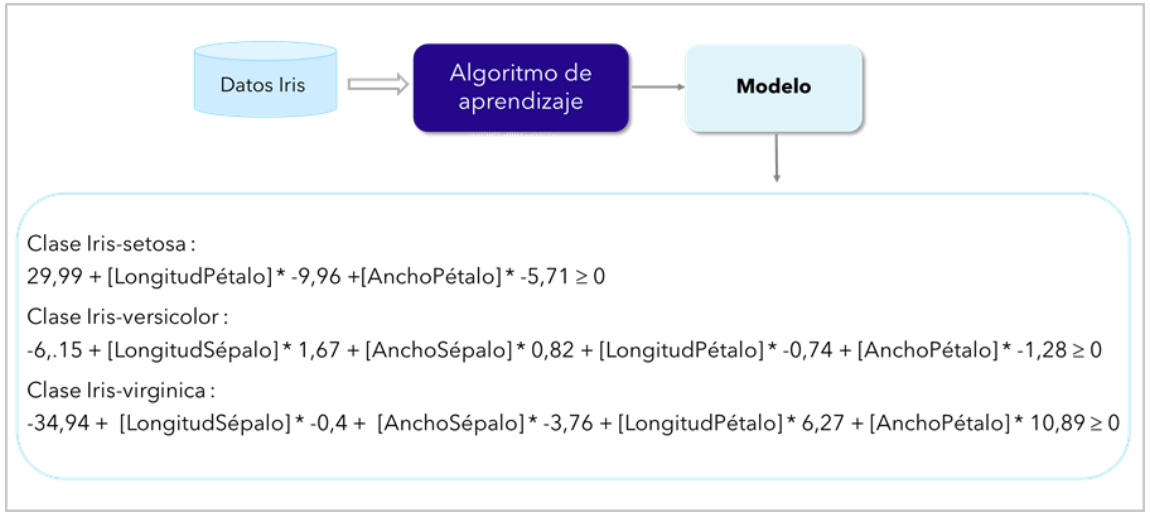

Algunos algoritmos supervisados:

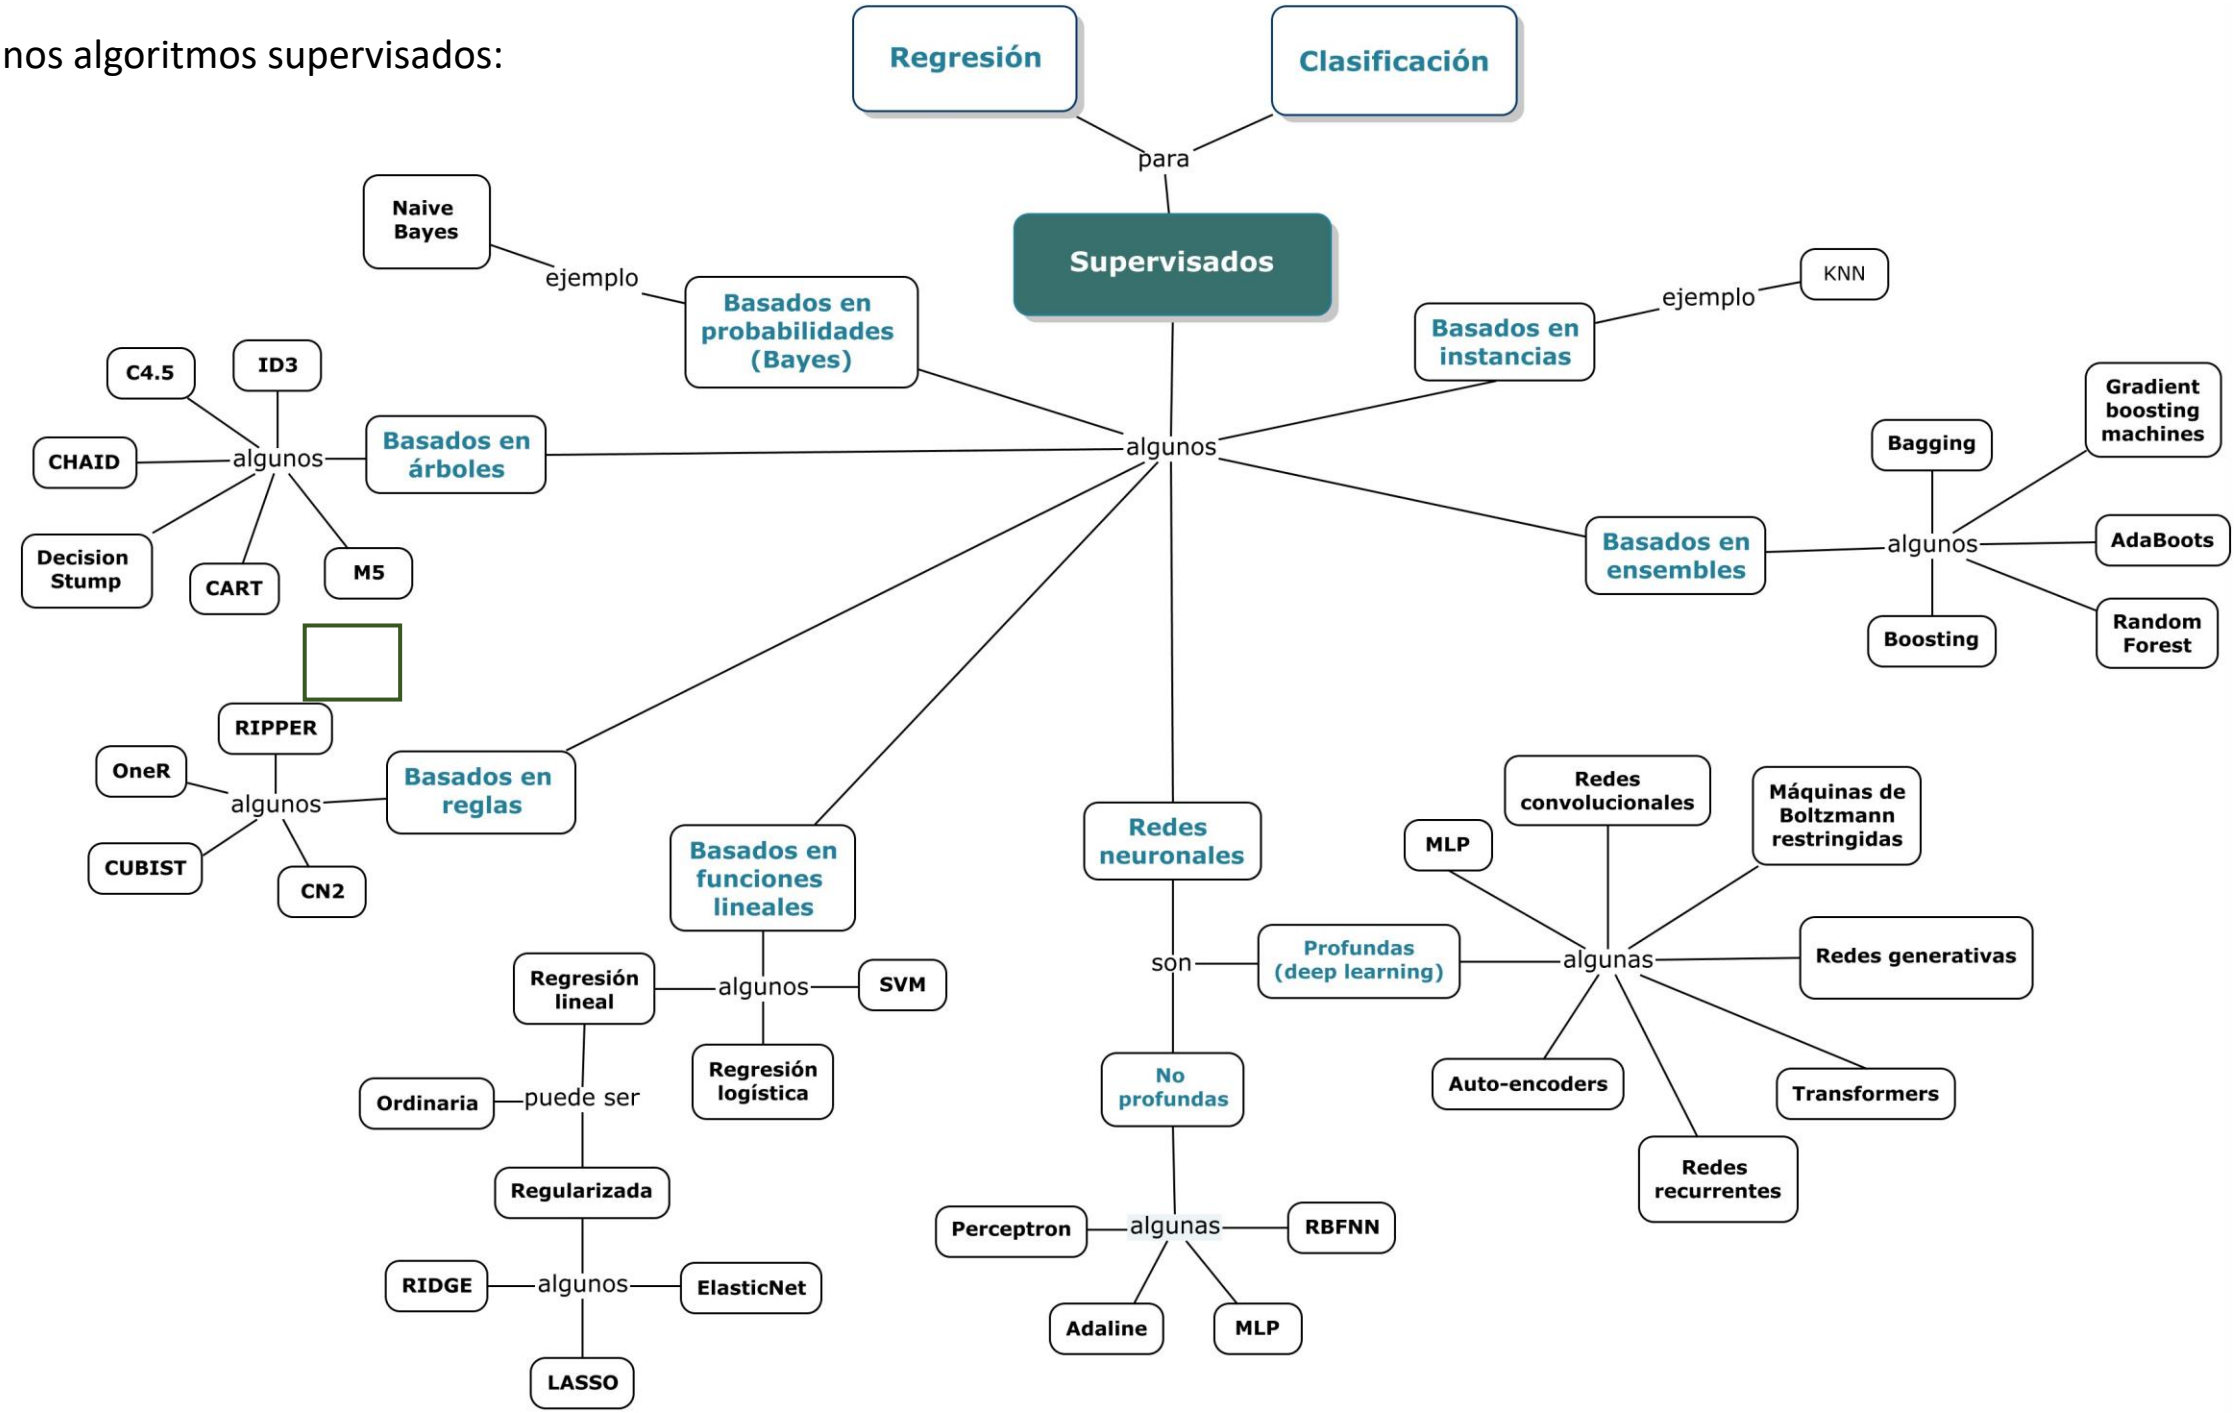

Algunos algoritmos no supervisados:

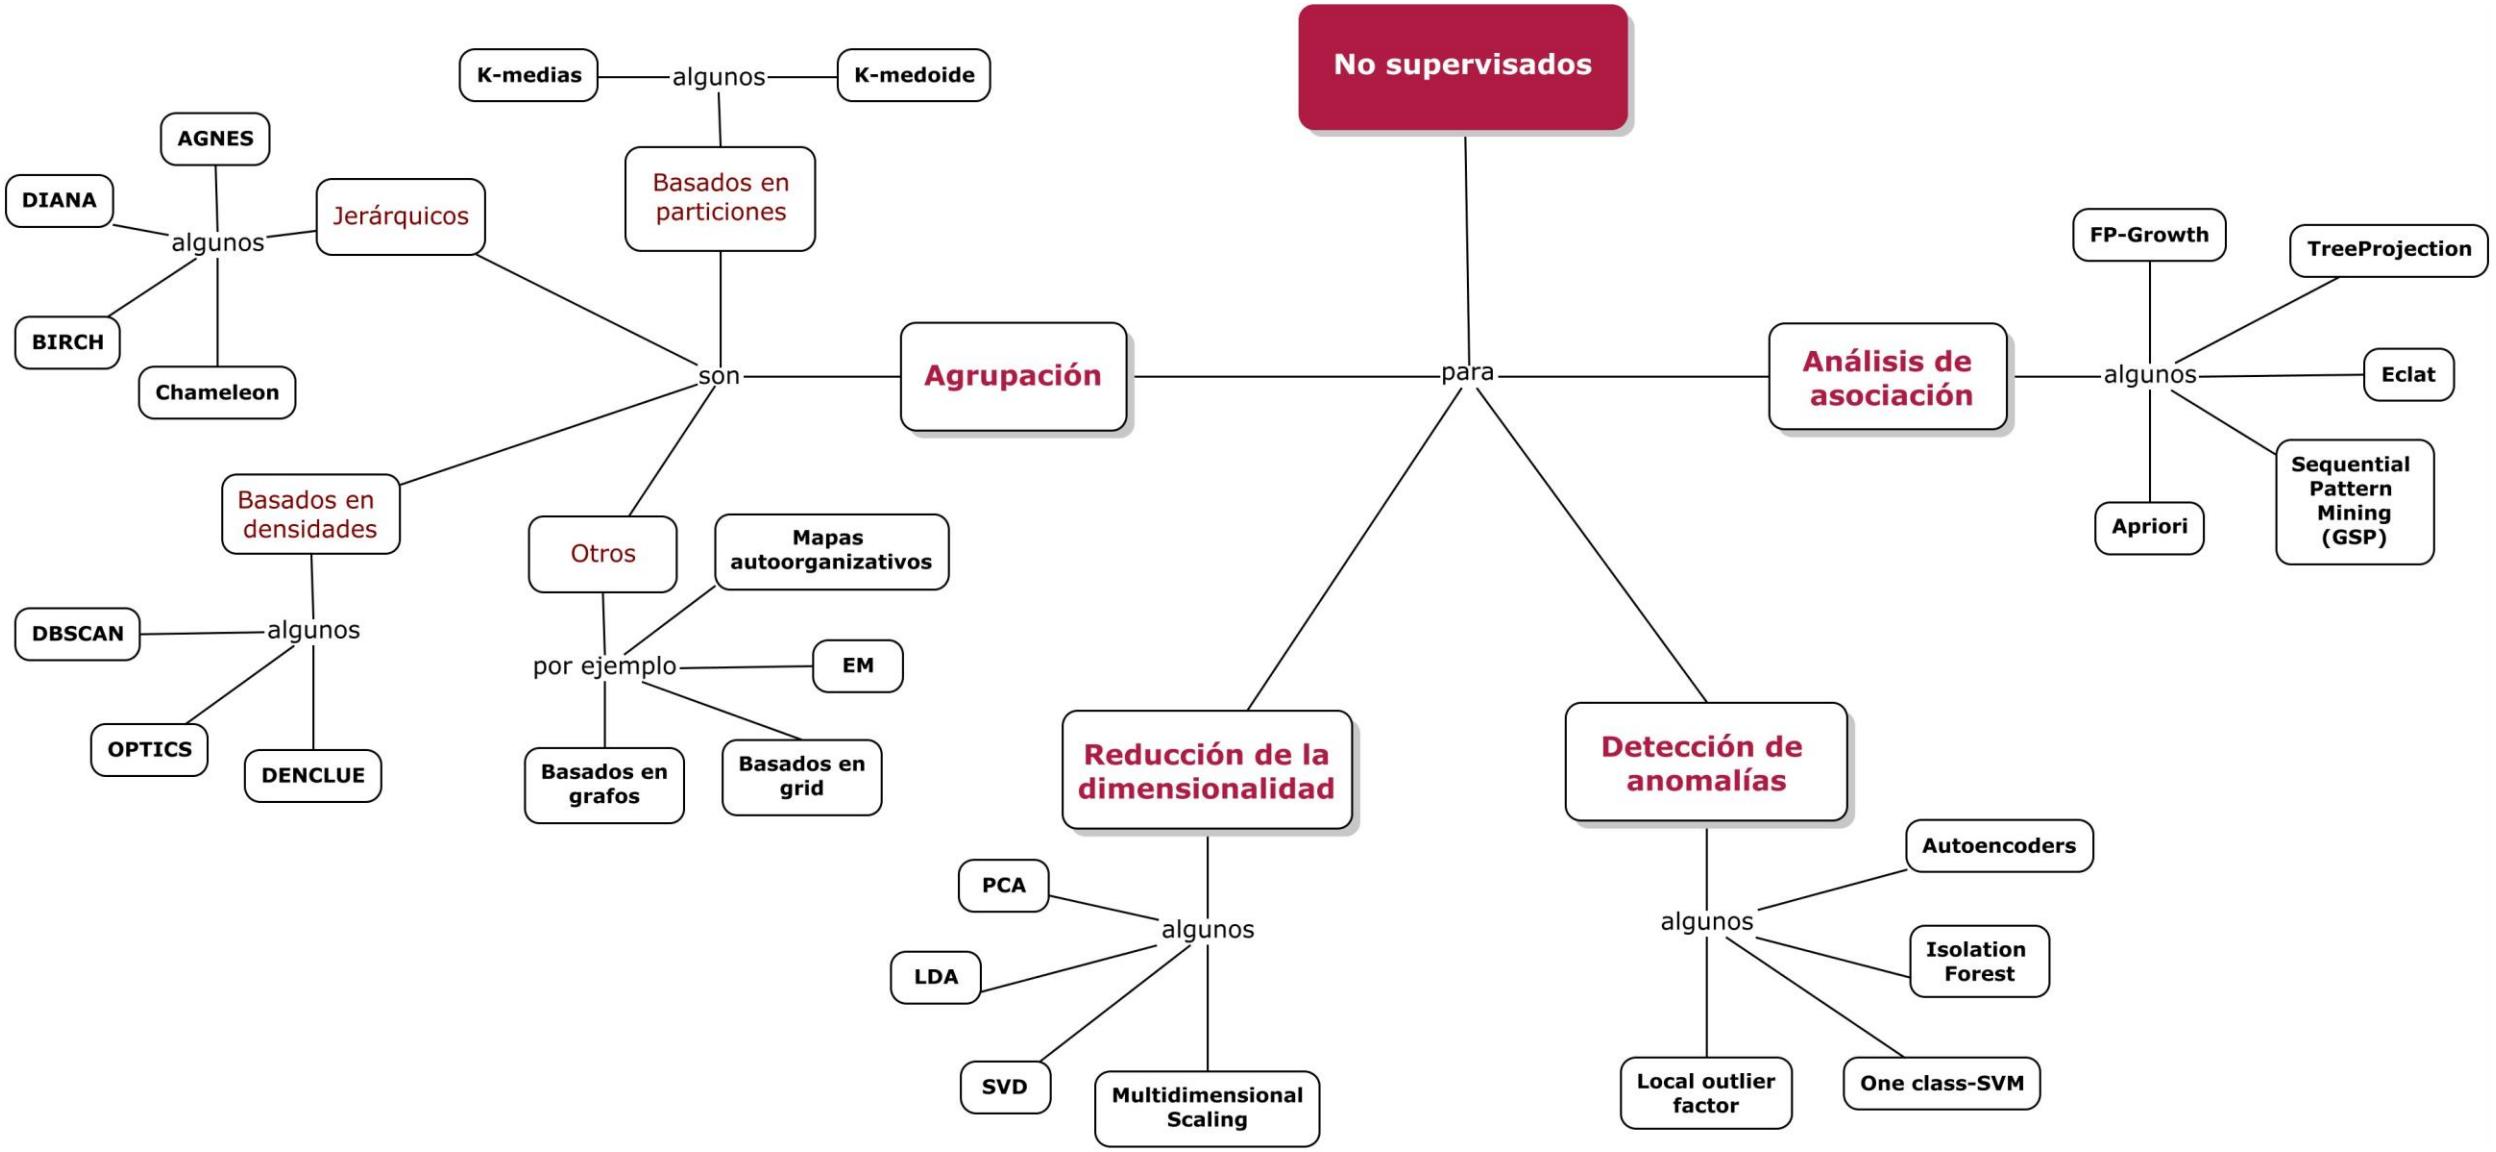

Ciclo de machine learning

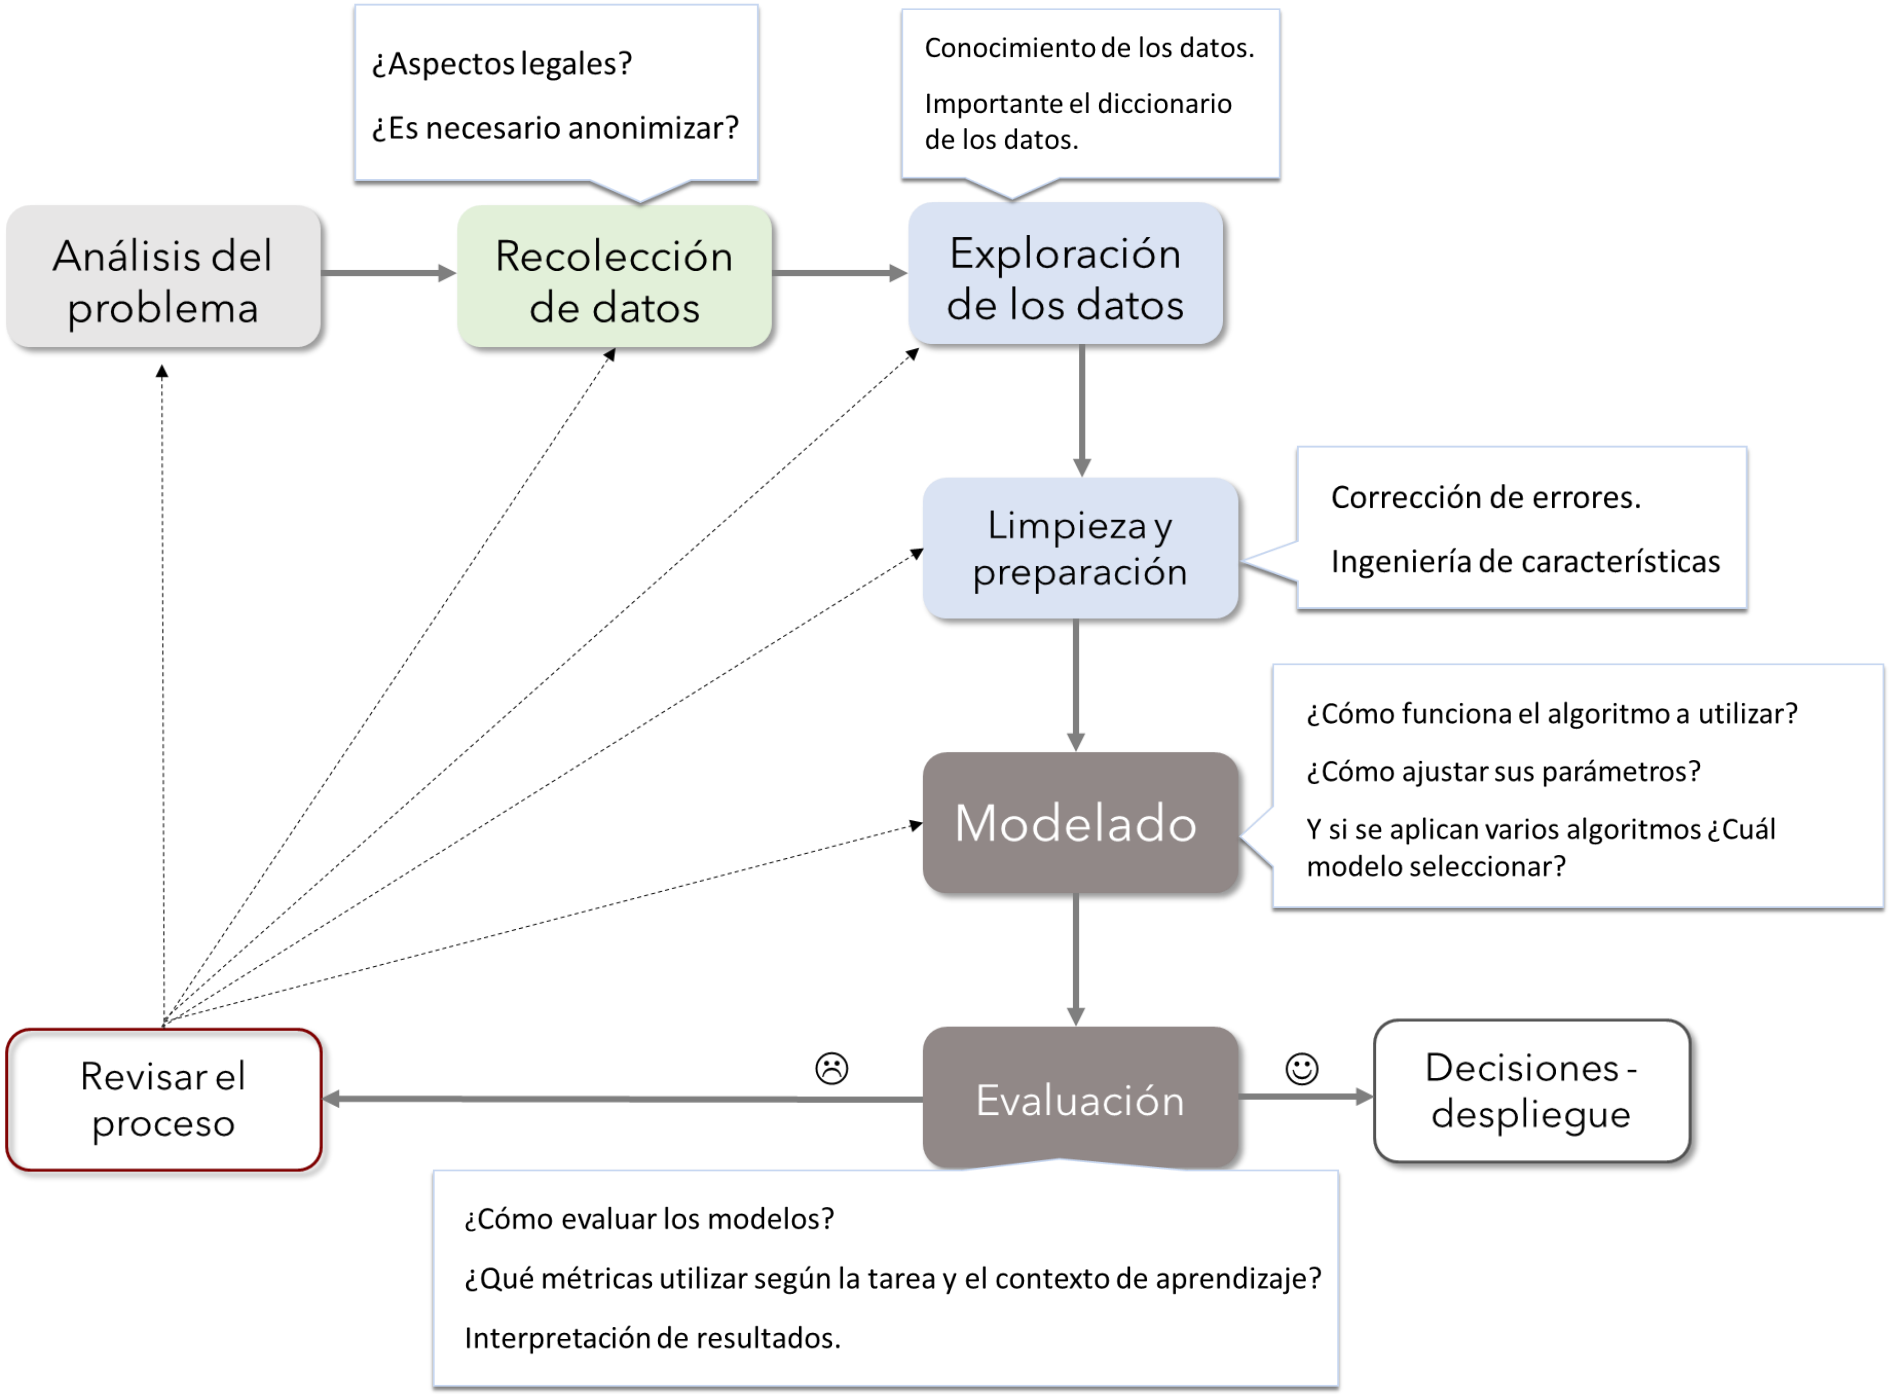

¿Cuáles sesgos se pueden presentar?

¿Implicaciones éticas del usos de datos?

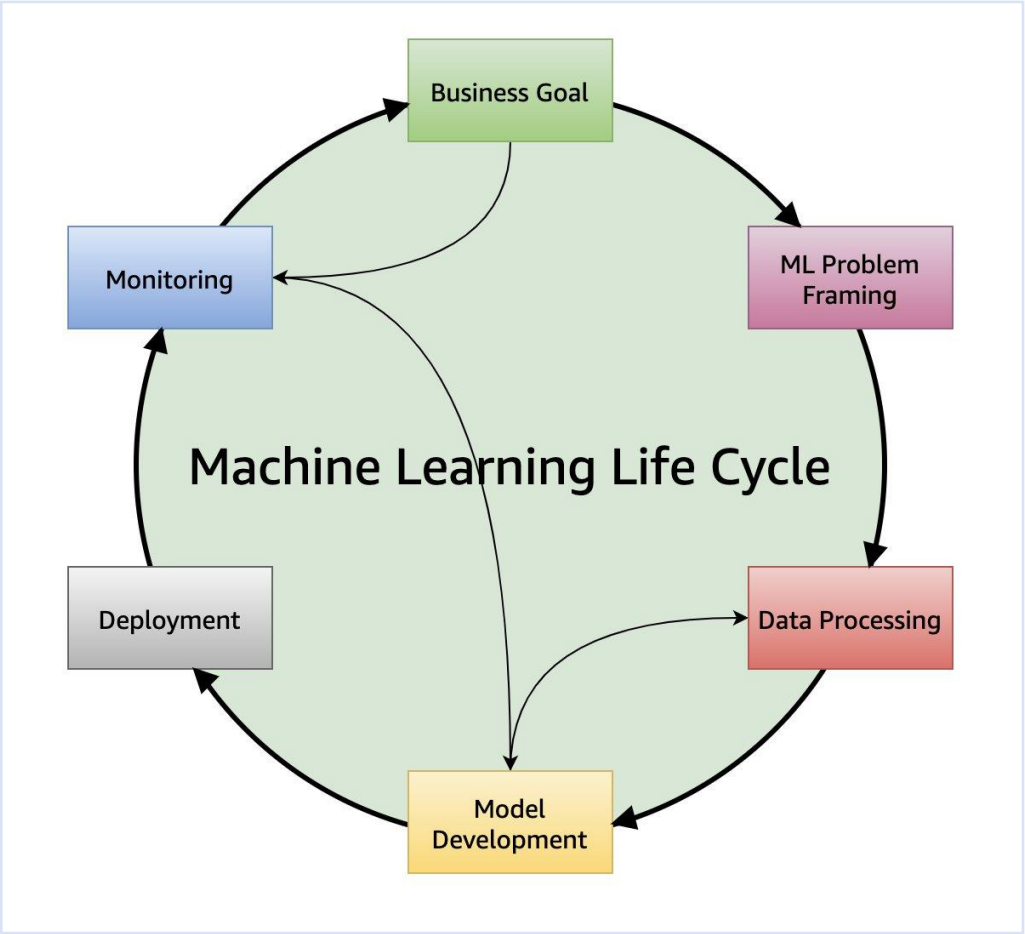

Well-Architected machine learning lifecycle

https://docs.aws.amazon.com/wellarchitected/latest/machine-learning-lens/well-architected-machine-learning-lifecycle.html

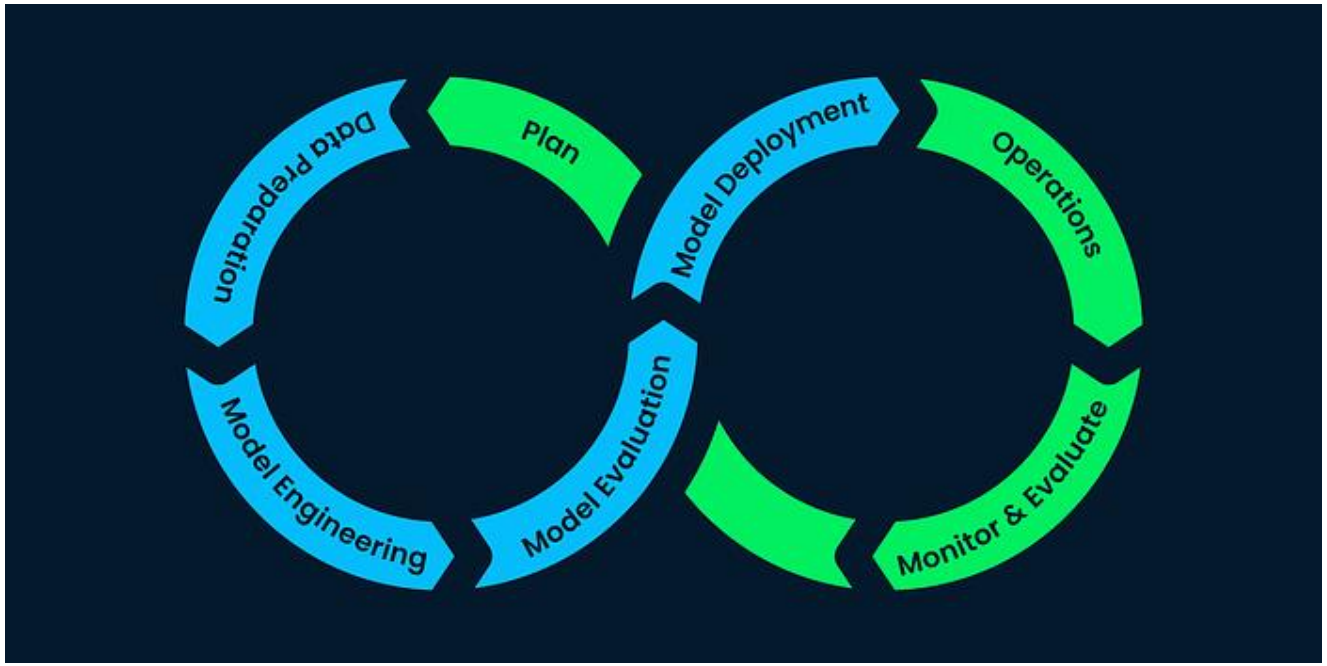

Navigating the Machine Learning Development Lifecycle: From Data to Deployment.

https://medium.com/@nay1228/navigating-the-machine-learning-development-lifecycle-from-data-to-deployment-fc603f5249e3

¿Cómo resolver una tarea de regresión?

¿Qué hace un algoritmo de aprendizaje para resolver la tarea de regresión?

El algoritmo, a partir de los datos, construye una función que al aplicarla a un vector de entrada $\boldsymbol{x}$ producirá como salida un estimado $\hat{y}$.

Esta función es el **modelo de regresión**.

Algunos algoritmos:

- Regresión lineal
- Regresión lasso y ridge
- Regresión polinomial
- Árboles de decisión para regresión
- Máquinas de vectores de soporte para regresión
- Redes neuronales para regresión
- Random Forest para regresión
- K-vecinos más cercanos para regresión, …

x_1	x_2	.....	x_d	y
⋮				

$\hat{y}$

Algoritmo de regresión

$$g: X \rightarrow Y / g(\boldsymbol{x}) = \hat{y}$$

$$\boldsymbol{x} = (x_1, x_2, x_3, \dots, x_d)$$

Objetivo: que el estimado $\hat{y}$ se aproxime al valor real tanto como sea posible.

$$\hat{y} \cong y$$

Como ejemplo se abordará un problema relacionado con la predicción de precios de ventas de vehículos usados. Para las empresas del sector sería de gran utilidad contar con un modelo predictivo que les permita estimar precios con base en las características del vehículo y que les ayude a conocer cuáles son los factores que más inciden en este. Se trata de un caso de uso general que aplica para cualquier tipo de producto.

Análisis del problema

Compresión del negocio

¿Modelo de negocio? ¿Cuál es el problema? ¿Situación actual? ¿Cómo el negocio resuelve el problema? ¿Enfoque analítico (tarea de ML)? ¿Cómo evaluar los resultados? ¿Rendimientos de referencia? ¿Requisitos de los datos? ¿Fuentes de datos?

Recolección de los datos

Verificar aspectos legales.

Se obtienen los datos de las fuentes de información que hayan sido seleccionadas.

Garantizar que se anonimiza o elimina la información confidencial o protegida, en caso de ser necesario.

Para las empresas del sector sería de gran utilidad contar con una aplicación que les permita estimar precios con base en las características del vehículo y que les ayude a conocer cuáles son los factores que más inciden en este.

Actualmente, el proceso de estimación de precios se basa en una inspección que requiere tiempo y experticia.

La empresa tiene datos relacionados con ventas que se han realizado en el último año. Una exploración inicial de estos datos muestra que hay en total 8128 registros, caracterizados por un conjunto de variables entre las cuales se encuentra el precio de venta.

Objetivo de ML: desarrollar un modelo de **regresión**. Se utilizará en primera instancia la regresión lineal, ya que permite una interpretación del modelo mediante el análisis de los coeficientes de regresión. También es posible utilizar librerías para este propósito.

Datos

referencia	modelo	precio	kilometraje	combustible	propietario	motor	poder_maximo	asientos
Maruti Swift Dzire VDI	2014	450000	145500	Diesel	First Owner	1248	74	5.0
Skoda Rapid 1.5 TDI Ambition	2014	370000	120000	Diesel	Second Owner	1498	103.52	5.0
Honda City 2017-2020 EXi	2006	158000	140000	Petrol	Third Owner	1497	78	5.0
Hyundai i20 Sportz Diesel	2010	225000	127000	Diesel	First Owner	1396	90	5.0
Maruti Swift VXI BSIII	2007	130000	120000	Petrol	First Owner	1298		5.0
Hyundai Xcent 1.2 VTVT E Plus	2017	440000	45000	Petrol	First Owner	1197	81.86	50
Maruti Wagon R LXI DUO BSIII	2007	96000	175000	LPG	First Owner	1061	57.5	5.0
Maruti 800 DX BSII	2001	45000	5000	Petrol	Second Owner	796000	37	4.0
Toyota Etios VXD	2011	350000	90000	Diesel	First Owner	1364	67.1	5.0
Ford Figo Diesel Celebration Edition	2013	200000	169000	Diesel	First Owner	1399	68.1	5.0

Número de datos: 8128

Algoritmo de regresión

Modelo de regresión

Precio

Maruti Omni E MPI STD BS IV	2018	25000	Petrol	First Owner	796	34.2	8.0

Exploración de los datos

Compresión de los datos

referencia	modelo	precio	kilometraje	combustible	propietario	motor	poder_maximo	asientos
Maruti Swift Dzire VDI	2014	450000	145500	Diesel	First Owner	1248	74	5.0
Skoda Rapid 1.5 TDI Ambition	2014	370000	120000	Diesel	Second Owner	1498	103.52	5.0
Honda City 2017-2020 EXi	2006	158000	140000	Petrol	Third Owner	1497	78	5.0
Hyundai i20 Sportz Diesel	2010	225000	127000	Diesel	First Owner	1396	90	5.0
Maruti Swift VXI BSIII	2007	130000	120000	Petrol	First Owner	1298		5.0
Hyundai Xcent 1.2 VTVT E Plus	2017	440000	45000	Petrol	First Owner	1197	81.86	50
Maruti Wagon R LXI DUO BSIII	2007	96000	175000	LPG	First Owner	1061	57.5	5.0
Maruti 800 DX BSII	2001	45000	5000	Petrol	Second Owner	796000	37	4.0
Toyota Etios VXD	2011	350000	90000	Diesel	First Owner	1364	67.1	5.0
Ford Figo Diesel Celebration Edition	2013	200000	169000	Diesel	First Owner	1399	68.1	5.0
Renault Duster 110PS Diesel RxL	2014	500000	68000	Diesel	Second Owner	1461	108.45	5.0
Maruti Zen LX	2005	92000	100000	Petrol	Second Owner	993	60	5.0
Maruti Swift Dzire VDi	2009	280000	140000	Diesel	Second Owner	1248	73.9	5.0
Maruti Swift 1.3 VXi	2007	200000		Petrol	Second Owner			
Maruti Wagon R LXI Minor	2009	180000	90000	Petrol	Second Owner	1061	67	5.0
Mahindra KUV 100 mFALCON G80 K8 5str	2016	400000	40000	Petrol	First Owner	1198	82	5.0
Maruti Ertiga SHVS VDI	2016	778000	70000	Diesel	Second Owner	1248	88.5	7.0
Hyundai i20 1.4 CRDi Asta	2012	500000	53000	Diesel	Second Owner	1396	90	5.0
Maruti Alto LX	2002	150000	80000	Petrol	Second Owner	796	46.3	5.0
Hyundai i20 2015-2017 Asta 1.4 CRDi	2016	680000	100000	Diesel	First Owner	1396	88.73	5.0
Mahindra Verito 1.5 D4 BSIII	2011	174000	100000	Diesel	Second Owner	1461	64.1	5.0
Honda WR-V i-DTEC VX	2017	950000	50000	Diesel	First Owner	1498	98.6	5.0
Maruti Swift Dzire ZDI	2015	525000	40000	Diesel	First Owner	1248	74	5.0
Maruti SX4 ZDI	2012	600000	72000	Diesel	First Owner	1248	88.8	5.0
Tata Tigor 2017-2020 XZ	2018	500000	35000	Petrol	First Owner	1199	83.81	5.0
Maruti Baleno Delta 1.2	2016	575000	45000	Petrol	First Owner	1197	83.1	5.0
Maruti Alto 800 LXI	2017	275000	28000	Petrol	First Owner	796	47.3	5.0
Chevrolet Enjoy TCDi LTZ 7 Seater	2013	300000	70000	Diesel	First Owner	1248	73.8	7.0
Maruti Wagon R LXI Minor	2009	220000	120000	Petrol	First Owner	1061	67	5.0
Maruti Omni E MPI STD BS IV	2018	254999	25000	Petrol	First Owner	796	34.2	8.0
Maruti Vitara Brezza LDi Option	2017	670000	70000	Diesel	First Owner	1248	88.5	5.0
Fiat Palio 1.2 ELX	2003	70000	50000	Petrol	Second Owner			

⋮

Es necesario el diccionario de los datos.

Con base en el diccionario y el análisis exploratorio:

Limpieza de los datos

Corrección de errores

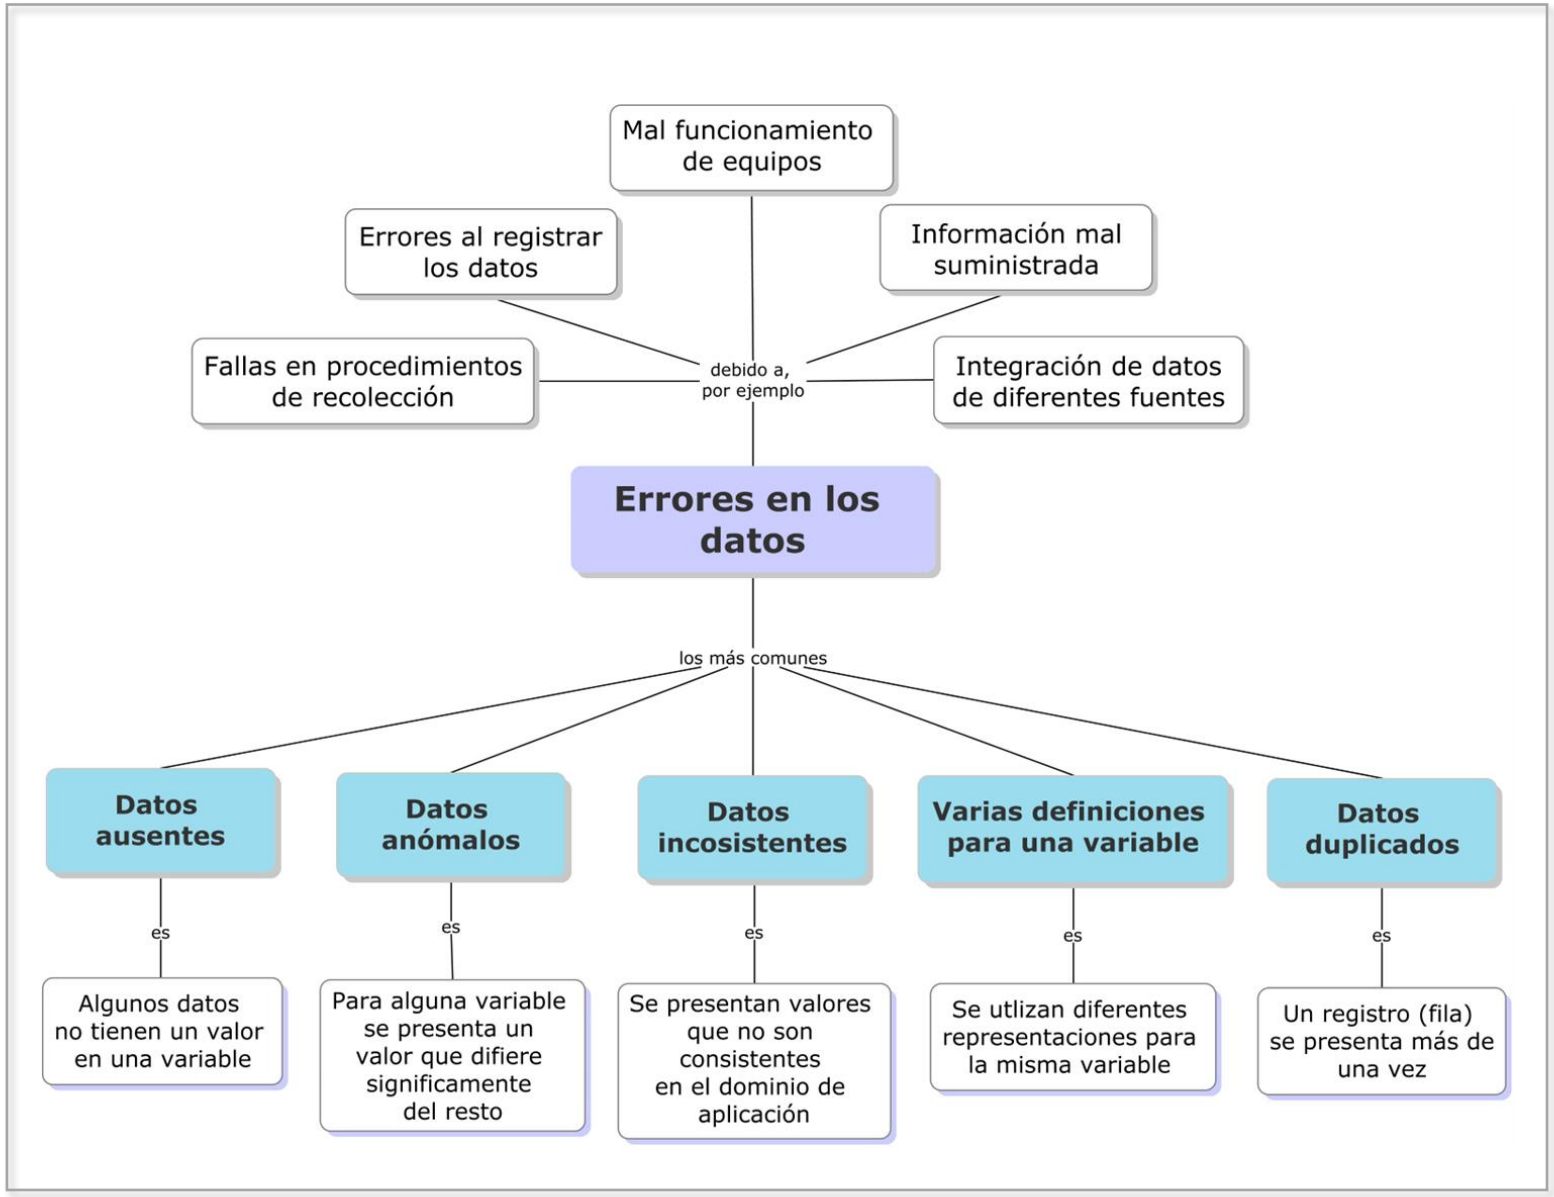

Decisiones:

Eliminación de registros con ausencias.

Corrección de datos anómalos en la variable “Asientos”.

Eliminación de registros con valores extremos en la variable “Motor”.

Eliminación de registros duplicados.

Preparación de los datos

Ingeniería de características

- El objetivo es mejorar la representación de los datos para los algoritmos de aprendizaje que se emplearán en el modelado.

- Para realizar esta tarea nos apoyamos en la ingeniería de características:

"…proceso de transformar los datos en características que representan mejor el problema subyacente, lo que permite mejorar el aprendizaje automático…" (Ozdemir y Susarla, 2018).

"… proceso de crear representaciones de los datos para incrementar la efectividad de un modelo…" (Kuhn y Johnson, 2020).

- Se trata entonces de aplicar un conjunto de técnicas que nos permitan construir una mejor representación de los datos, tomando en cuenta las características del problema bajo estudio y, a su vez, los requerimientos de entrada de los algoritmos de aprendizaje.

- Es importante que siempre tengas en cuenta que la forma de representar los datos puede tener un gran efecto en el rendimiento de los modelos que se generan.

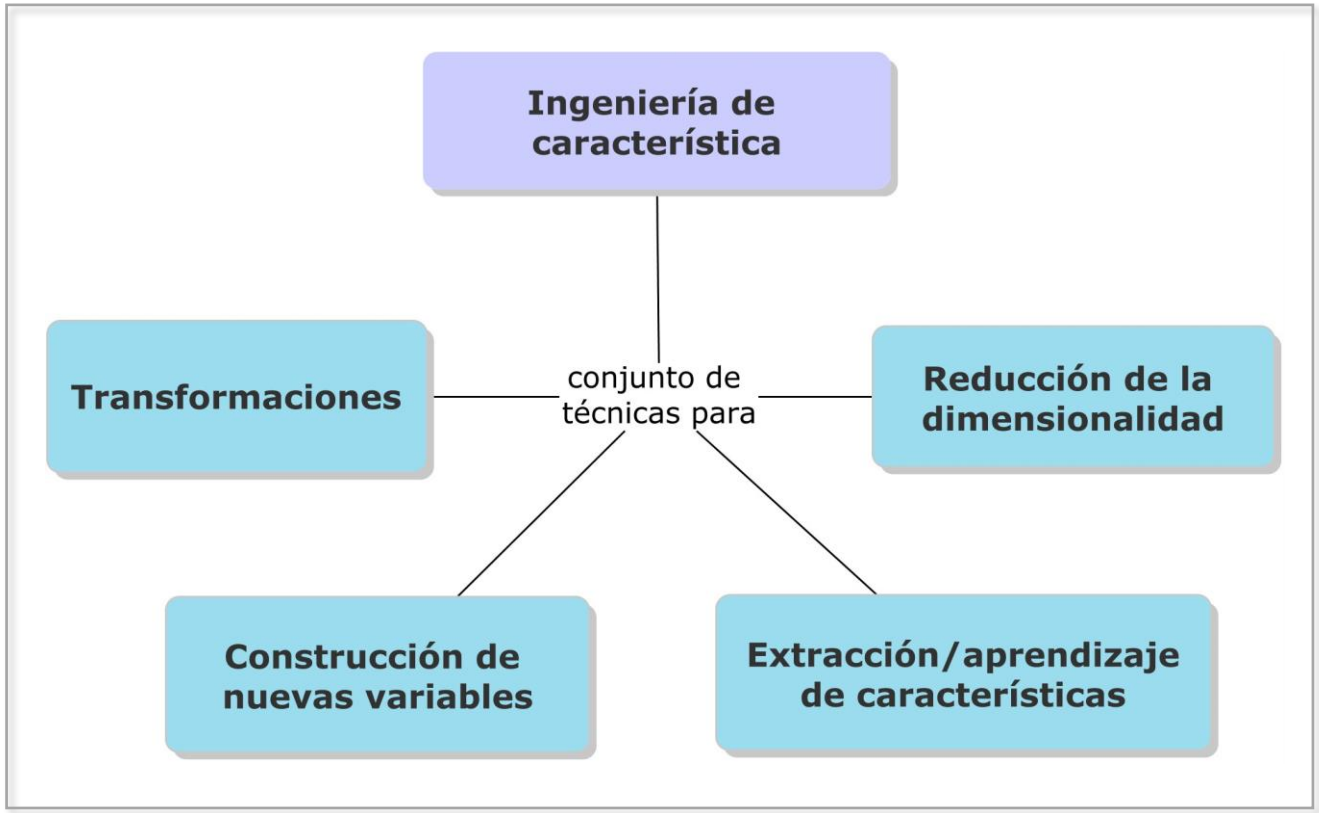

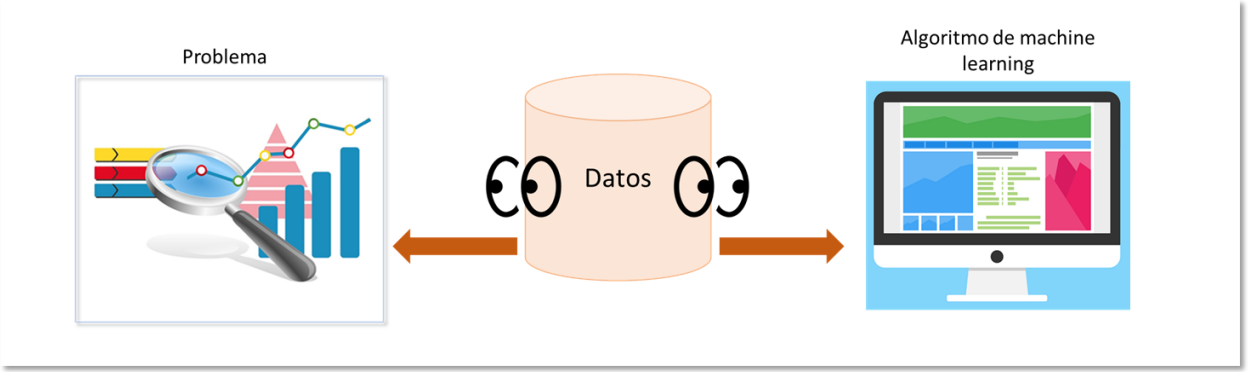

¡Buscar la mejor representación posible!

Decisiones:

Transformación one-hot para las variables categóricas “Combustible” y “Propietario”.

Además, se eliminó la variable “referencia” por tener una alta cardinalidad.

Resultado de la fase de preparación de datos:

modelo	precio	kilometraje	motor	poder_maximo	asientos	combustible_CNG	combustible_Diesel	combustible_LPG	combustible_Petrol	propietario_First Owner	propietario_Fourth & Above Owner	propietario_Second Owner	propietario_Test Drive Car	propietario_Third Owner
2014	450000	145500	1248.0	74.0	5.0	0	1	0	0	1	0	0	0	0
2014	370000	120000	1498.0	103.52	5.0	0	1	0	0	0	0	1	0	0
2006	158000	140000	1497.0	78.0	5.0	0	0	0	1	0	0	0	0	1
2010	225000	127000	1396.0	90.0	5.0	0	1	0	0	1	0	0	0	0
2007	130000	120000	1298.0	88.2	5.0	0	0	0	1	1	0	0	0	0
2017	440000	45000	1197.0	81.86	5.0	0	0	0	1	1	0	0	0	0
2007	96000	175000	1061.0	57.5	5.0	0	0	1	0	1	0	0	0	0
2001	45000	5000	796.0	37.0	4.0	0	0	0	1	0	0	1	0	0
2011	350000	90000	1364.0	67.1	5.0	0	1	0	0	1	0	0	0	0
2013	200000	169000	1399.0	68.1	5.0	0	1	0	0	1	0	0	0	0
2014	500000	68000	1461.0	108.45	5.0	0	1	0	0	0	0	1	0	0
2005	92000	100000	993.0	60.0	5.0	0	0	0	1	0	0	1	0	0
2009	280000	140000	1248.0	73.9	5.0	0	1	0	0	0	0	1	0	0
2009	180000	90000	1061.0	67.0	5.0	0	0	0	1	0	0	1	0	0
2016	400000	40000	1198.0	82.0	5.0	0	0	0	1	1	0	0	0	0
2016	778000	70000	1248.0	88.5	7.0	0	1	0	0	0	0	1	0	0
2012	500000	53000	1396.0	90.0	5.0	0	1	0	0	0	0	1	0	0
2002	150000	80000	796.0	46.3	5.0	0	0	0	1	0	0	1	0	0
2016	680000	100000	1396.0	88.73	5.0	0	1	0	0	1	0	0	0	0
2011	174000	100000	1461.0	64.1	5.0	0	1	0	0	0	0	1	0	0
2017	950000	50000	1498.0	98.6	5.0	0	1	0	0	1	0	0	0	0
2015	525000	40000	1248.0	74.0	5.0	0	1	0	0	1	0	0	0	0
2012	600000	72000	1248.0	88.8	5.0	0	1	0	0	1	0	0	0	0
2018	500000	35000	1199.0	83.81	5.0	0	0	0	1	1	0	0	0	0
2016	575000	45000	1197.0	83.1	5.0	0	0	0	1	1	0	0	0	0
2017	275000	28000	796.0	47.3	5.0	0	0	0	1	1	0	0	0	0
2013	300000	70000	1248.0	73.8	7.0	0	1	0	0	1	0	0	0	0
2009	220000	120000	1061.0	67.0	5.0	0	0	0	1	1	0	0	0	0
2018	254999	25000	796.0	34.2	8.0	0	0	0	1	1	0	0	0	0
2017	670000	70000	1248.0	88.5	5.0	0	1	0	0	1	0	0	0	0
2012	150000	35000	796.0	35.0	5.0	0	0	0	1	0	0	1	0	0

⋮

En regresión lineal:

Variable dependiente = y

modelo	precio	kilometraje	motor	poder_maximo	asientos	combustible_CNG	combustible_Diesel	combustible_LPG	combustible_Petrol	propietario_First Owner	propietario_Fourth & Above Owner	propietario_Second Owner	propietario_Test Drive Car	propietario_Third Owner
2014	450000	145500	1248.0	74.0	5.0	0	1	0	0	1	0	0	0	0
2014	370000	120000	1498.0	103.52	5.0	0	1	0	0	0	0	1	0	0
2006	158000	140000	1497.0	78.0	5.0	0	0	0	1	0	0	0	0	1
2010	225000	127000	1396.0	90.0	5.0	0	1	0	0	1	0	0	0	0
2007	130000	120000	1298.0	88.2	5.0	0	0	0	1	1	0	0	0	0
2017	440000	45000	1197.0	81.86	5.0	0	0	0	1	1	0	0	0	0
2007	96000	175000	1061.0	57.5	5.0	0	0	1	0	1	0	0	0	0
2001	45000	5000	796.0	37.0	4.0	0	0	0	1	0	0	1	0	0
2011	350000	90000	1364.0	67.1	5.0	0	1	0	0	1	0	0	0	0
2013	200000	169000	1399.0	68.1	5.0	0	1	0	0	1	0	0	0	0
2014	500000	68000	1461.0	108.45	5.0	0	1	0	0	0	0	1	0	0

Algoritmo de regresión → Modelo de regresión

$$\hat{y} = w_0 + w_1 \times modelo + w_2 \times kilometraje + \cdots + w_{14} \times propietario_ThirdOwner$$

Parámetros del modelo

Ejemplo: regresión lineal simple

$$precio\ estimado = \hat{y} = w_0 + w_1 \times kilometraje$$

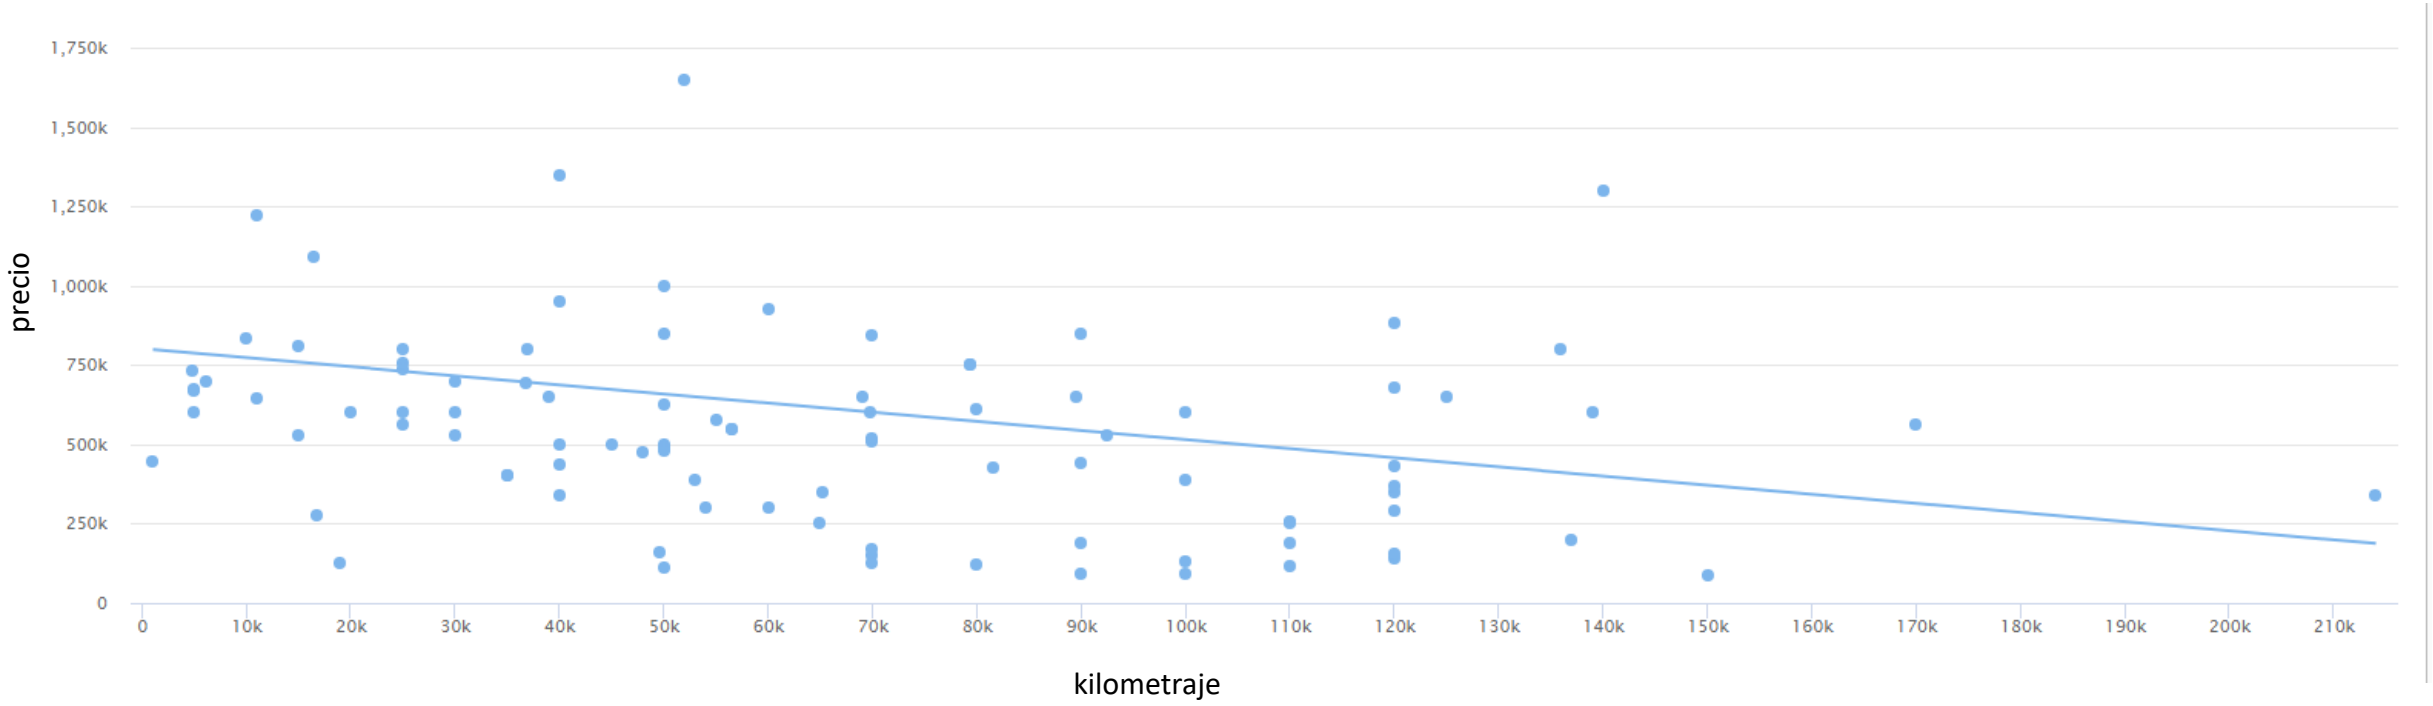

¿Cuántas soluciones existen?

Tomemos una solución…

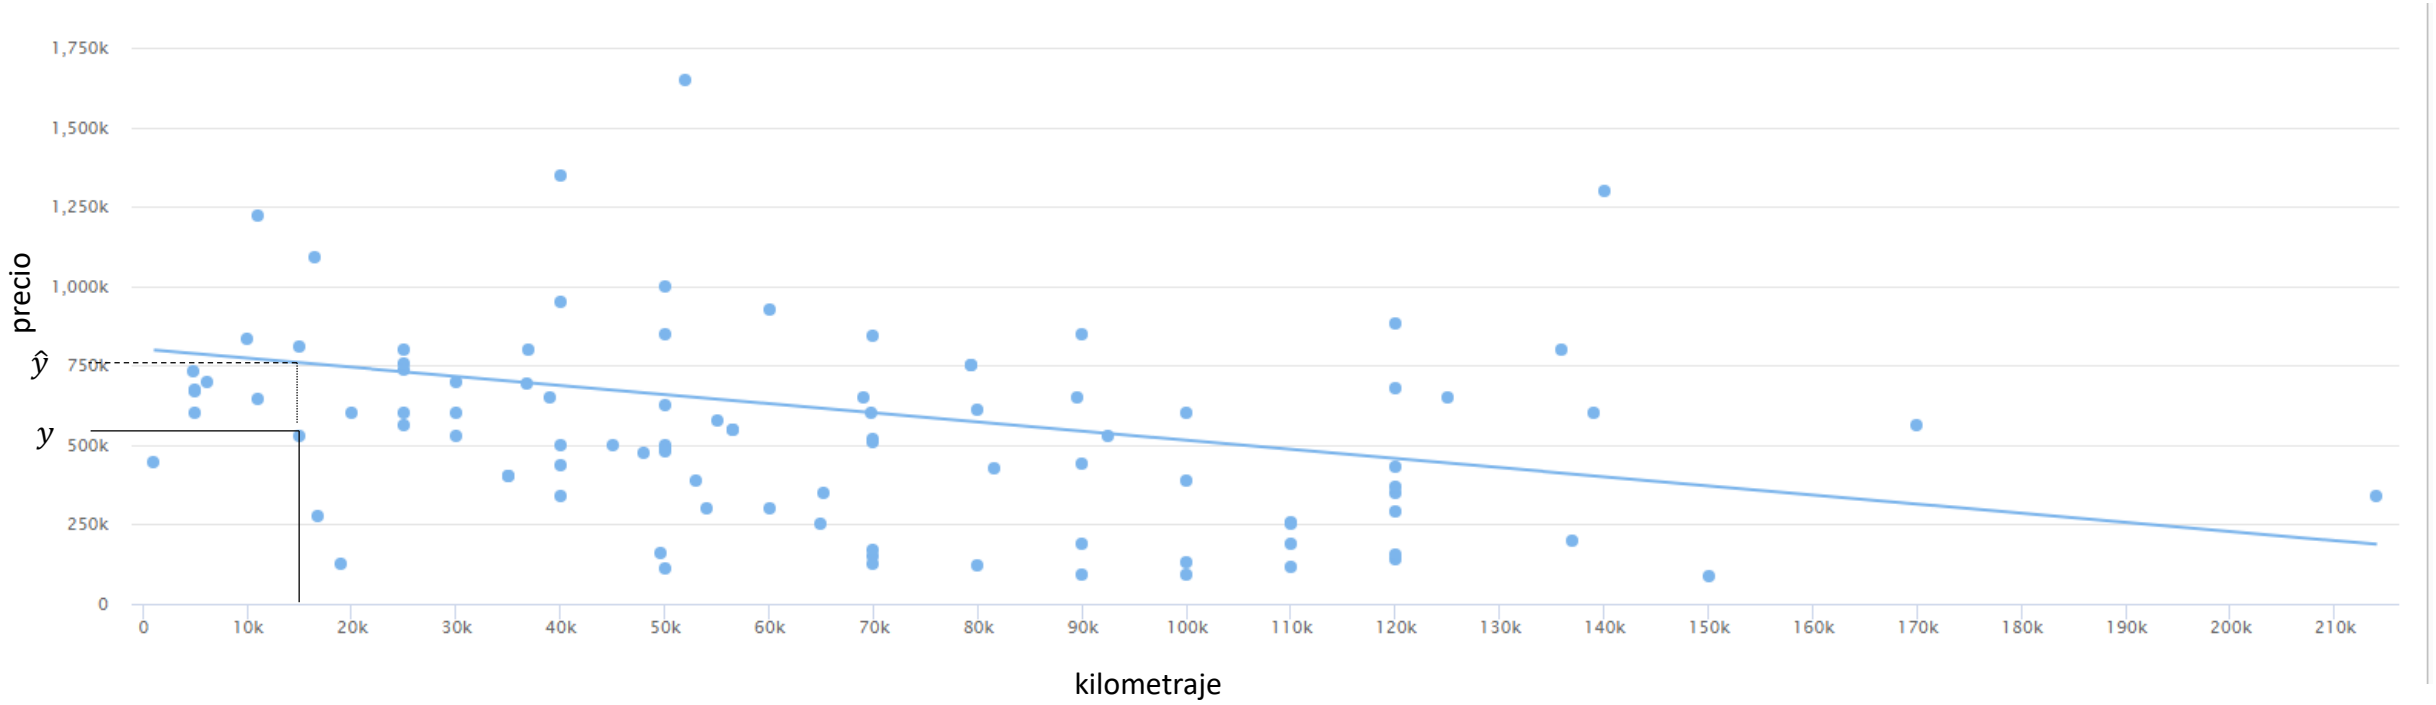

Para el dato: $(15000, 526000)$ la predicción que hace el modelo es:

$$\hat{y} = 750000 \quad \Rightarrow \quad error = (\hat{y} - y) = (750000 - 526000) = 224000$$

¿Cómo el algoritmo de aprendizaje selecciona la solución que mejor se ajusta a los datos?

Es decir, ¿cómo selecciona los valores de w_0 y w_1 que dan lugar a la recta de mejor ajuste?

$$Función\ de\ costo = \frac{1}{N}\sum_{i=1}^{N}(\widehat{y_i} - y_i)^2$$

<u>Función de costo</u>: mide la discrepancia entre lo que predice el modelo y el valor real (error) para todos los datos.

Para regresión la función más utilizada es el promedio de la suma de los errores al cuadrado o error cuadrático medio (MSE).

El valor de la función de costo depende de los parámetros del modelo (en este caso, w_0 y w_1)

$$Función\ de\ costo = \frac{1}{N}\sum_{i=1}^{N}(\widehat{y_i} - y_i)^2 = \boxed{\frac{1}{N}\sum_{i=1}^{N}\left((w_0 + w_1.x_i) - y_i\right)^2}$$

Algoritmo de aprendizaje

Objetivo: determinar los valores de los parámetros W que minimizan la función de costo. Esta función mide la discrepancia entre lo que predice el modelo y el valor real, para cada instancia del conjunto de datos.

☞ Solución analítica

Comienzo_procedimiento

Construir la matriz $\boldsymbol{X}$ *a partir de los datos*

Calcular la pseudo-inversa X^{+} *de la matriz* X =

$$\boldsymbol{X}^{+} = (\boldsymbol{X}^{t}\boldsymbol{X})^{-1}\boldsymbol{X}^{t}$$

Determinar los parámetros como:

$$\boldsymbol{w} = \boldsymbol{X}^{+}y$$

Fin-procedimiento

Salida = {w}

☞ Solución por optimización numérica (descenso por el gradiente)

Comienzo_procedimiento

$k = 0$

$w_i(k) = valor\ inicial$

Repetir hasta convergencia

$Desde\ i\ = 0{:}\,d$

$$w_i(k+1) = w_i(k) - \alpha g_k\ donde\ g_k = \nabla J(\boldsymbol{w})\Big|_{w_i(k)}$$

$k = k + 1$

Fin-procedimiento

Salida = {w}

Por ser la función de costo una función convexa, sólo tiene un mínimo global. Por ejemplo, si w_0 = 0 y una sola variable:

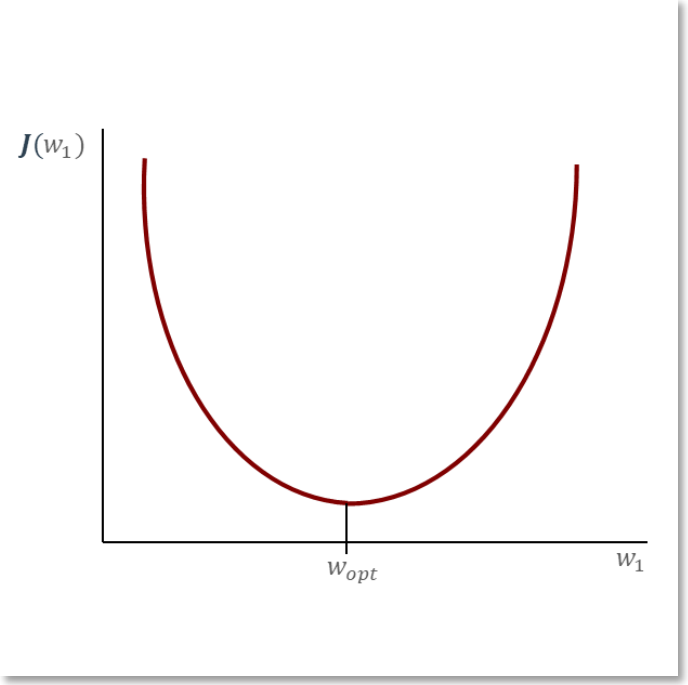

Ambos algoritmos consiguen la solución w_{opt}

Entonces ¿Qué es un algoritmo de aprendizaje?

Solo atributos numéricos

	x_1	x_2		x_d	y
Instancia 1					
Instancia 2					
Instancia N					

Aprendizaje supervisado
Tarea de regresión

Algoritmo de aprendizaje

Procedimiento de optimización

Función de costo

Procedimiento analítico:

Entrada = Conjunto de datos $D = \{(\boldsymbol{x}_i, y_i)\}_{i=1..N}$

Comienzo

Construir la matriz $\boldsymbol{X}$ *y el vector* $\boldsymbol{y}$ *a partir del conjunto de datos*

Calcular la pseudo-inversa $\boldsymbol{X}^+$ *de la matriz* $\boldsymbol{X}$ *=*

$$\boldsymbol{X}^+ = (\boldsymbol{X}^T\boldsymbol{X})^{-1}\boldsymbol{X}^T$$

Determinar los parámetros como:

$$\boldsymbol{w} = \boldsymbol{X}^+\boldsymbol{y}$$

Fin-procedimiento analítico

Salida = solución $\{\boldsymbol{w}\}$

Modelo estimado

Seleccionado de

Conjunto de hipótesis
H

$$\hat{y} = w_0 + w_1 \times x_1 + w_2 \times x_2 + \cdots + w_d \times x_d$$

$$parámetros\ del\ modelo = \{w_0, w_1, \ldots, w_d\}$$
$$d = No.\,de\ variables$$

$$J(W) = \frac{1}{N}\sum_{i=1}^{N}\left(\left((w_0 + w_1 \times x_{i1} + w_2 \times x_{i2} \ldots\ldots w_d \times x_{id})\right) - y_i\right)^2$$

Métricas para evaluar modelos de regresión:

Métrica	Interpretación
$r^2 = \frac{\sum_{i=1}^{N}(\widehat{y_i} - \bar{y})^2}{\sum_{i=1}^{N}(y_i - \bar{y})^2}$	Proporciona una medida de la proporción de la variación en la variable objetivo que es explicada por el modelo. Si, por ejemplo, r2 = 86,3 podríamos afirmar: “86,3% de la variabilidad en la variable respuesta es tomada en cuenta por la combinación lineal entre esta y las variables predictoras”. Dependiendo del contexto, podría no obtenerse valores altos de r2. Por ejemplo, en estudios sociales podrían obtenerse valores inferiores al 50%, por la dificultad de incluir en el modelo todas las variables que pueden incidir en las predicciones. Sin embargo, aun con valores bajos, si hay variables predictoras estadísticamente significativas, siempre será de utilidad hacer el análisis.
$MSE = \frac{1}{N}\sum_{i=1}^{N}(\widehat{y_i} - y_i)^2$	Para la interpretación, se suele utilizar la raíz cuadrada de este valor (RMSE) conocida como error típico o error estándar. Una ventaja es que el resultado se expresa en las unidades de medida de la variable objetivo. Es muy importante conocer la distribución de esta variable para poder determinar la calidad del modelo con base en el error. Por ejemplo, si el RMSE es de 5 ¿Podemos decir que el error es pequeño? ¿Es grande? Si la escala de la variable objetivo está entre [1, 10000] podríamos concluir que es pequeño, pero si la escala es de [1, 10] ¿También lo será? Seguramente no en este contexto. Tener en cuenta que al elevar al cuadrado el error de predicción se produce una sobreestimación cuando la diferencia entre el valor estimado y el valor real es grande, por lo que es sensible a valores extremos.
$MAE = \frac{1}{N}\sum_{i=1}^{N}\lvert\widehat{y_i} - y_i\rvert$	Al igual que MSE, mide el error de predicción. Además, las consideraciones de interpretación que se hicieron para este también aplican para MAE. Sin embargo, resulta más adecuada cuando en el conjunto de datos hay valores extremos.

En general…

¿Qué debemos tener en cuenta para utilizar un algoritmo?

Por ejemplo, regresión lineal…

☞ Con respecto a los datos:

- Solo variables numéricas. Pero, si el conjunto de datos tiene variables nominales ¿Qué hacer?
- ¿Qué pasa con la correlación (colinealidad) entre las variables?
- ¿Qué otras características de los datos debemos considerar para este algoritmo?
- ¿Escala bien con el número de datos?

☞ Con respecto a los resultados:

- ¿Cómo interpretar el modelo? ¿Qué significado tienen los coeficientes?

☞ Otros aspectos: control de la complejidad y ajuste de hiperparámetros, suposiciones sobre la función $objetivo$, contextos de aplicación, …

En resumen…

- Los algoritmos de aprendizaje trabajan sobre una clase de modelos (clase de hipótesis). Por ejemplo, la clase de hipótesis del algoritmo de regresión lineal es:

$$y = w_0 + w_1 \times x_1 + w_2 \times x_2 + \cdots + w_d \times x_d$$

- Cada clase de modelos tiene un conjunto de parámetros ajustables. Cada conjunto de posibles valores de estos parámetros define un modelo dentro de esta clase. Por ejemplo, para regresión lineal serán los coeficientes que acompañan a las variables de entrada en la combinación lineal.

- El algoritmo de aprendizaje de la regresión lineal es un procedimiento de optimización sobre una función de costo. Esta función de costo mide la discrepancia entre lo que predice el modelo y el valor real. Las variables de la función de costo son los parámetros de la clase de modelos con la que trabaja el algoritmo.

- La tarea entonces del algoritmo de aprendizaje es determinar los valores de los parámetros que mejor se ajustan a los datos (al hacerlo, implícitamente está seleccionado un modelo de la clase de hipótesis). Este modelo es el resultado del aprendizaje: una aproximación a la función (relación) desconocida que está representada por el conjunto de datos.

- Importante: **encontrar la representación de los datos que es adecuada para el algoritmo**.

Próxima sesión

- Discriminantes lineales.
- Regresión logística.
- Métricas para evaluar modelos de clasificación.